

Estimación de la Probabilidad de Victoria a partir del Estado de Juego en el Pokémon Trading Card Game: un Estudio de Clasificación Tabular con Control Explícito de Fuga de Información

Versión preliminar — Etapa 1: estado del arte y diseño propuesto

Adriel S. Chaves Salazar

Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica
2021031465

Daniel Duarte Cordero

Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica
2022012866

Sebastián Hernández Bonilla

Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica
2022093651

Resumen—Resumen preliminar. Este resumen describe el problema, la motivación y el enfoque propuesto. No reporta resultados experimentales, puesto que en esta etapa no se ha entrenado ningún modelo.

Evaluar una posición es una competencia central en los juegos de cartas competitivos y, sin embargo, en el Pokémon Trading Card Game no existe trabajo publicado que estime la probabilidad de victoria a partir de un estado de juego intermedio y parcialmente observable. El corpus de repeticiones del PTCG AI Battle Challenge, publicado recientemente, vuelve tratable la pregunta, pero su estructura hace que sea fácil responderla mal: una sola partida genera cientos de estados fuertemente correlacionados, de modo que una partición aleatoria a nivel de fila coloca estados de la misma partida a ambos lados de la división. En una auditoría de 52 085 episodios medimos que tal partición situaría el 99.995 % de los episodios en ambas particiones de forma simultánea.

Este trabajo pregunta, por tanto, cuánta información sobre el desenlace contiene un único estado observable, cómo crece esa información conforme avanza la partida, y cuánta sobrevive al evaluar sobre partidas, mazos y periodos no vistos. Se propone una formulación tabular supervisada, una fila por estado fresco del asiento activo, con características derivadas exclusivamente de la observación disponible en ese instante; una escalera de modelos clásicos que va desde un predictor trivial hasta potenciación del gradiente; una lista negra explícita de campos cuyo uso constituiría fuga de datos; y particiones agrupadas por episodio en lugar de por fila. La evaluación reporta discriminación y calibración por separado, de forma global y por ventana de turno, con intervalos de confianza remuestreados sobre episodios.

Como referencia externa parcialmente comparable se adopta la tarea análoga sobre estados de juego de Hearthstone, cuyo resultado oficial de referencia alcanzó un área bajo la curva ROC de 0.7846 y cuya mejor solución alcanzó 0.8019; las diferencias de juego, protocolo y población de agentes que impiden una comparación estricta se declaran de forma explícita.

Palabras clave—estimación de probabilidad de victoria, juegos de cartas coleccionables, aprendizaje automático tabular, fuga de datos, validación cruzada agrupada, calibración de clasificadores

I. INTRODUCCIÓN

I-A. Contexto y relevancia

Estimar la probabilidad de que un jugador venza desde la posición que ocupa actualmente sobre la mesa es una competencia recurrente de los sistemas que juegan. Una función de evaluación de estados convierte una búsqueda intratable en una tratable: permite a un agente detener una simulación antes de tiempo y aun así devolver un juicio con sentido. En los juegos competitivos esa misma estimación tiene un segundo público, pues analistas y jugadores la leen como una afirmación sobre qué recursos deciden realmente una partida. Ambos usos dependen del mismo objeto: una función que asigna a una posición observable una probabilidad de victoria.

Esa cantidad posee una propiedad que conviene fijar desde el comienzo. Brill *et al.* señalan que la probabilidad de victoria no es una estadística contable ni una magnitud observable, sino que queda definida por un modelo estimado a partir de datos [1]. El desenlace observado de una partida es binario, mientras que la magnitud que se desea estimar es una probabilidad que nunca se observa de forma directa.

[RAZÓN: Esta declaración debe aparecer en los primeros párrafos. Si no se establece que la probabilidad verdadera es inobservable, el lector puede suponer que existe una etiqueta contra la cual verificar cada predicción, y toda la discusión posterior sobre calibración pierde sentido.]

I-A1. *Dos propiedades que dificultan la tarea en juegos de cartas:* La primera es la información imperfecta. Un jugador nunca ve la mano del oponente ni las cartas de premio, de modo que el evaluador opera sobre una vista parcial y no sobre el estado verdadero del mundo.

La segunda es la no estacionariedad. El repertorio de cartas legales, los mazos que los jugadores llevan y la población de adversarios cambian con el tiempo, y un modelo ajustado a un conjunto de estrategias dominante no tiene por qué sobrevivir

al siguiente. Bertram *et al.* lo muestran de forma concreta para *Magic: The Gathering*: una representación de carta basada en codificación por identidad alcanza un 67.80 % de acierto sobre el conjunto de cartas con el que fue entrenada y queda simplemente indefinida sobre cartas que nunca vio, mientras que una representación construida a partir de atributos conserva un 68.00 % dentro de la distribución y aún alcanza un 42.87 % sobre conjuntos no vistos [2].

I-A2. La tarea en el dominio de los juegos competitivos:

En deportes electrónicos de tipo arena multijugador, la literatura trata la predicción de resultado como una aplicación consolidada del aprendizaje automático, y emplea tanto variables previas a la partida como información observada durante ella [3]. Tian *et al.* realizan predicción en tiempo real a partir de secuencias de estados y muestran que la importancia de la alineación, el oro, las bajas y las torres varía con el progreso del encuentro [4].

La utilidad de esta estimación excede el interés metodológico. Hodge *et al.* observan que, a diferencia de los deportes tradicionales, numerosos juegos competitivos carecen de un marcador legible, y que su complejidad dificulta el seguimiento por parte de audiencias no expertas; una estadística única que resuma el estado de la partida amplía el atractivo del juego y lo vuelve más accesible [5]. Xenopoulos *et al.* desarrollan la misma línea al estimar la probabilidad de victoria por ronda y analizar cómo varían los efectos de las características del estado entre poblaciones de jugadores con distinto nivel de habilidad [6].

En juegos de cartas la idea aparece con objetivos distintos. Miernik y Kowalski evolucionan funciones de evaluación para *Legends of Code and Magic*, cuya salida es un puntaje heurístico optimizado de forma indirecta por el rendimiento del agente y no una probabilidad calibrada de victoria [7]. Más cerca de la formulación adoptada aquí, el AAIA'17 Data Mining Challenge solicitó predecir el ganador de una partida de *Hearthstone* a partir de un único estado de juego, y reportó un resultado oficial de referencia de 0.7846 de área bajo la curva ROC frente a una mejor solución de 0.8019 [8]. Para *StarCraft II*, el descriptor SC2EGSet acompaña su corpus de repeticiones con experimentos de predicción de victoria sobre indicadores económicos agregados, y alcanza un acierto de 0.9071 cuando dispone de las características de ambos jugadores [9].

El *Pokémon Trading Card Game* carece de un estudio publicado comparable, pese a que su estructura de recursos—cartas de premio, asignación de energía, banca, líneas de evolución— difiere de la de ambos juegos de maneras que deberían cambiar qué características transportan información.

[RAZÓN: Declarar que la tarea no es inédita fortalece el trabajo en lugar de debilitarlo. Un planteamiento que reclamara originalidad absoluta sería contradicho por las referencias del propio documento, y la contribución real se sitúa en el traslado al dominio y en el tratamiento metodológico.]

I-A3. Generalización ante contenido y poblaciones cambiantes: Chitayat *et al.* muestran que representaciones ligadas a parámetros de diseño pueden conservar su rendimiento al

atravesar actualizaciones posteriores del juego, mientras que las basadas únicamente en identidad resultan más frágiles [10]. En el videojuego competitivo de la franquicia Pokémon, Angliss *et al.* separan de forma explícita el rendimiento sobre composiciones vistas de la generalización a composiciones no vistas, y muestran que entrenar con mayor diversidad mejora esa segunda capacidad [11].

Estos antecedentes motivan que una evaluación sobre el *Pokémon TCG* no se limite a una partición aleatoria de partidas, sino que examine además cambios temporales y composiciones no observadas durante el entrenamiento.

[POR COMPLETAR: Dos o tres oraciones con datos concretos del dominio del juego de cartas: tamaño de la comunidad competitiva, cantidad de cartas disponibles, complejidad combinatoria de la construcción de mazos.]

El estado de una partida involucra premios restantes, puntos de vida, energías acumuladas, cartas en mano, evoluciones y estados alterados, distribuidos entre dos jugadores con información parcial sobre el mazo y la mano del oponente. Un observador no experto no puede determinar de un vistazo cuál de los dos se encuentra en ventaja.

I-B. Planteamiento del problema

Este trabajo aborda una limitación específica: para el *Pokémon TCG* no existe evidencia sobre cuánta información contiene un único estado observable acerca del desenlace, sobre cómo se acumula esa información a lo largo de la partida, ni sobre cuánta se transfiere a partidas, mazos y periodos temporales no vistos durante el entrenamiento.

La literatura que respondería esas preguntas para juegos adyacentes responde solo una parte. Janusz *et al.* reportan discriminación pero no calibración [8]; Białecki *et al.* reportan acierto y describen sus propios experimentos como más ilustrativos que investigativos [9]; y ninguno reporta rendimiento bajo un cambio de distribución declarado.

I-B1. La estructura del corpus y su consecuencia: Esa brecha se ha vuelto abordable recientemente. El PTCG AI Battle Challenge publica a diario repeticiones en formato JSON de partidas completas entre agentes que compiten entre sí [12]. El corpus declara 67 entregas diarias, del 2026-06-16 al 2026-08-21, con 329 336 episodios y 1.29 TB sin comprimir.

Nuestra auditoría cubre una muestra temporal de diez de esos días, el 14.9 % de los días y el 15.8 % de los episodios declarados. Dentro de esa muestra se analizaron 52 085 episodios a partir de 182.6 GiB de JSON con cero errores de análisis sintáctico, y se obtuvieron 7 038 378 instantáneas de estado utilizables: aproximadamente 135 filas correlacionadas por cada partida independiente.

Datos con esta forma premian el protocolo equivocado. Si esas instantáneas se particionaran al azar, estados de una misma partida aparecerían simultáneamente en entrenamiento y en prueba. Lo medimos directamente: bajo una partición aleatoria 70/30 a nivel de instantánea, la fracción esperada de episodios presentes en ambas particiones es 0.999945.

Brill *et al.* demuestran que, cuando múltiples observaciones comparten el mismo sorteo del desenlace, el sesgo y la

varianza de los estimadores se incrementan y el tamaño de muestra efectivo se reduce sustancialmente [1]. Karbalaie *et al.* midieron el efecto sobre las cifras reportadas en un conjunto clínico de medidas repetidas, donde un clasificador de árboles extremadamente aleatorizados obtuvo 0.91 de acierto bajo validación cruzada estratificada de diez pliegues y 0.66 bajo validación dejando un participante fuera, una inflación de 0.25 producida enteramente por la regla de partición [13]. Figueiredo y Mendes cuantifican el mismo fenómeno en conjuntos de imágenes con alta correlación espaciotemporal [14].

El costo de ignorar la estructura no es, por tanto, un sesgo marginal: es la diferencia entre un resultado y un artefacto.

[RAZÓN: Este párrafo debe existir en la introducción y no solo en la metodología. El riesgo metodológico propio del track seleccionado es la fuga de información, y presentarlo desde el planteamiento del problema convierte su control en parte de la contribución en lugar de en una precaución técnica mencionada al final.]

I-B2. *El problema es también de procedencia:* Puesto que el corpus fue recolectado por un tercero y publicado en medio de una competencia en curso, no controlamos su procedencia, que es precisamente la situación que Kaufman *et al.* identifican como el caso más difícil para el control de la fuga de datos [15]. Establecer que una cifra reportada significa lo que aparenta significar forma parte, por tanto, del problema de investigación y no de sus preliminares.

El problema metodológico central consiste entonces en estimar $P(\text{victoria} \mid \text{estado})$ empleando exclusivamente información observable hasta el instante de predicción, y manteniendo intactas las unidades independientes durante la evaluación.

I-C. *Pregunta de investigación*

PI: ¿En qué medida las características observables del estado de una partida de *Pokémon TCG* permiten estimar la probabilidad de su desenlace mediante modelos clásicos de aprendizaje automático; cómo varía esa capacidad predictiva conforme progresa la partida; y cuánta se conserva al evaluar sobre episodios, mazos y periodos temporales ausentes del entrenamiento?

Condiciones de refutación. La respuesta sería negativa, o quedaría sustancialmente debilitada, si el intervalo de confianza del área bajo la curva ROC en la ventana temprana incluyera el valor 0.5; si el desempeño no mejorara al avanzar la partida una vez controlada su longitud; si el modelo no superara a una heurística de dominio sobre partidas no vistas; o si la señal desapareciera bajo el protocolo temporal o el de reserva de mazos.

Condiciones de medición. La discriminación se mide mediante el área bajo la curva ROC, y la calidad de la probabilidad mediante la pérdida logarítmica, el puntaje de Brier y curvas de fiabilidad. Las métricas se reportan de forma global y por ventana de turno. Las particiones y los intervalos de confianza se construyen sobre episodios, aunque cada fila de la representación tabular corresponda a una observación individual.

Condiciones de viabilidad. La pregunta puede responderse dentro del semestre: los datos ya están descargados y auditados, y definir el protocolo no requiere entrenar ningún modelo.

[RAZÓN: El enunciado exige que la pregunta pueda responderse con evidencia y admita refutación. Enumerar las condiciones concretas bajo las cuales la respuesta sería negativa es lo que distingue una pregunta de investigación de una expectativa.]

I-D. *Hipótesis de trabajo*

H1. Las características estructuradas del estado observable contienen señal predictiva sobre el desenlace desde etapas tempranas de la partida —área bajo la curva ROC significativamente superior a 0.5 en la ventana temprana— y esa señal aumenta conforme la partida progresa.

H2. La señal temprana no se explica únicamente por el orden de turno ni por la identidad del mazo.

H3. Bajo el protocolo temporal, la calibración se degrada antes y en mayor medida que la discriminación.

Fundamento de H3. No es una conjetura sino una predicción importada de un campo vecino. Guo *et al.* revisaron quince estudios clínicos sobre cambio temporal del conjunto de datos y encontraron que los once estudios que midieron calibración reportaron deterioro de la calibración, mientras que solo tres de los doce que midieron discriminación reportaron deterioro de la discriminación [16]. Xenopoulos *et al.* observan el mismo patrón en un juego competitivo: un modelo evaluado fuera de su entorno presenta un incremento moderado en la pérdida logarítmica acompañado de una degradación considerablemente mayor en el error de calibración esperado [6]. Silva Filho *et al.* ofrecen la explicación formal: las reglas de puntuación propias se descomponen en un componente de calibración y uno de refinamiento, y las métricas basadas exclusivamente en el ordenamiento son invariantes ante transformaciones monótonas de las probabilidades predichas [17].

Que esa asimetría se sostenga en un dominio de juegos es una pregunta empírica abierta, y enunciarla como hipótesis la vuelve falsable aquí.

Criterios de falsación. La componente temprana de H1 se debilita si el intervalo de confianza del área bajo la curva en esa ventana incluye 0.5, y su componente dinámica queda refutada si el valor por ventana no crece una vez controlada la duración de la partida. H2 queda refutada si un modelo restringido al orden de turno y a la identidad del mazo iguala al conjunto completo de características, lo que indicaría un artefacto de emparejamiento y no señal del estado de juego. H3 queda refutada si el puntaje de Brier y las curvas de fiabilidad no se degradan más rápido que el área bajo la curva bajo la partición temporal. Una caída hasta el nivel del azar en el protocolo temporal se interpretará como ausencia de generalización y no como fallo de ejecución.

No se fija de antemano ningún umbral numérico de mejora: sin resultado empírico previo sobre este corpus, cualquier número de ese tipo sería inventado.

Advertencia sobre H1. Brill *et al.* documentan que el sesgo del estimador es considerablemente mayor al comienzo de la partida, por dos razones estructurales: los estados tempranos con desequilibrios marcados son infrecuentes, y resulta más difícil vincular un estado temprano con un desenlace determinado al final [1]. En consecuencia, un desempeño reducido en la ventana temprana admite dos interpretaciones que este diseño debe procurar distinguir: ausencia genuina de señal, o sesgo del estimador por escasez de observaciones en esa región del espacio de estados.

[RAZÓN: Declarar esta ambigüedad antes de obtener resultados es obligatorio. Sin ella, un desempeño bajo en turnos tempranos se interpretaría como refutación de H1 cuando podría deberse al sesgo que la referencia documenta.]

[DECIDIR: Para separar ambas interpretaciones hay que definir en la Etapa 2 un procedimiento adicional: reportar el conteo de episodios y de observaciones por ventana de turno junto a las métricas, o restringir el análisis temprano a regiones del espacio de estados con soporte suficiente. La decisión afecta el diseño experimental y conviene tomarla antes de ejecutar.]

I-E. Objetivos

Objetivo general. Desarrollar y evaluar modelos clásicos de aprendizaje automático que estimen la probabilidad de victoria en partidas de *Pokémon TCG* a partir de características tabulares derivadas exclusivamente del estado observable, y caracterizar cómo evoluciona esa capacidad predictiva a lo largo de la partida y ante cambios de episodio, mazo y periodo temporal.

Objetivos específicos.

1. Formalizar la estimación de la probabilidad de victoria a partir del estado de juego como un problema de clasificación binaria probabilística sobre datos tabulares, estableciendo la distinción entre la unidad de observación y la unidad estadísticamente independiente.
2. Caracterizar el corpus y su calidad sobre la representación tabular final: análisis exploratorio, diccionario de datos, mecanismos de ausencia, valores atípicos, balance de clases y representatividad.
3. Construir una tubería reproducible que vaya de la repetición en formato JSON a una tabla de instantáneas frescas con perspectiva normalizada, semillas fijas y verificación de esquema.
4. Diseñar y verificar los controles de fuga de datos: agrupación por episodio, lista negra explícita de campos prohibidos y pruebas automatizadas que fallen si una columna prohibida entra al vector de características.
5. Comparar una escalera de modelos de referencia, desde un predictor trivial hasta potenciación del gradiente, bajo tres protocolos de partición, reportando discriminación y calibración con intervalos de confianza calculados sobre episodios.
6. Analizar explicabilidad y generalización: ablaciones por familia de características, importancia por permutación agrupada, curvas de fiabilidad y la curva de capacidad predictiva por turno.

[RAZÓN: Los objetivos deben poder verificarse al final del semestre. Se redactan como acciones con producto observable —formalizar, caracterizar, construir, diseñar, comparar, analizar— y no como intenciones de desempeño, porque un objetivo del tipo «superar un umbral» quedaría incumplido si el resultado fuera negativo, cuando un resultado negativo también responde la pregunta.]

I-F. Contribución esperada

Se esperan tres contribuciones.

La primera es una caracterización de la probabilidad de victoria desde el estado de juego en un juego de cartas que no ha sido estudiado de esta forma, incluyendo el perfil por turno de la capacidad predictiva que Janusz *et al.* reportan para *Hearthstone* pero que no existe para el *Pokémon TCG* [8].

La segunda es un protocolo de evaluación cuyos controles de fuga están medidos y no solo afirmados: la auditoría cuantifica la contaminación que produciría el protocolo ingenuo, de modo que el diseño agrupado se justifica con una cifra de este corpus y no por analogía.

La tercera es un análisis explícito de la diferencia entre discriminación y calidad probabilística, dimensión que Grinsztajn *et al.* identifican como pendiente en la evaluación de modelos tabulares [18] y que la literatura de predicción de desenlace en juegos ha reportado de forma desigual. A ello se suma una tubería reproducible y un diccionario de datos documentado para un corpus que hoy carece de descripción arbitrada, siguiendo la estructura que el descriptor SC2EGSet establece para datos de repeticiones de deportes electrónicos [9].

Un resultado negativo también sería una contribución. Si la discriminación colapsa bajo el protocolo temporal, eso constituye evidencia sobre la rapidez con que un conjunto de estrategias dominante invalida un evaluador de estados, que es la pregunta que Bertram *et al.* plantean para repertorios de cartas en cambio permanente [2].

[RAZÓN: La contribución se enuncia en términos de aportes verificables y no de resultados prometidos. Comprometerse en la Etapa 1 con un nivel de desempeño a la altura del trabajo a un resultado que aún no se conoce.]

I-G. Estructura del documento

La Sección II revisa la literatura en tres ejes —el problema y su dominio, las técnicas del *track* seleccionado, y el conjunto de datos— y cierra con la identificación explícita de las brechas. La Sección III declara el punto de referencia tomado de la literatura y discute su comparabilidad. La Sección IV presenta la formalización del problema, el protocolo experimental y el plan de modelos de referencia. La Sección V desarrolla el análisis técnico exigido por el *track* seleccionado, con énfasis en la prevención de fuga de información. La Sección VI documenta las consideraciones éticas preliminares.

II. TRABAJOS RELACIONADOS

Los candidatos se recuperaron de Scopus, IEEE Xplore, la ACM Digital Library, Springer, los *proceedings* de AAAI y AIIDE, y los registros de los editores de las

revistas correspondientes. Las cadenas de búsqueda combinaron win prediction, game state, collectible card game y esport replay dataset para el dominio, y data leakage, grouped cross-validation, repeated measures, temporal dataset shift y tabular deep learning para la metodología.

La inclusión exigió venue arbitrado de revista o conferencia, un DOI que resolviera, y contenido que respaldara una decisión efectivamente tomada en este trabajo. Se excluyeron los estudios exclusivamente previos a la partida cuando no aportaban a la representación de estados ni a la generalización. La mayoría de los trabajos retenidos se publicó en 2021 o después; los más antiguos se conservan de forma deliberada por ser referencias fundacionales del campo o el único antecedente publicado de la tarea.

[POR COMPLETAR: Completar con el número total de trabajos cribados y retenidos por el equipo, consolidando los registros de selección de los tres ejes.]

[RAZÓN: Este párrafo convierte la revisión en un procedimiento auditable en lugar de una lista de lecturas. Hodge et al. organizan su revisión declarando los temas que la estructuran [5], y Grinsztajn et al. enuncian criterios explícitos de inclusión de conjuntos de datos [18]; ambas prácticas son el precedente de exigir transparencia en el procedimiento.]

II-A. Eje A: el problema y su dominio

II-A1. Predicción del desenlace a partir de un único estado: La formulación dominante trata la predicción del desenlace como clasificación binaria supervisada sobre una instantánea de la posición, con la etiqueta tomada del resultado registrado de la partida completa. El AAI'A17 Data Mining Challenge lo enuncia exactamente en esos términos para *Hearthstone*: los participantes recibían la descripción de un estado de juego y entregaban la verosimilitud de que el jugador uno venciera, puntuada mediante el área bajo la curva ROC [8]. El descriptor SC2EGSet aplica el mismo encuadre a *StarCraft II*, derivando indicadores económicos de las repeticiones y clasificando el desenlace a partir de ellos [9]. Ninguna de las dos formulaciones requiere un simulador en el momento de la predicción, y ninguna trata la trayectoria como un problema de control. Esta es la formulación que se adopta aquí.

La revisión sistemática de Kamal et al. sitúa estos trabajos en un campo más amplio: incluye treinta y cinco estudios sobre juegos de arena multijugador y encuentra un predominio del aprendizaje supervisado, con uso frecuente de estadísticas de jugador, mecánicas del juego y eventos intra-partida [3].

Lo que estos trabajos establecen es que la formulación es viable y que la señal es sustancial. Lo que no establecen es que el nivel alcanzable se transfiera entre juegos. Los puntos de operación reportados difieren más entre sí que la diferencia entre métodos dentro de cualquiera de los estudios, y no están medidos en la misma escala: Janusz et al. reportan área bajo la curva sobre estados extraídos de partidas entre agentes que eligen sus acciones al azar, mientras que Bialecki et al. reportan acierto sobre características promediadas a lo largo de toda la partida.

II-A2. Capacidad predictiva a lo largo de la partida: Un segundo tema, presente en varios trabajos pero desarrollado por ninguno, es que la capacidad predictiva no es un escalár.

Janusz et al. grafican el área bajo la curva sobre turnos consecutivos y muestran que crece a lo largo de la partida [8]. Bialecki et al. grafican el acierto sobre el tiempo de partida y observan que sus tres clasificadores alcanzan una asíntota alrededor de los 550 segundos, lo que interpretan como el punto en que los indicadores económicos dejan de aportar información adicional [9]. Tian et al. encuentran que la utilidad de las variables cambia con la etapa: la alineación domina al inicio, el oro gana relevancia en la etapa media, y las bajas y las torres se vuelven más informativas posteriormente; reportan una exactitud del 81.8 % en el nodo temporal de siete minutos según su tabla detallada, si bien el resumen del artículo menciona 84.7 % [4].

[RAZÓN: La discrepancia entre el valor de la tabla y el del resumen debe consignarse. Reportar únicamente la cifra más alta sin señalar la divergencia constituiría una lectura selectiva de la fuente.]

Todas estas curvas señalan el mismo punto metodológico: una única cifra agregada promedia un régimen en el que el estado dice poco con otro en el que lo dice casi todo. Ninguno de estos trabajos reporta intervalos de confianza sobre esas curvas, y ninguno reporta cómo cambia su forma cuando cambia la población de jugadores.

Hodge et al. organizan las características empleadas en la literatura según el momento en que están disponibles —previas al juego, durante el juego y posteriores al juego— y recogen la observación de que las disponibles durante el juego concentran la información más útil para la predicción [5]. Su revisión reúne dieciséis trabajos previos y advierte que la variación en tamaño, composición y versión del juego entre los conjuntos empleados obliga a tratar con cautela la comparación de las exactitudes reportadas.

[RAZÓN: Esta advertencia debe recogerse de forma explícita porque es el precedente de dominio de la declaración de comparabilidad que exige la Sección III.]

II-A3. Evaluación de estados en juegos de cartas: Miernik y Kowalski evolucionan funciones lineales y basadas en árboles para asignar un valor escalar a estados de *Legends of Code and Magic*; su mejor variante alcanza un 60.2 % de tasa de victoria en el torneo de evaluación, pero la función se optimiza de forma indirecta mediante el desempeño del agente y no representa una probabilidad aprendida a partir de pares estado–desenlace [7].

Xenopoulos et al. estiman la probabilidad de victoria por ronda en un videojuego de disparos tácticos y comparan tres poblaciones de jugadores con distinto nivel de habilidad [6]. Su representación del estado combina información global de la ronda con información agregada por bando, estructura análoga a la que se adopta aquí. Reportan que los modelos se encuentran bien calibrados dentro de su propio entorno, y que el entrenado sobre la población de menor nivel presenta mayor pérdida logarítmica y menor calidad de calibración al evaluarse sobre las poblaciones profesionales.

II-A4. Generalización ante contenido cambiante: El contenido de estos juegos no se queda quieto. Bertram *et al.* lo abordan directamente para *Magic: The Gathering*, evaluando mediante la reserva de un conjunto de cartas completo. Sus resultados separan dos capacidades que una única puntuación dentro de la distribución confunde: una codificación por identidad alcanza un 67.80 % de acierto sobre datos reservados del mismo conjunto y no puede producir predicción alguna para cartas nunca vistas, mientras que las representaciones construidas a partir de atributos alcanzan un 68.00 % dentro de la distribución y un 42.87 % sobre conjuntos no vistos; escalado a un corpus de 2990 cartas, el mismo modelo alcanza un 55.44 % sobre un conjunto enteramente reservado [2]. La lección trasciende su tarea: una codificación del contenido basada en la identidad puede ser indistinguible de una semántica dentro de la distribución y no valer nada fuera de ella.

Chitayat *et al.* proponen una representación de personajes basada en atributos y habilidades de diseño en lugar de identificadores; un modelo que la emplea mantiene su desempeño sobre dos versiones posteriores del juego no utilizadas para entrenar [10]. Su caso de estudio, sin embargo, predice conteos finales a partir de duración y composición de equipo, y no probabilidad de victoria desde un estado intermedio.

Angliss *et al.* abordan la diversidad de composiciones. Su banco de pruebas separa composiciones vistas de composiciones fuera de distribución, y reporta que el agente entrenado con mayor diversidad transfiere mejor a composiciones no vistas aun cuando su rendimiento empeora en configuraciones familiares [11].

Saravanan y Guzdial estudian la evolución del conjunto de estrategias dominante ante cambios de balance del juego [19]. El trabajo se sitúa en el videojuego competitivo de la franquicia Pokémon y no en el juego de cartas coleccionables, distinción que debe mantenerse presente al interpretar sus resultados. Los autores definen dicho conjunto como el conocimiento que excede las reglas del juego y que se manifiesta en los personajes y estrategias predominantes dentro de la base de jugadores, y observan que cambia de forma continua.

[RAZÓN: La aclaración sobre cuál juego de la franquicia estudia este trabajo es obligatoria en su primera mención. Presentarlo sin la distinción atribuiría al artículo un alcance que no tiene.]

II-A5. Síntesis del eje: Enfoques predominantes. En deportes electrónicos predominan los métodos supervisados para predicción de resultado y, en trabajos sobre estado dinámico, las representaciones que incorporan información intra-partida. En juegos de cartas y en Pokémon aparecen además evaluadores heurísticos, búsqueda, clonación de comportamiento y aprendizaje por refuerzo, pero dichos enfoques optimizan decisiones o políticas y no necesariamente producen probabilidades calibradas [3], [7], [11].

Aspectos considerados resueltos. La predicción del desenlace a partir de un estado intermedio es un problema supervisado bien planteado y tratable en juegos de cartas coleccionables y en juegos de estrategia en tiempo real; las características tabulares derivadas del estado transportan señal sustancial [8], [9]; y la capacidad predictiva varía sistemáticamente a lo largo de la

partida [4]. Existen asimismo protocolos explícitos para estudiar la robustez ante actualizaciones del juego y ante composiciones no vistas [2], [10], [11].

Aspectos abiertos. Si las probabilidades estimadas están calibradas y no meramente bien ordenadas; cómo se comporta el perfil por etapa bajo un cambio declarado en la población de jugadores o de mazos; y si algo de esto se sostiene en el *Pokémon TCG*, para el que no existe estudio publicado. Tampoco resulta válido asumir que los resultados obtenidos en juegos de arena multijugador, en el videojuego competitivo de Pokémon o en *Hearthstone* se transfieren de forma directa, dado que difieren las reglas, las unidades de observación, los protocolos y la población.

II-B. Eje B: las técnicas del track seleccionado

El *track* seleccionado corresponde al aprendizaje automático clásico sobre datos tabulares. Este apartado establece el estado actual de dichos métodos, los supuestos bajo los cuales operan, y las condiciones que determinan la validez de las cifras que producen.

II-B1. Estado actual de los métodos tabulares: Borisov *et al.* presentan una revisión sistemática de los enfoques de aprendizaje profundo para datos tabulares heterogéneos, junto con una comparación experimental frente a métodos clásicos bajo un protocolo uniforme [20]. Los autores organizan la literatura en tres familias: métodos de transformación de datos, arquitecturas especializadas y modelos de regularización. Su evaluación reporta que los conjuntos de árboles con potenciación del gradiente obtienen los mejores resultados en la mayoría de los conjuntos considerados, y concluye que la conveniencia de emplear técnicas actuales de aprendizaje profundo sobre datos tabulares admite en general una respuesta negativa, particularmente para conjuntos heterogéneos de tamaño reducido.

Grinsztajn *et al.* amplían la evidencia con una comparación sobre cuarenta y cinco conjuntos de datos, contabilizando el costo de la selección de hiperparámetros, y reportan que los modelos basados en árboles resultan superiores para todo presupuesto de búsqueda considerado [18].

II-B2. El rendimiento marginal de la complejidad en este dominio: La evidencia procedente del propio dominio de juegos apunta en la misma dirección, y lo hace con cifras. En la competencia de *Hearthstone* se registraron 296 equipos y 188 enviaron solución; todos los equipos mejor clasificados usaron redes neuronales, y aun así la puntuación ganadora de 0.8019 supera al resultado de referencia de los organizadores, 0.7846 —una red totalmente conectada de dos capas ocultas sobre la representación tabular—, por menos de un dos por ciento, y los organizadores lo hacen notar explícitamente [8]. En SC2EGSet, tres clasificadores convencionales con hiperparámetros próximos a los predeterminados quedan a menos de 0.016 de acierto unos de otros: máquina de vectores de soporte en 0.9071, potenciación del gradiente en 0.8924 y regresión logística en 0.8916 [9].

Dos estudios independientes sobre dos juegos distintos coinciden, por tanto, en que la mayor parte de la señal extraíble

de una representación tabular del estado es alcanzable sin arquitecturas profundas, y en que el residuo es lo bastante pequeño como para que la interpretabilidad y el costo dominen la elección.

Karbalaie *et al.* afinan el argumento en dirección a los modelos más simples, y por una razón inesperada: compararon diez clasificadores y encontraron que los modelos lineales fueron los más honestos bajo validación consciente de la agrupación. La regresión logística y el análisis discriminante lineal difirieron a lo sumo en 0.03 de acierto entre el protocolo contaminado y el correcto, mientras que los conjuntos de árboles mostraron brechas de al menos 0.34 y fueron los modelos cuyas puntuaciones más infló el protocolo defectuoso [13].

[RAZÓN: Este hallazgo debe consignarse porque invierte una expectativa: los modelos de alta capacidad no son solo más difíciles de interpretar, son los modelos a los que un protocolo defectuoso favorece. Constituye un argumento para mantener un modelo lineal regularizado en la comparación como punto de referencia, y no por formalidad.]

II-B3. Supuestos bajo los que operan estos métodos: Grinsztajn *et al.* identifican tres propiedades de los datos tabulares que explican la diferencia de desempeño [18]. En primer lugar, las funciones objetivo asociadas a estos conjuntos no son suaves, mientras que las redes neuronales presentan un sesgo hacia soluciones suaves; los modelos basados en árboles, que aprenden funciones constantes por tramos, no exhiben dicho sesgo. En segundo lugar, los conjuntos tabulares contienen una proporción apreciable de características no informativas, ante las cuales los modelos neuronales de tipo perceptrón multicapa resultan menos robustos. En tercer lugar, las características de un conjunto tabular poseen significado individual, propiedad que los procedimientos invariantes ante rotaciones no pueden aprovechar.

[POR COMPLETAR: Párrafo argumentando cada una de las tres propiedades sobre el dominio concreto: la irregularidad de la función objetivo asociada a los umbrales duros del juego, la presencia previsible de características poco informativas en el diccionario, y el significado individual de las variables del estado.]

El supuesto que todos estos métodos comparten es que las muestras son independientes, y es exactamente el supuesto que este corpus viola. Karbalaie *et al.* cuantifican la consecuencia sobre 623 ensayos de 72 participantes: la validación cruzada estratificada de diez pliegues da un acierto de 0.91, y el mismo modelo bajo validación dejando un participante fuera da 0.66 [13]. Su explicación es la que se transfiere: en datos de medidas repetidas el tamaño muestral efectivo se aproxima al número de participantes y no al número de ensayos. Sustituir participante por episodio e instantánea por ensayo enuncia la restricción que gobierna el presente trabajo. Reportan además que la validación cruzada agrupada de k pliegues coincide con el diseño de dejar un grupo fuera dentro de 0.02 de acierto y a un costo mucho menor, lo que resulta decisivo cuando la unidad de agrupación se cuenta en decenas de miles.

[RAZÓN: Brecha de dominio, declarada de forma explícita: se trata

de un estudio de biomecánica, citado por su argumento estadístico sobre observaciones dependientes y no como resultado del dominio de juegos.]

Límites del alcance de la evidencia tabular. Borisov *et al.* reportan que, en el mayor de los conjuntos evaluados, con características predominantemente continuas, una arquitectura basada en mecanismos de atención supera a los métodos clásicos [20]. Esta observación resulta pertinente dado el volumen de observaciones disponible aquí. Sin embargo, la condición relevante no es el número de filas sino el número de unidades estadísticamente independientes —52 085 episodios frente a 7 038 378 filas—, y las variables del estado son heterogéneas y no predominantemente continuas.

Por su parte, Grinsztajn *et al.* excluyen de su comparación los conjuntos con datos faltantes, aquellos con variables categóricas de cardinalidad superior a veinte, los conjuntos cuyas observaciones no son independientes, y los conjuntos deterministas procedentes de juegos [18]. El problema abordado aquí no es determinista: el desenlace de una partida no se deduce del estado intermedio, sino que depende del orden restante del mazo, de la información oculta del oponente y de las decisiones posteriores de ambos jugadores. Es precisamente esa condición la que motiva estimar una probabilidad en lugar de deducir una etiqueta. Respecto del supuesto de independencia, este trabajo adopta el episodio como unidad independiente.

[RAZÓN: Ambos límites deben declararse en el texto y no omitirse. Son las dos objeciones más directas que puede recibir la justificación del track, y responderlas de forma anticipada es preferible a que surjan durante la sustentación.]

II-B4. Dificultad intrínseca de la tarea: Brill *et al.* examinan la dificultad de estimar la probabilidad de victoria mediante un estudio de simulación en el cual la probabilidad verdadera es calculable de forma exacta [1]. Reportan que la estructura de dependencia propia de los datos observacionales incrementa el sesgo y la varianza de los estimadores y reduce el tamaño de muestra efectivo; que resulta preferible conservar la totalidad de las observaciones por partida antes que retener una sola, dado que el conjunto completo aporta información sobre la estructura del espacio de covariables; y que los intervalos de confianza construidos mediante remuestreo presentan cobertura inferior a la nominal, incluso cuando el remuestreo respeta la estructura de agrupamiento.

Los autores declaran de forma explícita que sus hallazgos resultan aplicables a cualquier conjunto de datos en el cual la variable de resultado corresponda al desenlace de una unidad y las observaciones consistan en las unidades que conducen a dicho desenlace [1]. El corpus empleado aquí satisface esa descripción.

II-B5. La fuga de datos como objeto formal: Kaufman *et al.* aportan el marco que vuelve verificables, y no meramente intuitivas, las decisiones de partición. Definen la fuga de datos como una propiedad intrínseca de la relación entre las entradas observacionales de un modelo y la instancia objetivo: una característica es legítima solo si es observable para el propósito de inferir ese objetivo en particular, evaluada instancia por

instancia [15]. Dos consecuencias gobiernan el diseño de este trabajo. La primera es el requisito de la no máquina del tiempo: un modelo legítimo solo puede usar información de un instante no posterior al del objetivo. La segunda es la separación aprender–predecir, según la cual cada observación se etiqueta con la información necesaria para decidir su legitimidad y el conjunto de entrenamiento se construye después de modo que solo entren entradas legítimas.

Advierten además que la fuga entra por las decisiones de diseño —diseño de características, selección de modelo, elección de hiperparámetros informada por conocimiento que el modelo desplegado no tendría—, a la que llaman la forma más peligrosa porque un evaluador no puede detectarla ni siquiera buscándola, y señalan que eliminar las fugas evidentes puede no sellar el resto.

Sasse *et al.* actualizan ese marco convirtiéndolo en un catálogo de escenarios organizados como fuga de prueba a entrenamiento, de prueba a prueba, de característica a objetivo, de objetivo, de conjunto de datos y de variables de confusión [21]. Tres de sus entradas se corresponden con decisiones de este trabajo. Su tratamiento de la fuga de prueba a entrenamiento enumera el no tener en cuenta muestras dependientes como causa primaria. Su caso de preprocesamiento establece que el escalado, la imputación, la reducción de dimensionalidad y el sobremuestreo estimados sobre el conjunto completo antes de particionar constituyen por sí mismos fuga de datos. Y su categoría de característica a objetivo cubre el caso que aquí más importa: variables informativas y disponibles durante el aprendizaje pero ausentes en el despliegue, cuya prescripción es una pregunta antes que una regla —comprobar si cada característica estaría disponible tras el despliegue.

Figueiredo y Mendes complementan esa formalización con una medición. Estudian el efecto de la partición aleatoria sobre conjuntos de imágenes con alta correlación espaciotemporal, y reportan que produce una inflación apreciable de las métricas respecto de una partición que asigna agrupaciones completas [14]. Su trabajo pertenece al dominio de la visión por computador y se considera aquí un análogo metodológico; el mecanismo subyacente —observaciones casi idénticas a ambos lados de la partición— es independiente del dominio. Cabe destacar que su contribución central consiste en un procedimiento para inferir las agrupaciones, dado que las imágenes no vienen etiquetadas por escena; en este corpus la agrupación viene dada de forma exacta por el identificador de episodio.

II-B6. Evaluación de la calidad de las probabilidades: Silva Filho *et al.* presentan una revisión de los métodos para evaluar y mejorar las probabilidades predichas por un clasificador [17]. Un modelo se considera calibrado cuando las probabilidades que predice se corresponden con las frecuencias observadas. Los autores exponen que las reglas de puntuación propias se descomponen en un componente de calibración y uno de refinamiento, descomposición que fundamenta el conjunto de métricas adoptado aquí. Señalan asimismo que los estimadores del error de calibración basados en discretización dependen

del número y la construcción de los intervalos empleados.

Niculescu-Mizil y Caruana examinan las probabilidades producidas por distintas familias de algoritmos y reportan que los métodos de máximo margen, entre ellos los conjuntos de árboles con potenciación, desplazan la masa de probabilidad alejándola de los extremos, produciendo una distorsión de forma sigmoidea [22]. Reportan igualmente que la regresión logística y los conjuntos por agregación resultan bien calibrados sin corrección posterior, y que recalibrar estos últimos puede deteriorarlos. Su análisis de curvas de aprendizaje establece que el método de recalibración apropiado depende del tamaño del conjunto disponible para dicho ajuste.

[RAZÓN: Esta referencia debe aparecer porque convierte la calibración de una preocupación general en una predicción concreta sobre los modelos que este trabajo va a emplear. Sin ella, la sección de métricas carecería de justificación específica.]

Ojeda *et al.* comparan de forma sistemática los enfoques de recalibración disponibles para la estimación de probabilidades de dos clases, evaluando entre otros aspectos su capacidad de generalizar estimaciones precisas a poblaciones externas [23]. Dimitriadis *et al.* abordan la inestabilidad de los diagramas de fiabilidad construidos mediante discretización, y proponen un procedimiento que genera diagramas reproducibles junto con una medida numérica de descalibración [24].

[DECIDIR: Las recomendaciones de Ojeda *et al.* y las de Niculescu-Mizil y Caruana no coinciden de forma inmediata respecto del método de recalibración preferible. La resolución requiere revisar si el escenario evaluado por Ojeda *et al.* —transferencia a poblaciones externas— corresponde al protocolo temporal de este trabajo, en cuyo caso su recomendación tendría precedencia. La decisión debe tomarse antes de la Etapa 2.]

II-B7. Requisitos metodológicos del track: Emmanuel *et al.* revisan los mecanismos de datos faltantes y muestran que la eficacia de un método de imputación depende de las características del conjunto: en su experimento, la superioridad relativa entre procedimientos se invierte según el conjunto evaluado [25]. El resultado relevante no es que una técnica resulte superior, sino que la estrategia depende del mecanismo de ausencia. Una frecuencia elevada de valores ausentes no justifica por sí sola imputarlos de forma automática.

Van den Goorbergh *et al.* estudian modelos de regresión logística bajo ausencia de corrección, submuestreo aleatorio, sobremuestreo aleatorio y generación sintética de la clase minoritaria. Las correcciones no mejoran de forma sistemática el área bajo la curva, y sí producen una sobreestimación pronunciada de la probabilidad de la clase minoritaria, con el consiguiente deterioro de la calibración [26].

[RAZÓN: El alcance de esta última referencia debe respetarse. El trabajo no evalúa la ponderación de clases ni familias distintas de la regresión logística, de modo que no justifica preferir la ponderación como regla general. Presentarlo de otro modo excedería lo que la fuente sostiene.]

II-B8. Justificación técnica del track: El Track A se elige por la fuerza de esa evidencia y no por descarte. El corpus de repeticiones se reduce de forma natural a una tabla de ancho fijo con campos numéricos, binarios y categóricos, que

es el régimen en el que los estudios del dominio de juegos citados muestran una paridad casi total entre modelos clásicos y profundos [8], [9], y en el que la evidencia tabular general favorece a los conjuntos de árboles [18], [20].

La pregunta científica es cuáles características del estado transportan información sobre la victoria, lo que exige modelos cuyas atribuciones puedan inspeccionarse. Y el riesgo dominante es de protocolo y no de capacidad: la contaminación medida de una partición a nivel de fila hace que sea el diseño de la partición, y no la arquitectura, la variable que determina si un resultado tiene significado.

Un modelo secuencial profundo sobre la trayectoria, la alternativa natural del Track B, respondería una pregunta distinta y más amplia, heredando todos los riesgos de fuga y ninguna de las ventajas de interpretabilidad. El aprendizaje por refuerzo, lectura natural de un corpus de episodios, se descarta porque el objeto de estudio es la función de valor de forma aislada, aprendida *offline* a partir de desenlaces registrados, y no una política.

II-C. Eje C: el conjunto de datos y sus análogos

II-C1. Ausencia de literatura previa sobre este corpus:

No localizamos ninguna publicación arbitrada que utilice los episodios del PTCG AI Battle Challenge [12]. El corpus se publicó en 2026 y está ligado a una competencia todavía en curso. De acuerdo con el enunciado del curso, el eje se cubre por tanto con conjuntos de datos análogos del mismo dominio, y la sustitución se argumenta en lugar de darse por supuesta.

[RAZÓN: La ausencia debe declararse de forma explícita en este apartado y recogerse después como brecha. Declararla convierte una carencia en un hallazgo de la revisión.]

II-C2. Por qué los análogos son comparables, y dónde no lo son: SC2EGSet es el análogo estructural más cercano: un corpus de repeticiones competitivas de un juego de dos jugadores, procesado en registros de estado por partida, publicado junto con sus herramientas de extracción y acompañado de experimentos de predicción de victoria sobre características tabulares [9]. Comparte la forma de la tubería —repetición cruda, estado analizado, características tabulares, etiqueta supervisada de desenlace— y el hecho de que los datos fueron producidos por competencia y no por experimento. Difiere en género, en tanto *StarCraft II* es un juego de estrategia en tiempo real y no un juego de cartas por turnos con recursos discretos, y difiere en unidad de observación, puesto que sus modelos consumen agregados por partida y no estados instantáneos.

El conjunto de la competencia de *Hearthstone* es el análogo más cercano en género: un juego de cartas coleccionables con mazos, mano, tablero e información oculta, cuya tarea es precisamente la predicción del ganador a partir de un estado intermedio [8]. Difiere en la calidad de los agentes que lo generaron y en que sus estados fueron publicados por los organizadores en formato tabular en lugar de ser analizados por quien modela.

El corpus de selección de cartas de *Magic: The Gathering* es análogo solo en el sentido estrecho que importa para una de nuestras decisiones: es un juego de cartas coleccionables

cuyo contenido cambia con el tiempo y cuya evaluación reserva contenido no visto [2]. Su tarea es predecir una elección humana de carta, no un desenlace de partida, y no debe leerse como un resultado de predicción de victoria.

II-C3. Problemas documentados de los corpus comparables: Los problemas que estos autores declaran son los problemas que deberíamos esperar.

Białecki *et al.* afirman que su corpus contiene únicamente repeticiones de nivel de torneo y que, en consecuencia, no admite análisis entre niveles de habilidad; que los cambios del juego a lo largo del tiempo hacen que algunos campos tomen valor cero, de modo que la representación cambió con el tiempo; que la completitud dependió de qué organizadores decidieron publicar; y que deliberadamente no filtraron repeticiones terminadas de forma prematura, con el fin de preservar las distribuciones originales [9].

Cada uno de esos puntos tiene su contraparte medida en nuestro corpus: los episodios se seleccionan por puntuación media de los agentes y se truncan a un tope diario de volumen; seis versiones del motor coexisten en la muestra auditada, de la 1.30.1 a la 1.32.4; y los episodios abandonados están presentes y son identificables.

Janusz *et al.* documentan dos problemas propios. Sus estados provenían de partidas entre agentes que elegían sus decisiones al azar, lo que constituye una población específica y no representativa; y se detectó una fuga de datos involuntaria durante las primeras semanas de la competencia, que obligó a los organizadores a mover 1 250 000 casos del conjunto de prueba al de entrenamiento [8].

[RAZÓN: Vale la pena enunciar lo segundo con claridad: un incidente de fuga dentro de una competencia organizada profesionalmente sobre exactamente esta tarea es la evidencia más fuerte disponible de que el riesgo es real y no hipotético.]

II-C4. Cambio de distribución y qué se degrada primero: La respuesta parcial de Janusz *et al.* al problema de la población es también el resultado de generalización más útil del que disponemos. Habiendo entrenado sobre estados de juego aleatorio, construyeron un segundo corpus de 28 604 partidas y 814 407 estados generados por agentes fuertes de búsqueda en árbol Monte Carlo, y observaron que el área bajo la curva total caía solo de aproximadamente 0.79 a aproximadamente 0.75 al evaluar sobre esa población desplazada [8]. Un cambio en la calidad de los agentes cuesta, por tanto, algo, pero mucho menos de lo que podría temerse.

Lo que ese experimento no mide es la calibración, y la evidencia sistemática indica que esa es la magnitud en mayor riesgo. Guo *et al.* examinaron 4 457 referencias y retuvieron quince estudios que cuantificaban el cambio temporal e implementaban alguna mitigación. Los once estudios que evaluaron calibración reportaron deterioro de la calibración, mientras que solo tres de los doce que evaluaron discriminación reportaron deterioro de la discriminación [16]. Su inventario de mitigaciones está dominado por el reajuste del modelo, la calibración de probabilidades, la actualización del modelo y la selección de modelo, frente a solo dos enfoques a nivel de características, y su síntesis es que todas esas

estrategias preservaron la calibración pero ninguna preservó uniformemente la discriminación.

Aportan además el vocabulario que este trabajo necesita, distinguiendo el cambio de covariables — $P_{\text{ent}}(x) \neq P_{\text{prueba}}(x)$ con $P_{\text{ent}}(y|x) = P_{\text{prueba}}(y|x)$ — del cambio de concepto — $P_{\text{ent}}(y|x) \neq P_{\text{prueba}}(y|x)$ con $P_{\text{ent}}(x) = P_{\text{prueba}}(x)$ —, y señalando que ambos pueden coexistir.

[RAZÓN: Brecha de dominio, declarada de forma explícita: se trata de predicción clínica, citada por la asimetría que mide y por la terminología que estandariza, no como hallazgo del dominio de juegos. Sus propias limitaciones declaradas —barrido incompleto de actas de congresos y ausencia de tratamiento del cambio geográfico— no afectan a ninguno de los dos usos.]

II-D. Análisis comparativo

De la Tabla I emergen cuatro patrones.

Una división de métricas que bloquea la comparación directa. Los estudios sobre estados de juego reportan escalares distintos —área bajo la curva en unos casos, exactitud en otros— y ninguno reporta una regla de puntuación propia ni una curva de fiabilidad, con la excepción de Xenopoulos *et al.*, que sí incorporan una medida de error de calibración [6]. Cualquier afirmación de que uno de estos sistemas está mejor calibrado que otro carecería de respaldo, porque la mayoría no lo midió. **La generalización se mide contra cosas diferentes.** Calidad de los agentes [8], conjuntos de cartas no vistos [2], identidad del participante [13], tiempo calendario [16], versiones del juego [10], composiciones de equipo [11], nivel de habilidad [6]. Y las degradaciones reportadas son en todos los casos lo bastante grandes como para importar: 0.79 a 0.75 de área bajo la curva, 67.20 % a 55.44 % de acierto, 0.91 a 0.66 de acierto. Una única cifra dentro de la distribución es la magnitud menos informativa que reporta cualquiera de estos trabajos. Un único holdout aleatorio sería, por tanto, insuficiente para sostener una conclusión firme de generalización.

La unidad de observación es menor que la unidad independiente, y los trabajos difieren en si actúan en consecuencia. Janusz *et al.* separan entrenamiento y prueba a nivel de partidas completas, de modo que su protocolo está agrupado aunque no lo formulen así. Karbalaie *et al.* convierten la agrupación en el objeto de estudio. Bialecki *et al.* reportan validación cruzada de cinco pliegues sobre 22 230 muestras promediadas derivadas de 11 115 partidas únicas —dos filas por partida, una por jugador— sin describir restricción alguna de agrupación a nivel de partida.

[RAZÓN: Lo siguiente es una inferencia nuestra y no una afirmación de los autores: si esos pliegues se extrajeron a nivel de fila, ambas filas de una partida podrían caer a lados opuestos de una partición, y sus aciertos reportados serían optimistas en una cantidad desconocida. Se señala como salvedad de comparabilidad y no como error, puesto que el artículo no declara el particionador que utilizó.]

El resultado depende de una población acotada. Los estudios sobre juegos de arena multijugador revisados se restringen a jugadores de nivel elevado o profesional; el trabajo sobre el videojuego competitivo de Pokémon opera con un entorno

y un formato distintos de los del juego de cartas; y los dos corpus de repeticiones declaran esa limitación para sí mismos. Ello obliga a declarar los límites de extrapolación y a evitar presentar un resultado obtenido sobre agentes artificiales como evidencia acerca de jugadores humanos.

II-E. Brechas identificadas

Carencias encontradas en la literatura.

1. **Ningún trabajo arbitrado utiliza este corpus.** Los episodios del PTCG AI Battle Challenge no tienen descripción publicada, ni diccionario de datos documentado, ni resultado de referencia reportado [12].
2. **La tarea no se ha estudiado en el Pokémon TCG.** La predicción de victoria desde el estado está establecida en *Hearthstone* [8] y en *StarCraft II* [9], pero no en un juego cuya estructura de recursos se apoya en cartas de premio, asignación de energía, banca y evolución.
3. **Se reporta discriminación sin calibración.** La literatura de predicción de desenlace revisada reporta predominantemente métricas de ordenamiento o exactitud [4], [5], [8], [9], con la excepción de Xenopoulos *et al.*, que incorporan una medida de error de calibración [6]. Karbalaie *et al.* colocan explícitamente la calibración fuera de su alcance y la recomiendan como trabajo futuro [13], y Guo *et al.* muestran que es la magnitud que se degrada primero [16]. Un modelo pensado como evaluador de posiciones está siendo validado, por tanto, sobre la propiedad equivocada en la mayoría de los casos.
4. **Evaluación de métricas probabilísticas pendiente en la comparación de modelos tabulares.** Grinsztajn *et al.* identifican explícitamente esta línea como no cubierta por su comparación [18].
5. **La evaluación agrupada se aplica de forma inconsistente en corpus de estados de juego.** El costo medido de ignorar la dependencia solo está disponible desde otros campos [13], [14], [21]; dentro de los conjuntos de datos de juegos la restricción unas veces se satisface sin ser nombrada [8] y otras queda sin describir [9].
6. **La generalización rara vez se evalúa bajo un cambio declarado, y nunca bajo los tres a la vez.** Cuando se hace, la degradación es sustancial [2], [8], y la evidencia sistemática encuentra solo quince estudios que a la vez cuantifiquen el cambio temporal y actúen sobre él [16]. No existe un protocolo único que combine partida nueva, composición no vista y periodo posterior para esta tarea.

[RAZÓN: La brecha tercera no puede formularse como ausencia absoluta. Al menos un trabajo de la propia bibliografía reporta calibración, de modo que afirmar que ningún trabajo lo hace sería contradicho por una referencia citada en este mismo documento.]

Brechas que este trabajo aborda. Las brechas 2, 3, 5 y 6. La segunda, planteando la tarea en el Pokémon TCG por primera vez y reportando el perfil por turno de la capacidad predictiva. La tercera, reportando pérdida logarítmica, puntaje de Brier y curvas de fiabilidad junto al área bajo la curva, y poniendo a prueba la hipótesis H3 de forma explícita. La quinta, agrupando por identificador de episodio toda partición, todo intervalo de

Tabla I

RESUMEN COMPARATIVO DE TRABAJOS RELACIONADOS. LOS VALORES ESTÁN TRANSCRITOS DE LA FUENTE. LOS CONJUNTOS DE DATOS DIFIEREN EN TAMAÑO, COMPOSICIÓN, JUEGO Y VERSIÓN, POR LO QUE LA COMPARACIÓN DIRECTA REQUIERE CAUTELA.

Referencia	Año	Técnica	Conjunto de datos / entorno	Métrica principal	Resultado reportado	Limitación identificada
Janusz et al. [8]	2017	Competencia: ensambles de redes convolucionales, potenciación del gradiente y regresión logística; referencia de los organizadores con red de dos capas ocultas	<i>Hearthstone</i> : 3.25 M de estados de entrenamiento de $\approx 65\,000$ partidas; 750 000 estados de prueba de $> 180\,000$ partidas; 9 mazos en entrenamiento frente a 27 en prueba	AUC	0.7846 la referencia; 0.8019 la mejor solución; brecha $< 2\%$. Transferencia a estados de agentes de búsqueda: ≈ 0.79 a ≈ 0.75	Estados generados por agentes que eligen acciones al azar, población no representativa; no se reporta calibración; fuga involuntaria a mitad de competencia que obligó a mover 1.25 M de casos de prueba a entrenamiento
Hodge et al. [5]	2021	Regresión logística, bosques aleatorios y potenciación del gradiente	DotA 2: 5 744 repeticiones mixtas y 186 profesionales	Exactitud	[?]	Los conjuntos de la literatura no son comparables entre sí; el flujo en vivo provee un subconjunto de las características de las repeticiones
Guo et al. [16]	2021	Revisión sistemática PRISMA de estrategias de mitigación del cambio temporal	15 estudios de predicción clínica retenidos de 4 457 referencias examinadas; regresión logística en 13 de 15	Cambio en calibración y en discriminación	Deterioro de calibración en 11 de los 11 estudios que la midieron; deterioro de discriminación en solo 3 de 12	Dominio clínico, citado por la asimetría medida y por la terminología del cambio de distribución; sin metaanálisis; cobertura incompleta de actas de congresos
Tian et al. [4]	2022	Red recurrente con características de alineación y combate	Honor of Kings: 27 256 partidas, 496 342 marcos	Exactitud	81.8 % en el nodo de 7 min (Tabla III); el resumen reporta 84.7 %	Datos de un solo día y jugadores de nivel elevado; partición descrita a nivel de marcos sin agrupación explícita por partida; no evalúa calibración
Miernik y Kowalski [7]	2022	Evolución de funciones de evaluación lineales y basadas en árboles	Legends of Code and Magic	Tasa de victoria	60.2 % promedio global para la variante Tree-from-Linear	No estima probabilidades de forma supervisada; posible especialización respecto del oponente usado para evaluar
Xenopoulos et al. [6]	2022	Máquinas de potenciación explicables (modelo aditivo generalizado)	CSGO: tres entornos de habilidad	Pérdida logarítmica y error de calibración esperado	[?]	Un solo juego; el modelo interpretable podría ser superado; no es posible identificar a los jugadores que incurren en trampa
Białecki et al. [9]	2023	Regresión logística, máquina de vectores de soporte y potenciación del gradiente con hiperparámetros próximos a los predeterminados; validación cruzada de 5 pliegues	SC2EGSet: 55 paquetes de repeticiones de torneos de StarCraft II; 11 115 partidas únicas reducidas a 22 230 muestras promediadas; 17 características económicas	Exactitud	0.9071 con dos jugadores; 0.8924 y 0.8916 los otros dos modelos; 0.8488 con un solo jugador	Solo jugadores de nivel de torneo, sin análisis entre niveles de habilidad; los autores llaman a sus experimentos más ilustrativos que investigativos; campos puestos a cero conforme el juego cambió; no se describe agrupación por partida para los pliegues

confianza y todo pliegue de validación cruzada, y reportando la contaminación medida que produciría la alternativa ingenua. La sexta, evaluando bajo tres cambios declarados —episodios no vistos, mazos no vistos y periodos posteriores— y reportando cada uno por separado en lugar de promediarlos.

Brechas que quedan fuera del alcance. La primera se documenta pero no se cierra: un proyecto de un semestre no puede establecer una referencia arbitrada para el corpus, y este trabajo no pretende serlo. La cuarta excede el alcance, dado que este no es un estudio comparativo de familias de modelos sobre múltiples conjuntos de datos. La comparabilidad estricta con el antecedente de *Hearthstone* queda igualmente fuera de alcance por las razones enumeradas en la Sección III: las diferencias

son estructurales y no pueden eliminarse reejecutando ninguno de los dos experimentos. Más allá de estas, no se persigue construir un agente competitivo, aprender una política, separar la deriva del conjunto de estrategias dominante del cambio de versión del motor —la muestra auditada confunde ambas causas—, ni generalizar ningún hallazgo a jugadores humanos.

[RAZÓN: Reconocer explícitamente las brechas que el trabajo no aborda es un requisito del enunciado y no una debilidad. Un apartado que declarara abordarlas todas resultaría menos creíble que uno que delimita su alcance.]

Tabla I
RESUMEN COMPARATIVO DE TRABAJOS RELACIONADOS (CONTINUACIÓN).

Referencia	Año	Técnica	Conjunto de datos / entorno	Métrica principal	Resultado reportado	Limitación identificada
Chitayat et al. [10]	2023	Representación agrupada de personajes con K-Means y redes neuronales	DotA 2: versiones 7.27–7.33, 61 254 partidas	AUC	0.85 en versiones conocidas; 0.85 y 0.86 en dos versiones posteriores	Solo partidas profesionales; predice conteos finales a partir de duración y composición, no probabilidad desde un estado intermedio
Bertram et al. [2]	2024	Redes siamesas bajo ordenamiento contextual, sobre representaciones generalizadas de carta (atributos, metadatos, imágenes)	Selección de cartas de Magic: The Gathering; ≈ 100 M de elecciones en 14 conjuntos; un conjunto completo reservado	Acierto <i>top-1</i>	67.20 % sobre conjuntos vistos frente a 55.44 % sobre el no visto; la codificación por identidad queda indefinida sobre cartas no vistas	La tarea es predecir una elección humana y no un desenlace de partida, por lo que solo es análogo en generalización de contenido; las elecciones humanas no son consistentes, lo que acota el acierto alcanzable
Saravanan y Guzdial [19]	2024	Agente de refuerzo y agente heurístico, con constructor de equipos	Pokémon Showdown: cuatro escenarios de prohibición	Solapamiento, distancia de edición y correlación de rangos	[?]	La correlación de rangos resulta débil y no significativa: el conjunto descubierto difiere del real pese al solapamiento
Kamal et al. [3]	2025	Revisión sistemática con metodología PRISMA	35 estudios sobre deportes electrónicos de arena multijugador	Métricas heterogéneas	Sin resultado único; se reportan, entre otros, AUC de 0.97 y exactitud cercana al 93 %	Alta heterogeneidad entre tareas, conjuntos y protocolos; generalización limitada entre regiones, periodos y poblaciones
Karbalaie et al. [13]	2026	Diez clasificadores bajo cuatro diseños de validación: estratificada de 10 pliegues, dejando un participante fuera, agrupada de 3 pliegues y anidada	623 ensayos de salto de 72 participantes; 624 características reducidas a un conjunto fijo de 10	Exactitud y brecha entrenamiento–prueba	0.91 bajo estratificada de 10 pliegues frente a 0.66 dejando un participante fuera; los modelos lineales difieren ≤ 0.03 ; la anidada coincide con dejar uno fuera dentro de 0.02	Dominio de biomecánica, citado por su argumento estadístico y no como resultado del dominio de juegos; una única tarea binaria sobre 72 participantes; calibración explícitamente fuera de alcance
Angliss et al. [11]	2026	Clonación de comportamiento y aprendizaje por refuerzo multiagente	Pokémon VGC: más de 700 000 registros de partida humanos; 72 composiciones fuera de distribución	Tasa de victoria y evaluación cruzada	0.669 del agente entrenado con 64 composiciones frente al entrenado con una, sobre las composiciones no vistas	El desempeño disminuye al crecer la diversidad; la evaluación humana es anecdótica; no es una tarea de estimación de probabilidad

Nota. Las referencias de carácter puramente metodológico incluidas en la revisión —formalización de la fuga de datos, catálogos de escenarios de fuga, revisiones de calibración y de modelos tabulares— no figuran en esta tabla, dado que no resuelven una tarea de predicción sobre un conjunto de datos comparable. Sus aportes se discuten en el texto de la Sección II-B.

III. BASELINE DE LITERATURA

III-A. Ausencia de resultado publicado sobre este corpus

No existe resultado publicado sobre el corpus objetivo, de modo que el punto de referencia se toma del trabajo análogo cuya tarea, unidad de observación y métrica son las más cercanas a las nuestras.

[RAZÓN: Esta declaración debe abrir la sección y no ocultarse. El enunciado prevé explícitamente la sustitución cuando el conjunto carece de literatura previa, de modo que declararla constituye cumplir el requisito y no eludirlo. La ausencia se recoge además como brecha en la Sección II-E.]

III-B. Origen y protocolo del punto de referencia

Objetivo de referencia: área bajo la curva ROC en la banda 0.78–0.80, proveniente del AAIA’17 Data Mining Challenge sobre *Hearthstone* [8].

Tarea: predecir el ganador a partir de un único estado de juego. **Unidad de observación:** un estado de juego. **Métrica:** área bajo la curva ROC.

Resultado oficial de referencia: 0.7846, obtenido por una red totalmente conectada con dos capas ocultas sobre la representación tabular, que quedó en el puesto 94. **Mejor solución enviada:** 0.8019, un ensamble construido sobre redes convolucionales.

Protocolo: 3 250 000 estados de entrenamiento provenientes de aproximadamente 65 000 partidas frente a 750 000 estados de prueba provenientes de más de 180 000 partidas distintas, con 9 mazos en entrenamiento y 27 en prueba, de modo que el conjunto de prueba contiene cartas nunca vistas en entrenamiento; puntuaciones preliminares sobre un 5 % aleatorio fijo del conjunto de prueba y puntuaciones finales sobre

el resto.

III-C. *Qué pretende hacer este trabajo con esa cifra*

El objetivo operativo es que el modelo clásico más fuerte alcance esa banda de 0.78–0.80 bajo nuestro propio protocolo primario en la ventana tardía de la partida, y establecer en qué punto de la partida se alcanza por primera vez esa banda.

No se afirma que superaremos 0.8019, porque las dos cifras no están medidas sobre el mismo objeto. Este trabajo declara el rango como referencia de orden de magnitud y no como umbral obligatorio.

[RAZÓN: Declarar el número como cifra a batir cuando procede de otro juego constituiría una comparación no legítima. Declararlo como orden de magnitud cumple el requisito de la sección y respeta a la vez el criterio de comparabilidad.]

III-D. *Comparabilidad del protocolo*

La comparación se considera **parcialmente comparable**. Coinciden la naturaleza binaria del desenlace, el uso de información intra-partida y la evaluación mediante área bajo la curva. No coinciden el juego, las reglas, la representación del estado ni la población que genera las partidas.

Diferencias que impiden una comparación justa.

- **Juego distinto.** *Hearthstone* y el *Pokémon TCG* difieren en sistemas de recursos, condiciones de victoria y estructura de tablero, de modo que el contenido informativo de un estado no es la misma magnitud.
- **Población de agentes distinta.** Sus estados provienen de agentes que actúan al azar; los nuestros, de agentes que compiten y son seleccionados por puntuación. Su propio experimento de transferencia muestra que esto importa, y cuesta aproximadamente 0.04 de área bajo la curva en la dirección de agentes aleatorios a agentes fuertes [8].
- **Partición distinta.** Su separación es por partida y por mazo entre dos conjuntos fijos; la nuestra es una partición agrupada por episodio, con protocolos adicionales temporal y de reserva de mazos.
- **Prevalencia de clases distinta.** Su conjunto de entrenamiento tiene 50.46 % de victorias y el de prueba 57.27 %, de modo que las dos mitades de su propio banco de pruebas no provienen de la misma distribución [8].
- **Descripción del estado distinta.** Su representación tabular fue suministrada por los organizadores, y las mejores participaciones reconstruyeron características a partir del JSON crudo; nuestro conjunto de características lo construimos nosotros y está restringido por una lista negra de fuga.
- **Conjunto de métricas distinto.** Aunque ambos reportan área bajo la curva, este trabajo añade pérdida logarítmica, puntaje de Brier y curvas de fiabilidad, de modo que la evaluación no se reduce a la misma métrica.

[RAZÓN: Esta enumeración es la exigencia central del criterio de baseline. Hodge et al. ofrecen el precedente: publican una tabla comparativa de dieciséis trabajos y advierten en nota al pie que la variación en tamaño, composición y versión del juego obliga a tratar con cautela la comparación de las exactitudes reportadas [5].]

Interpretación del número. El intervalo de 0.7846 a 0.8019 se emplea como referencia externa del nivel de discriminación alcanzado en una tarea análoga. No constituye una cifra que este proyecto deba superar para considerarse válido: un resultado inferior puede ser metodológicamente sólido si se obtiene bajo un protocolo más estricto, y uno superior no probaría de forma automática un mejor desempeño, dadas las diferencias enumeradas.

III-E. *Anclajes secundarios de orden de magnitud*

Se dispone de un segundo anclaje, más débil. SC2EGSet reporta 0.9071 de acierto en predicción de victoria con dos jugadores y 0.8488 con un solo jugador [9]. Se registra aquí por completitud y no se adopta como objetivo: la métrica es acierto y no área bajo la curva, la unidad es una partida completa y no un instante, las características son promedios sobre la partida, y la cuestión de la agrupación planteada en la Sección II-D queda sin resolver.

Hodge et al. reportan exactitudes sobre datos mixtos y profesionales de un videojuego de arena multijugador, evaluando en el punto medio de la partida [5]. Xenopoulos et al. reportan valores de pérdida logarítmica y de error de calibración esperado para modelos evaluados dentro y fuera de su entorno de entrenamiento [6].

[POR COMPLETAR: Consignar los valores exactos de la Tabla III de Hodge et al. y de la Tabla 1 de Xenopoulos et al. tras verificación directa en el artículo.]

[RAZÓN: Estas referencias se incluyen con su métrica original y sin convertirla. Traducir una exactitud a un área bajo la curva, o una pérdida logarítmica a una exactitud, produciría cifras que ninguno de los artículos reporta.]

[DECIDIR: Queda pendiente definir si el trabajo declara además un umbral propio de éxito, independiente de la literatura, formulado sobre los modelos de referencia internos descritos en la Sección IV-E. Un umbral de esa naturaleza sería comparable de forma legítima, a diferencia del número de literatura. La decisión afecta la redacción de la discusión final y conviene tomarla antes de la Etapa 2.]

IV. METODOLOGÍA PROPUESTA

Esta sección describe lo que se propone hacer. No se ha entrenado ningún modelo y ningún valor aquí reportado es empírico; las únicas magnitudes medidas que aparecen son propiedades del corpus, establecidas por la auditoría que se describe en la Sección V.

[RAZÓN: Esta advertencia debe abrir la sección. Sin ella, las cifras de auditoría intercaladas en el texto podrían leerse como resultados de modelo.]

IV-A. *Formalización del problema*

Sea $\mathcal{E}$ el conjunto de episodios, cada uno una partida completa entre dos agentes. Un episodio $e \in \mathcal{E}$ produce una secuencia ordenada de estados; de ella se retiene la subsecuencia de estados *frescos* del asiento que actúa, indexada por t . Cada estado retenido produce una observación

$$(x_i, y_i, g_i, \tau_i, d_i),$$

donde $x_i \in \mathcal{X} \subseteq \mathbb{R}^p$ es el vector de características construido a partir de la observación disponible para el asiento activo en ese instante, $y_i \in \{0, 1\}$ indica si el jugador desde cuya perspectiva se construyó la fila venció en el episodio, $g_i \in \mathcal{E}$ es el identificador del episodio, $\tau_i \in \mathbb{N}$ es el índice de turno y d_i la fecha de calendario.

Los tres últimos campos se arrastran para agrupación, estratificación y análisis; por construcción, nunca son componentes de x_i .

La tarea es clasificación binaria probabilística: aprender $f : \mathcal{X} \rightarrow [0, 1]$ tal que

$$f(x) \approx \Pr(Y = 1 \mid X = x), \quad (1)$$

donde la probabilidad se toma sobre la aleatoriedad del juego posterior al instante observado: el orden restante del mazo, la información oculta del oponente y las decisiones futuras de ambos agentes.

[RAZÓN: La ecuación debe explicitar sobre qué se toma la probabilidad. Es lo que distingue este problema de uno determinista, y constituye la respuesta al criterio de exclusión que Grinsztajn et al. aplican a los conjuntos de juegos en los cuales el objetivo se deduce de los datos [18].]

Puesto que la salida es una probabilidad y no una etiqueta, el objetivo de entrenamiento es una regla de puntuación propia: la log-verosimilitud negativa regularizada,

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \left\{ -\frac{1}{N} \sum_{i=1}^N [y_i \log f(x_i) + (1 - y_i) \log (1 - f(x_i))] + \lambda \Omega(f) \right\}, \quad (2)$$

con Ω la penalización de complejidad de la familia $\mathcal{F}$ y λ seleccionado sobre datos de validación.

[RAZÓN: Minimizar una regla de puntuación propia en lugar de una pérdida de clasificación es una elección deliberada y debe declararse como tal: es el objetivo cuyo óptimo es la probabilidad condicional verdadera, y la calibración es una de las propiedades que este trabajo se propone medir.]

IV-A1. Restricciones que completan la formulación: La primera es la condición de legitimidad de Kaufman et al.: todo componente de x_i debe ser observable para el propósito de inferir y_i , evaluado instancia por instancia, y en particular no puede depender de información generada después del turno τ_i [15].

La segunda es una restricción de partición. Para cualesquiera dos partes A y B de una división,

$$\{g_i : i \in A\} \cap \{g_i : i \in B\} = \emptyset, \quad (3)$$

de modo que ningún episodio aporte filas a más de una parte.

La restricción (3) es el enunciado formal del argumento del tamaño muestral efectivo de Karbalaie et al.: la unidad independiente es el episodio, no la fila [13].

IV-A2. Definición del objetivo: La etiqueta se deriva del campo de recompensas a nivel de episodio, que resuelve el 99.86 % de los episodios auditados: 27 135 con recompensa (1, -1), 24 844 con (-1, 1), 33 empates y 73 desenlaces anómalos.

Los empates se excluyen del objetivo binario; su volumen no puede sostener una tercera clase. Los desenlaces anómalos —por agotamiento de tiempo, error o estado inválido— tienen ganador identificable, pero el final no procede de la dinámica del juego, de modo que se excluyen del entrenamiento principal y se reservan para análisis de sensibilidad.

[RAZÓN: Los criterios de exclusión deben declararse en la formalización y no en el análisis de datos. Excluir observaciones sin regla previamente establecida constituye una decisión posterior a los datos.]

IV-A3. Unidad de observación y unidad independiente:

- **Unidad de observación.** Un estado fresco del asiento activo, proyectado a una perspectiva común propio/oponente. La observación del asiento inactivo no se duplica como fila adicional.
- **Unidad estadísticamente independiente.** El episodio. El desenlace se sortea una única vez por episodio, y todas sus observaciones comparten ese sorteo.

Los 52 085 episodios auditados generan 7 038 378 observaciones útiles, aproximadamente 135 filas por unidad independiente.

[RAZÓN: Toda mención del tamaño del corpus en este documento debe expresar ambas cifras. Reportar únicamente el conteo de filas transmitiría una noción inexacta de la cantidad de evidencia disponible, precisamente el error que Brill et al. identifican [1].]

IV-B. Alcance del uso de las observaciones

Se conserva la totalidad de las observaciones por episodio, sin submuestreo. Brill et al. reportan que retener todas las observaciones de una unidad resulta preferible a conservar una sola, dado que el conjunto completo aporta información sobre la estructura del espacio de covariables, pese a la dependencia entre las etiquetas [1].

[RAZÓN: Esta decisión debe justificarse de forma explícita porque la alternativa —retener un estado por episodio para obtener observaciones independientes— resulta intuitivamente atractiva y es peor. Sin la cita, parecería una omisión en lugar de una elección informada.]

IV-C. Tubería propuesta

El procedimiento ingiere las repeticiones en formato JSON, valida la firma de esquema y su versión declarada, selecciona los estados frescos del asiento activo, y proyecta cada fila a la perspectiva del jugador activo. A continuación aplica el filtro de lista negra, construye las características por familia, y materializa la tabla. La partición agrupada precede al ajuste de toda transformación.

Dos decisiones de diseño merecen justificación.

Normalización de la perspectiva. Cada fila se proyecta a propio frente a oponente usando el índice de asiento, de modo que el modelo aprenda relaciones entre magnitudes y no la identidad de un asiento. La auditoría encontró que asiento y orden de turno están casi perfectamente confundidos en los días tardíos, lo que de otro modo convertiría la identidad del asiento en un atajo atractivo.

Ajuste del preprocesamiento dentro del pliegue. Los parámetros de escalado, codificación de variables categóricas, cualquier




Figura 1. Tubería propuesta, de la repetición cruda al modelo evaluado. Las etapas 1 a 5 se ejecutan una sola vez. El filtro de lista negra y la partición agrupada se imponen mediante pruebas automatizadas y no por convención. En la etapa final del proyecto, el mismo extractor alimenta al agente inteligente con la probabilidad estimada.

imputación y cualquier ponderación de clases se estiman dentro del pliegue de entrenamiento y después se aplican a los datos reservados. Sasse *et al.* clasifican la alternativa —estimarlos sobre el conjunto completo antes de particionar— como fuga de prueba a entrenamiento, aunque el modelo en sí se ajuste después de la partición [21].

Xenopoulos *et al.* y Hodge *et al.* describen procedimientos análogos, en los cuales las repeticiones se procesan mediante un analizador sintáctico que produce estados a intervalos regulares, y dichos estados constituyen la entrada de los modelos [5], [6].

[RAZÓN: Citar ambos precedentes evita que el procedimiento parezca una construcción improvisada. La estructura repetición-analizador-tabla es la práctica establecida del dominio.]

IV-D. Protocolo experimental

IV-D1. Partición agrupada por episodio: El protocolo primario es una partición 70/15/15 agrupada por episodio, que satisface (3).

La alternativa —una partición aleatoria sobre filas— se rechaza sobre bases medidas y no de principio: en la muestra auditada, una partición aleatoria 70/30 de instantáneas colocaría el 99.9945 % de los episodios a ambos lados simultáneamente. El protocolo ingenuo contaminaría, por tanto, esencialmente todo el corpus.

Tres evidencias convergen sobre esta decisión. Brill *et al.* muestran que la dependencia entre observaciones que comparten desenlace incrementa el sesgo y la varianza del estimador [1]. Karbalaie *et al.* cuantifican la inflación resultante: 0.91 de acierto bajo validación estratificada frente a 0.66 bajo validación agrupada sobre los mismos datos [13]. Figueiredo

Tabla II
PROTOCOLOS DE EVALUACIÓN Y PREGUNTA QUE RESPONDE CADA UNO.

Protocolo	Criterio de partición	Pregunta que responde
A	Episodios disjuntos, asignación aleatoria	¿Generaliza a partidas no observadas?
B	Episodios disjuntos, corte cronológico por día	¿Se conserva el desempeño sobre periodos posteriores?
C	Episodios disjuntos, composiciones disjuntas	¿Aprendió a leer el estado o memorizó qué composiciones vencen?

y Mendes reportan el mismo fenómeno sobre conjuntos con alta correlación espaciotemporal [14].

[RAZÓN: Se citan las tres referencias y no una, porque miden cosas distintas: la primera sobre las propiedades del estimador; la segunda sobre la magnitud de la inflación bajo agrupación por sujeto; la tercera sobre la cifra publicada. Presentar solo una dejaría el argumento a medias.]

Una ventaja de este corpus respecto de los escenarios estudiados por Figueiredo y Mendes es que la agrupación no requiere inferencia: el identificador de episodio la determina de forma exacta. En su trabajo, la contribución central consiste precisamente en un procedimiento para inferir agrupaciones que no vienen dadas [14].

IV-D2. Tres protocolos de generalización: Protocolo B. La partición cronológica asigna al entrenamiento los días 2026-06-17, 06-18, 06-23 y 06-29; a la validación los días 07-05 y 07-11; y a la prueba los días 07-25 y 08-04. El día 06-16 se mantiene fuera por corresponder a un arranque parcial, y el 07-17 se reserva por su concentración extrema de composiciones y agentes, sujeto a revisión posterior al análisis exploratorio.

Este protocolo implementa la separación aprender–predecir que Kaufman *et al.* describen como predicción sobre el futuro [15]. Hodge *et al.* adoptan una partición ordenada cronológicamente con el fin de no emplear datos posteriores para predecir eventos anteriores [5], y Saravanan y Guzdial documentan que el conjunto de estrategias dominante cambia de forma continua [19].

Protocolo C. Aparta composiciones de mazo, o pares de composiciones enfrentadas, de forma completa para el conjunto de prueba. Es el diseño que Bertram *et al.* emplean para separar la memorización de contenido conocido de la comprensión del contenido [2], y coincide con la evaluación sobre composiciones no vistas de Angliss *et al.* [11].

Los tres protocolos responden preguntas distintas y se reportan por separado, nunca promediados.

[POR COMPLETAR: El criterio exacto de separación por composición depende del análisis de concentración presentado en la Sección V-H.]

IV-D3. Estrategia de validación: Los hiperparámetros se seleccionan mediante validación cruzada agrupada de k pliegues sobre la partición de entrenamiento, tomando el episodio como clave de agrupación. La partición de prueba se toca una sola vez, al final.

Karbalaie *et al.* reportan que la validación cruzada agrupada de k pliegues coincide con el diseño de dejar un grupo fuera —mucho más costoso— dentro de 0.02 de acierto y a un costo un orden de magnitud menor, lo que resulta decisivo cuando la unidad de agrupación se cuenta en decenas de miles [13].

Se prefiere un diseño plenamente anidado allá donde el presupuesto computacional lo permita, puesto que tanto Karbalaie *et al.* como Sasse *et al.* identifican el sesgo de selección como una fuga residual cuando los mismos pliegues sirven para ajustar y para evaluar [13], [21].

[RAZÓN: El uso de validación cruzada agrupada, y no de su variante por defecto, es una condición necesaria: las implementaciones habituales asumen independencia entre observaciones y anularían el control establecido en la partición.]

IV-D4. Conjunto de calibración: El procedimiento de recalibración descrito en la Sección IV-E requiere un subconjunto no empleado en el ajuste del modelo. Silva Filho *et al.* establecen que la recalibración debe ajustarse sobre datos no vistos durante el entrenamiento [17]. Niculescu-Mizil y Caruana detallan la consecuencia de incumplirlo: si el modelo separa perfectamente el conjunto sobre el cual se calibra, la transformación aprendida degenera [22].

[DECIDIR: El esquema 70/15/15 no contempla un conjunto de calibración. Las alternativas son: una cuarta partición obtenida dividiendo el conjunto de entrenamiento y agrupando por episodio; o emplear el mismo procedimiento de validación cruzada agrupada ya adoptado para hiperparámetros, verificando el orden de operaciones para que la selección no contamine la calibración. La decisión debe tomarse antes de ejecutar cualquier entrenamiento, puesto que modificar las particiones a mitad del proceso invalidaría los resultados previos.]

IV-D5. Métricas y su justificación: Cada métrica se incluye porque responde una pregunta que las demás no pueden responder.

La adopción simultánea se fundamenta en la descomposición que Silva Filho *et al.* exponen: las reglas de puntuación propias se separan en un componente de calibración y uno de refinamiento [17]. Ninguna métrica individual distingue entre las dos formas en que un estimador puede fallar.

El área bajo la curva es la métrica principal por tres razones: el objetivo está cercano al equilibrio a nivel de episodio, de modo que la exactitud sería poco informativa antes que engañosa; la métrica no exige comprometerse con un umbral, y en esta etapa no hay definido ningún costo de decisión; y es la única métrica sobre la que existe una cifra publicada análoga.

La calibración se incluye porque Guo *et al.* la identifican como la propiedad que se degrada primero bajo cambio temporal [16], porque Xenopoulos *et al.* observan el mismo patrón en un juego competitivo [6], y porque Van den Goorbergh *et al.* muestran que ciertas intervenciones pueden dejar el área bajo la curva prácticamente sin variación y simultáneamente distorsionar las probabilidades [26]. Niculescu-Mizil y Caruana señalan en la misma línea que, cuando se requieren probabilidades bien calibradas, ni la exactitud ni el área bajo la curva resultan suficientes [22].

Tabla III
MÉTRICAS DE EVALUACIÓN, COMPONENTE QUE MIDE CADA UNA Y PREGUNTA QUE RESPONDE.

Métrica	Componente	Pregunta, y por qué no basta por sí sola
Área bajo la curva ROC (principal)	Refinamiento	¿Ordena el modelo correctamente dos posiciones? Independiente del umbral, robusta ante desbalance moderado, y es la métrica del único antecedente publicado comparable [8]. No dice nada sobre si la probabilidad es correcta
Pérdida logarítmica	Ambos	¿Es exacta la probabilidad en sí misma? Es el objetivo de entrenamiento (2), de modo que reportarla muestra además si la optimización tuvo éxito
Puntaje de Brier	Ambos	¿Cuál es el error cuadrático de la probabilidad, y cómo se descompone en calibración y refinamiento?
Curva de fiabilidad y error de calibración	Calibración	Entre las posiciones a las que el modelo asigna un 70 %, ¿vence efectivamente el 70 %?
Exactitud, precisión, exhaustividad y F1	—	Se reportan solo una vez fijado y justificado un umbral, para comparabilidad con trabajos que reportan exactitud [9]. Insuficientes por sí solas: un modelo puede acertar la clase y estar sistemáticamente sobreconfiado

Todas las métricas se reportan de forma global y por ventana de turno.

[DECIDIR: Si la distribución de clases de la tabla final resultara marcadamente desbalanceada —magnitud aún no medida, puesto que depende de cuántas instantáneas aporta cada bando— se añadirá el área bajo la curva de precisión-exhaustividad, con la clase minoritaria declarada explícitamente.]

Construcción de las curvas de fiabilidad. Silva Filho *et al.* advierten que los estimadores del error de calibración basados en discretización dependen del número y la construcción de los intervalos empleados [17]. Dimitriadis *et al.* proponen un procedimiento que produce diagramas reproducibles junto con una medida numérica de descalibración [24].

[DECIDIR: Queda por verificar la disponibilidad de una implementación del procedimiento de Dimitriadis *et al.* en el entorno de trabajo. En caso de no estar disponible, se emplea el error de calibración esperado con discretización, declarando la limitación correspondiente.]

IV-D6. Intervalos de confianza: Todo intervalo de confianza se obtiene por remuestreo sobre episodios, nunca sobre filas, por la misma razón que gobierna (3).

Brill *et al.* reportan que el remuestreo que ignora la estructura de agrupamiento alcanza una cobertura marcadamente inferior a la nominal, y que incluso el remuestreo que respeta dicha estructura permanece por debajo del nivel declarado [1].

[RAZÓN: Debe declararse que los intervalos constituyen una cota optimista de la incertidumbre real. Presentarlos como intervalos de cobertura nominal válida contradiría la evidencia de la referencia que fundamenta el método.]

Tabla IV
ESCALERA DE MODELOS DE REFERENCIA.

Nivel	Modelo	Pregunta que responde
B0	Clasificador de probabilidad a priori	¿Cuál es el piso? Lo que quede por debajo es ruido
B1	Heurística de dominio sobre una diferencia de recursos, definida tras el análisis exploratorio	¿Hace falta aprendizaje automático en absoluto?
B2	Regresión logística regularizada	¿Es la relación esencialmente lineal? Aporta coeficientes inspeccionables y probabilidades calibrables
B3	Árbol de decisión y bosques aleatorios	¿Existen interacciones y no linealidades que el modelo lineal pierde?
B4	Potenciación del gradiente	¿Cuánto compra la complejidad, y a qué costo de interpretabilidad?

IV-E. Plan de modelos de referencia

Cada peldaño de la escalera se justifica por lo que el anterior dejó sin explicar.

La inclusión de los niveles B2 a B4 se fundamenta en la evidencia de que los conjuntos de árboles constituyen el estado del arte sobre datos tabulares [18], [20].

Sobre B1. Hodge *et al.* reportan que un modelo construido sobre una única característica alcanza un desempeño cercano al obtenido con el conjunto completo [5]. Un resultado análogo aquí constituiría un hallazgo y no un fracaso.

[RAZÓN: Declarar de antemano que un buen desempeño de la heurística sería un resultado válido evita que, ante ese escenario, se busque justificar la complejidad del modelo con argumentos posteriores a los datos.]

Sobre B2. No se incluye por formalidad. Es el modelo que la evidencia revisada trata como referencia honesta: fue el algoritmo más común en los quince estudios clínicos de cambio temporal [16], quedó a 0.016 de acierto del mejor modelo en SC2EGSet [9], y estuvo entre los menos inflados por un protocolo defectuoso en el banco de pruebas de validación [13].

Sobre B4. La evidencia revisada fija una expectativa baja sobre cuánto añade: la mejor solución de *Hearthstone* superó al resultado de referencia de una red de dos capas por menos de un dos por ciento de área bajo la curva [8].

[DECIDIR: La familia concreta de potenciación del gradiente permanece por fijar. La elección debe considerar el manejo nativo de variables categóricas de alta cardinalidad y el costo de inferencia, dado que el modelo será consumido por un agente en la etapa final.]

Tercera referencia. La banda de 0.78 a 0.80 declarada en la Sección III se arrastra como referencia externa parcialmente comparable, con sus límites declarados [8].

IV-E1. Ablaciones por familia de características: Las ablaciones por familia —progreso, recursos, tablero, energía, estados alterados, diferenciales y contexto de mazo— se

ejecutan bajo el mismo protocolo, de modo que la contribución marginal de cada bloque se mida en lugar de afirmarse.

Una ganancia grande del bloque de contexto de mazo se interpreta como evidencia de memorización del conjunto de estrategias dominante y no de comprensión, que es la lectura que Bertram *et al.* justifican: una representación que identifica el contenido en lugar de describirlo puede ser excelente dentro de la distribución e inútil fuera de ella [2].

IV-E2. Recalibración: El procedimiento no aplica recalibración de forma uniforme. Niculescu-Mizil y Caruana reportan que los métodos de máximo margen presentan distorsión sistemática, mientras que la regresión logística y los conjuntos por agregación resultan bien calibrados sin corrección, y que recalibrar estos últimos puede deteriorarlos [22]. En consecuencia, se mide la calibración de cada modelo antes de decidir si aplicar corrección, y se reportan ambas mediciones.

[RAZÓN: Los mismos autores reportan que el ordenamiento de los modelos según la calidad de sus probabilidades difiere antes y después de la recalibración. Reportar una sola de las dos mediciones ofrecería una comparación incompleta.]

[DECIDIR: La elección del método permanece abierta. Niculescu-Mizil y Caruana establecen un criterio basado en el tamaño del conjunto de calibración [22], mientras que Ojeda *et al.* evalúan sistemáticamente los métodos atendiendo a la generalización hacia poblaciones externas [23]. Dado que el protocolo B constituye un escenario de transferencia a una población distinta, corresponde determinar cuál de las dos recomendaciones aplica.]

IV-F. Plan de explicabilidad

La contribución no puede ser una puntuación aislada; la pregunta sustantiva es cuáles características del estado transportan información sobre la victoria. Se proponen cuatro instrumentos, cada uno ligado a una pregunta distinta.

Los **coeficientes de la regresión logística** responden si la asociación de una característica con la victoria tiene la dirección que el conocimiento del dominio predice.

La **importancia por permutación agrupada** —permutando dentro de los episodios, nunca entre ellos— responde cuánto aporta una característica una vez respetada la dependencia. Karbalaie *et al.* señalan explícitamente que las estimaciones de importancia dependen del diseño de validación y pueden ser inestables bajo particiones a nivel de fila [13], razón por la cual la agrupación forma parte de la medición y no es un detalle de ella.

Las **ablaciones por familia** responden cuánto vale cada bloque.

Los **valores SHAP** se emplean únicamente cuando el modelo elegido es un conjunto de árboles y la pregunta es la atribución por instancia —por qué *esta* posición recibió esta puntuación—, puesto que esa es la pregunta que los tres instrumentos anteriores no pueden responder.

[RAZÓN: Los instrumentos se eligen por la pregunta que responden y no por disponibilidad. Incluir un método de atribución sin una pregunta asociada produce material que no se puede interpretar.]

IV-G. Contrato de reproducibilidad

La auditoría se ejecuta bajo una única semilla declarada. La etapa de modelado mantendrá las semillas y configuraciones en ficheros versionados y no en banderas de línea de comandos, fijará las dependencias, registrará cada ejecución junto con su identificador de revisión, y almacenará tablas comparables de parámetros y métricas.

La representación tabular se materializa una sola vez en formato columnar, puesto que el cuello de botella computacional es el análisis sintáctico y no el entrenamiento. Los datos crudos nunca se versionan; el repositorio lleva los *scripts* y las instrucciones para obtenerlos.

Esto refleja la práctica del descriptor SC2EGSet, que publica sus herramientas de extracción, sus registros de procesamiento y sus estadísticas resumidas junto a los datos [9], y atiende una debilidad documentada de la literatura sobre cambio temporal, donde el código estaba disponible en solo dos de quince estudios revisados [16].

Se adopta además la práctica de repetir cada experimento sobre múltiples semillas y reportar la dispersión resultante. Grinsztajn *et al.* varían el orden de las evaluaciones para separar el efecto del método de la variabilidad del procedimiento [18]; Figueiredo y Mendes ejecutan múltiples ciclos por estrategia de partición [14]; Brill *et al.* generan múltiples conjuntos de entrenamiento por configuración [1].

[POR COMPLETAR: Nombres definitivos de los ficheros de configuración y comandos de reproducción, una vez implementada la tubería.]

IV-H. Riesgos y mitigación

Expectativa sobre el efecto del protocolo. Se anticipa que la partición agrupada produzca métricas inferiores y mayor dispersión entre ejecuciones que una partición aleatoria. Figueiredo y Mendes documentan este comportamiento [14], y Karbalaie *et al.* cuantifican su magnitud sobre datos con estructura comparable [13]. Dicho comportamiento corresponde al funcionamiento correcto del protocolo y no a un defecto de su calibración.

[RAZÓN: Esta declaración debe redactarse antes de disponer de resultados. Ante métricas inferiores a las esperadas, la expectativa documentada previamente protege la decisión de mantener el protocolo.]

IV-I. Integración prevista con el agente

En la etapa final del proyecto el estimador entrenado es consumido por un agente inteligente como evaluador de posiciones. La interfaz es deliberadamente estrecha: el agente entrega un estado, el mismo extractor de características usado en entrenamiento produce x , y el modelo devuelve $f(x) \in [0, 1]$.

El agente no entrena el modelo, no lo actualiza mediante interacción y no lo sustituye, de modo que el proyecto no se convierte en aprendizaje por refuerzo en ninguna etapa. El consumo se verificará mostrando que el ordenamiento de posiciones candidatas por parte del agente cambia cuando el estimador se reemplaza por el modelo trivial B0, es decir, que el agente está efectivamente usando la predicción.

Tabla V
RIESGOS IDENTIFICADOS Y SU MITIGACIÓN.

Riesgo	Impacto	Mitigación o disparador
Instantáneas de un mismo episodio repartidas entre particiones	Alto	Agrupación por identificador de episodio en toda partición y todo pliegue; prueba automatizada de intersección vacía
Un campo prohibido alcanza el vector de características	Alto	Lista negra explícita; la construcción falla si una columna prohibida está presente
Fuga introducida por decisiones de diseño	Medio	Reglas de exclusión y ventanas de turno declaradas antes de tocar el conjunto de prueba [15]
Preprocesamiento ajustado sobre el conjunto completo	Medio	Todas las transformaciones se ajustan dentro del pliegue de entrenamiento [21]
Cambio de distribución entre días tempranos y tardíos	Medio	Reportar el protocolo temporal por separado y declarar cualquier caída como resultado y no como fallo [16]
Memorización de composiciones en lugar de comprensión del estado	Medio	Protocolo C y ablación del bloque de contexto de mazo [2]
Características trivialmente predictivas cerca del final	Medio	Análisis por ventana de turno; las conclusiones tempranas se sostienen solo sobre la ventana temprana
Versión del motor confundida con el tiempo de calendario	Medio	Registrar la versión como covariable de auditoría y declarar la confusión
Sesgo del estimador en turnos tempranos	Medio	Reporte del soporte por ventana de turno junto a las métricas [1]
Lectura optimista de una puntuación no calibrada	Medio	Reportar una regla de puntuación propia y curvas de fiabilidad junto al área bajo la curva [16]

[RAZÓN: La calibración importa precisamente por esta razón: un evaluador que ordena correctamente las posiciones pero está sistemáticamente sobreconfiado engañará a cualquier regla de decisión que compare sus salidas contra un umbral fijo.]

V. ANÁLISIS TÉCNICO DEL TRACK

El track aprobado es el Track A, aprendizaje automático clásico sobre datos tabulares. **[POR COMPLETAR: Fecha de aprobación comunicada por el docente.]**

El análisis que sigue se apoya en una auditoría del corpus realizada antes de cualquier modelado. Produjo un registro por episodio para cada episodio auditado, un censo de campos a nivel de instantánea y un conjunto de compuertas de decisión, todo reproducible bajo una única semilla fija.

[RAZÓN: Regla epistémica de esta sección. Toda cifra que aparece a continuación fue medida por la auditoría propia del corpus y es reproducible a partir de sus scripts. Las magnitudes que no han sido medidas se nombran como pendientes, nunca se estiman.]

V-A. Análisis exploratorio

V-A1. *Alcance de lo medido:* El corpus publica 67 entregas diarias que abarcan del 2026-06-16 al 2026-08-21, declarando 329 336 episodios y 1.29 TB sin comprimir. La auditoría cubre una muestra temporal de diez de esos días —el 14.9 % de los días y el 15.8 % de los episodios declarados— elegidos para abarcar las fases inicial, media y tardía de la competencia, con tres días consecutivos al comienzo de modo que pudiera medirse la deriva día a día.

Dentro de esa muestra se analizaron 52 085 episodios a partir de 182.6 GiB de JSON con cero errores de análisis sintáctico, produciendo 7 038 378 instantáneas utilizables.

[RAZÓN: Toda afirmación de esta sección está acotada a esa muestra. Nada de lo aquí escrito caracteriza a los 57 días no auditados, y presentarlo de otro modo excedería el alcance de lo medido.]

V-A2. *Tamaño, estructura y unidad de observación:* La duración de las partidas está fuertemente sesgada a la derecha. El número de pasos por episodio tiene mediana 140 y media 137.1, con cuartiles 101 y 171, percentil 95 de 221 y máximo 6 900. El recuento de turnos es mucho menor —mediana 13, media 14.3, percentil 95 de 27, máximo 1 035— porque un solo turno se descompone en muchas acciones atómicas.

Esa brecha gobierna cómo debe definirse una ventana de turno: fijar el juego temprano en los turnos uno a ocho sería una elección arbitraria contra una distribución cuya mediana es 13, de modo que la ventana se define a partir de la distribución empírica y se declara antes de tocar el conjunto de prueba.

La unidad de observación es un estado fresco del asiento que actúa, y esta es una decisión medida antes que estilística. En un sondeo de 139 672 estados frescos, la observación perteneciente al asiento que no actúa resultó idéntica a su propio estado anterior en 137 989 casos, el 98.8 %. Tratar cada asiento de cada paso como una fila duplicaría por tanto casi todas las observaciones sin añadir información, y repesaría silenciosamente los episodios por su duración. Restringirse al asiento activo da una razón medida entre estados activos y pasos de 0.9854, que es de donde procede la cifra de 7 038 378.

[RAZÓN: Siete millones de filas y cincuenta y dos mil unidades independientes es el hecho más consecuente de esta sección, y la Sección V-G está construida sobre él.]

V-A3. *Distribución del objetivo a nivel de episodio:* El desenlace se deriva del campo de recompensas, que resuelve el 99.86 % de los episodios. Las combinaciones observadas son (1, -1) en 27 135 episodios, (-1, 1) en 24 844, (0, 0) en 33, y una recompensa no numérica en 73. A nivel de episodio esto da un 52.10 % de victorias para el asiento P0, un 47.70 % para P1, un 0.063 % de empates y un 0.140 % de abandonos, sin episodios sin resolver.

Restringido a los 51 979 episodios con ganador decidido, la tasa de victoria de P0 es 0.5220 y la del jugador que mueve primero es 0.5287.

V-A4. *Estructura temporal y deriva:* Los diez días auditados no son intercambiables. Medida con la divergencia de Jensen–Shannon en base 2 entre el primer y el último día auditado, la distribución de mazos es esencialmente disjunta —1.0000—, la población de agentes casi tanto —0.9723—, la distribución de cartas se ha desplazado hasta 0.4889, mientras que la duración de las partidas apenas se ha movido —0.1221.

La diversidad no decae de forma suave: los mazos distintos por día van de 1 268 el 2026-06-23 a 48 el 2026-07-17, y los equipos distintos de 2 309 a 79 en esos mismos dos días. La mediana de la puntuación media de los episodios sube de 628 el primer día a 1 141 el 2026-07-17.

Seis versiones del motor coexisten en la muestra, de la 1.30.1 a la 1.32.4, y están ordenadas en el tiempo, lo que significa que tiempo de calendario y versión del motor están confundidos en la muestra auditada.

[RAZÓN: La auditoría no puede separar la deriva del conjunto de estrategias dominante del cambio del motor, y este trabajo reportará esa confusión en lugar de resolverla. Tres corpus comparables controlaron esa variable de forma explícita [5], [6], [19]; no poder hacerlo es una limitación nuestra que debe declararse con esas palabras.]

Un hallazgo de deriva constituye una amenaza directa a una característica concreta: la probabilidad de que el jugador que mueve primero sea el asiento P0 era 0.5089 el 2026-06-29 y es 0.9991 desde el 2026-07-17 en adelante. En los días tardíos, identidad de asiento y orden de turno son casi la misma variable.

V-B. Diccionario de datos

Un censo de campos sobre 139 672 estados frescos encontró 34 campos de estado presentes en el 100 % de las instantáneas inspeccionadas: 11 campos globales, 13 por jugador y 10 por Pokémon sobre 1 118 776 instancias.

El diccionario es preliminar y está sujeto a revisión tras el análisis exploratorio de la tabla materializada.

[DECIDIR: Hodge *et al.* incorporan además, para cada característica, el cambio respecto del instante inmediatamente anterior [5]. El diccionario actual no contempla variables de esa naturaleza, que permitirían representar la variación reciente del estado y no únicamente su valor. Su incorporación debe evaluarse antes de materializar la tabla, verificando que la información del instante anterior sea efectivamente anterior al instante de predicción y no constituya, por tanto, una fuga.]

V-C. Calidad de los datos

V-C1. *Qué ha sido verificado:* Los 52 085 episodios auditados se analizaron sin error. Una única firma de esquema de nivel superior cubre el 100 % de ellos y la versión de esquema vale 1 en todos, de modo que el corpus es estructuralmente homogéneo pese a las seis versiones del motor. Los índices de turno fueron monótonos en todos los episodios inspeccionados, con cero violaciones.

Todos los episodios auditados aparecen en el manifiesto de su día; a la inversa, cinco episodios declarados en el manifiesto del 2026-08-04 están ausentes de los ficheros, de 4 816 declarados.

Tabla VI

DICCIONARIO DE DATOS POR FAMILIA DE CARACTERÍSTICAS. LA PRESENCIA ES LA PROPORCIÓN MEDIDA DE INSTANTÁNEAS INSPECCIONADAS EN LAS QUE EL CAMPO DE ORIGEN EXISTE.

Familia	Tipo	Campos y derivación	Presencia y riesgo
Progreso	entero, binario	Índice de turno y contador de acciones, directos; indicador de jugador inicial derivado del orden y del índice de asiento; indicadores de energía adjuntada y de retirada	Presencia 100 %. El indicador de jugador inicial requiere investigación: asiento y orden de turno están casi perfectamente confundidos desde el 2026-07-17
Recursos	entero	Recuentos de mazo y de mano, directos; tamaño de la mano derivado de la lista propia; tamaño del descarte derivado	Presencia 100 %
Premios	entero	Ranuras de premio restantes, derivadas contando las ranuras no vacías	Presencia 100 %; el contenido está siempre oculto
Tablero	entero, continuo, binario	Tamaño de banca frente a su máximo; puntos de vida actuales, máximos y su razón; totales visibles; recuento de Pokémon dañados; energías, cartas de energía y herramientas; indicadores de pre-evolución y de aparición en el turno	Presencia 100 %. La razón de puntos de vida debe respetar $0 \leq hp \leq hp_{\text{máx}}$; la verificación forma parte del control de calidad
Estados alterados	binario	Envenenado, quemado, dormido, paralizado y confundido por jugador; estadio, estadio jugado y partidario jugado, globales	Presencia 100 %
Diferenciales	entero, continuo	Propio menos oponente para recuentos de mano, premios, banca, puntos de vida, energía y mazo	Derivados. Construcción siguiendo el precedente de Hodge <i>et al.</i> [5]
Contexto de mazo	categorico	Huella del mazo sobre un catálogo de 2376 mazos distintos	Cardinalidad elevada y riesgo alto de memorización del conjunto de estrategias dominante. Se admite únicamente en la ablación declarada, con retención por composición
Agrupación (<i>nunca características</i>)	—	Identificador de episodio, fecha e índice de turno	Se arrastran para agrupación, estratificación y reporte por ventana; excluidos del vector predictivo por construcción

Nota. Dos campos se excluyen sobre bases medidas antes de cualquier modelado. El campo de resultado del estado actual contiene el valor -1 en el 100 % de los 139 672 estados frescos inspeccionados: es constante y no transporta información en el momento de la predicción. El campo de observación en curso es nulo en 137 029 de esos estados, el 98.1 %, y su nulidad es una propiedad del juego y no un defecto, según se argumenta en la Sección V-D.

V-C2. Duplicados: Tres comprobaciones independientes devolvieron cero: ningún identificador de episodio repetido, ningún resumen criptográfico repetido sobre los bytes del fichero, y ninguna huella canónica repetida —esta última calculada sobre la semilla de configuración, ambos mazos en orden, la secuencia completa de acciones y las recompensas, excluyendo deliberadamente los metadatos volátiles. Ningún identificador aparece en más de un día. El juego contra uno mismo ocurre en cero de los 52 085 episodios.

[RAZÓN: La duplicación exacta no es una preocupación a nivel de episodio. La duplicación funcional dentro de un episodio es una cuestión distinta: en la muestra sondeada los 139 672 estados frescos fueron distintos, pero las cuasi duplicadas son la norma antes que la excepción. Esto no es un defecto que deba eliminarse —es la estructura de dependencia de los datos— y se aborda mediante agrupación y no mediante deduplicación.]

V-C3. Comprobaciones pendientes sobre la representación tabular: La auditoría verificó el corpus crudo. Lo siguiente debe reverificarse sobre la tabla materializada, y se consigna aquí como pendiente antes que como supuesto: la ausencia de valores por columna; los rangos imposibles —puntos de vida negativos o por encima del máximo, recuentos negativos, tamaño de banca por encima de su máximo—; la consistencia

lógica entre campos relacionados; las filas duplicadas dentro y entre episodios; y la cardinalidad efectiva de las columnas categóricas.

V-D. Valores ausentes e imputación

Emmanuel *et al.* distinguen los mecanismos de ausencia y muestran que la eficacia de un método de imputación depende de las características del conjunto: en su experimento, la superioridad relativa entre procedimientos se invierte según el conjunto evaluado [25]. Por ello la política es medir y caracterizar la ausencia antes de imputar, en lugar de aplicar una técnica por omisión.

Ausencia estructural. Un campo es nulo porque el juego lo define así: no hay Pokémon activo, no hay estadio en juego, la carta está oculta. El caso más claro es el campo de observación en curso, nulo en el 98.1 % de los estados inspeccionados, y el segundo es la mano del oponente, nula en el 100 %.

No son valores estadísticamente ausentes y no se imputan. Se codifican semánticamente, con un indicador binario de presencia más un centinela explícito.

[RAZÓN: Imputar una media aquí fabricaría un estado de juego que no puede ocurrir, y además destruiría la señal misma que el campo transporta: el hecho de que no se esté mirando nada es información.]

[RAZÓN: La referencia de Emmanuel et al. no formaliza por sí sola la categoría de ausencia estructural y no debe citarse como si lo hiciera. Sostener esa terminología en la versión final requiere una referencia específica sobre ausencia por diseño.]

[POR COMPLETAR: Incorporar una referencia arbitrada específica sobre ausencia por diseño o ausencia estructural que sustente la terminología empleada.]

Ausencia inesperada. Un campo requerido está ausente porque un episodio está malformado o el analizador es incompleto. El procedimiento es medir primero la frecuencia; si es residual, excluir la observación o el episodio dejando constancia del criterio y del recuento; si es sistemática, tratarla como defecto del analizador o cambio de esquema y corregir la tubería en lugar de parchear los datos.

Ninguna variable numérica se imputa automáticamente antes de haber estudiado su mecanismo de ausencia. Sea cual sea el mecanismo elegido, el estimador se ajusta dentro del pliegue de entrenamiento: Sasse *et al.* nombran explícitamente la imputación entre los pasos de preprocesamiento que producen fuga cuando se estiman sobre el conjunto completo antes de particionar [21].

Borisov *et al.* señalan, de forma complementaria, que los algoritmos modernos basados en árboles manejan internamente los valores faltantes y los rangos extremos [20], lo que reduce la dependencia del resultado respecto de la estrategia adoptada.

V-E. Valores atípicos

En este corpus un valor extremo suele ser un atípico válido antes que un error. Los pasos por episodio alcanzan 6900 frente a una mediana de 140, y el recuento de turnos alcanza 1035 frente a una mediana de 13 y un percentil 95 de 27.

Una partida de 1035 turnos merece investigación, no borrado: puede ser un tiempo agotado, un bucle de acciones, una interacción inusual de cartas, un fallo del simulador o una partida genuinamente larga, y esos cinco casos exigen respuestas distintas.

El procedimiento propuesto es diagnóstico antes que correctivo. Los candidatos se marcan por distancia distribucional —una regla intercuartil o de puntuación robusta sobre las características de duración y recuento— y por rangos imposibles en el dominio, que es una prueba distinta con un significado distinto. Los episodios marcados se inspeccionan caso por caso. Solo se eliminan los registros demostrablemente corruptos.

[RAZÓN: Cualquier regla de exclusión se declara antes de examinar la partición de prueba. Una regla elegida después de ver su efecto sobre la puntuación de prueba es una fuga por decisión de diseño en el sentido de Kaufman et al. [15].]

Contraste declarado con un corpus comparable. Los autores de SC2EGSet reemplazaron por la mediana los valores que excedían tres desviaciones estándar en sus propios experimentos [9]. No se adopta esa regla aquí, porque en un juego por turnos la cola de la distribución de duración puede ser exactamente donde vive el comportamiento interesante.

[RAZÓN: Declarar el desacuerdo con la práctica de un corpus comparable, y su razón, es preferible a divergir en silencio. La decisión queda expuesta y puede discutirse.]

V-F. Desbalance de clases

A nivel de episodio el objetivo está cerca del equilibrio: 52.10 % frente a 47.70 %, con empates en 0.063 % y abandonos en 0.140 %.

Esa no es, sin embargo, la distribución que verá el modelo. La etiqueta se define desde la perspectiva del jugador que actúa, y cada partida aporta un número distinto de instantáneas desde cada bando, de modo que la prevalencia de clases de la tabla final es función de la tabularización y **aún no ha sido medida**.

[RAZÓN: Debe recalcularse sobre la tabla materializada antes de tomar decisión alguna. Presentar la proporción a nivel de episodio como si fuera la proporción a nivel de fila reportaría como medido algo que no se ha medido.]

[POR COMPLETAR: Prevalencia de clases medida sobre la tabla materializada.]

La regla de decisión queda no obstante fijada de antemano, de modo que no pueda elegirse para acomodar un resultado. **Si el desbalance resultante es leve, no se corrige.** Corregir un desbalance que no necesita corrección distorsiona las probabilidades predichas, y esas probabilidades son la salida de este proyecto y no un subproducto. Van den Goorbergh *et al.* muestran que, para regresión logística estándar y regularizada, el submuestreo aleatorio, el sobremuestreo aleatorio y la generación sintética no mejoran de forma sistemática el área bajo la curva, y pueden sobreestimar de manera pronunciada la probabilidad de la clase minoritaria [26].

[RAZÓN: Esta referencia no avala preferir la ponderación de clases: dicha técnica no fue evaluada en el estudio, y no se adoptará por cita indirecta. Atribuirle esa recomendación excedería lo que la fuente sostiene.]

Si es apreciable, se comparan alternativas dentro del pliegue de entrenamiento y se reporta su efecto tanto sobre la discriminación como sobre la calibración. Silva Filho *et al.* señalan que el desbalance afecta las probabilidades predichas y, en consecuencia, la calibración [17]. No se usará sobremuestreo sintético sin justificación explícita, y bajo ninguna circunstancia fuera del pliegue de entrenamiento: Sasse *et al.* enumeran el sobremuestreo aplicado antes de particionar entre sus casos documentados de fuga [21].

Empates y abandonos. Los 33 empates se excluyen del objetivo binario y se documentan; su volumen no puede sostener una tercera clase. Los 73 abandonos tienen ganador identificable, pero el final no procede de la dinámica del juego, de modo que se excluyen del entrenamiento y se reservan para un análisis de sensibilidad.

V-G. Dependencia entre muestras y prevención de la fuga de datos

Esta es la subsección de la que depende la validez de todo lo demás, y el enunciado del curso penaliza la fuga confirmada más severamente que cualquier otro fallo aislado.

V-G1. La estructura de dependencia, medida: Cada episodio aporta en promedio unas 135 instantáneas, e instantáneas consecutivas difieren en una única acción atómica. Las filas son por tanto fuertemente dependientes dentro de un episodio e independientes solo entre episodios.

Medimos la consecuencia directamente: bajo una partición aleatoria 70/30 a nivel de instantánea, la fracción esperada de episodios presentes en ambas particiones es 0.999945.

Karbalaie *et al.* midieron un acierto de 0.91 bajo validación cruzada estratificada frente a 0.66 dejando un participante fuera sobre los mismos datos, e identificaron la causa en que el tamaño muestral efectivo es el número de participantes y no el de ensayos [13]. Sasse *et al.* clasifican precisamente este caso como vía primaria de fuga de prueba a entrenamiento [21].

[RAZÓN: Nuestro corpus es una instancia más extrema de la misma estructura: no dos muestras relacionadas, sino 135.]

V-G2. El momento de la predicción: Un campo puede existir en el JSON y aun así ser inválido como característica. La prueba que gobierna es el requisito de la no máquina del tiempo de Kaufman *et al.*: un modelo legítimo solo puede usar información de un instante no posterior al del objetivo [15], afinada por la pregunta que Sasse *et al.* recomiendan hacer de cada columna —si ese campo estaría disponible en el despliegue [21].

Aplicar esa prueba campo por campo produce cuatro clases. **Seguras.** Los campos de estado presentes en el 100 % de las instantáneas, leídos de la observación propia del asiento activo en el turno τ , junto con los recuentos, razones y diferenciales derivados de ellos. Son lo que el propio agente vio cuando decidió.

Requieren investigación. El indicador de jugador inicial, porque asiento y orden de turno están casi perfectamente confundidos desde el 2026-07-17 y el modelo podría aprender el asiento en lugar del tiempo; y el registro acumulado de acciones, legítimo únicamente si se trunca estrictamente antes de τ .

Fuga directa, excluidas por construcción. El campo de recompensas y el resultado final; cualquier recompensa por paso, no nula únicamente en el último; la carga útil de visualización, presente en el 100 % de los episodios, que expone el mazo restante de cada jugador en orden —información perfecta que nunca aparece en la observación—; las marcas de tiempo y los identificadores derivados del fichero; y los nombres de equipo o de agente, que actúan como sustituto de la habilidad.

[RAZÓN: Lo último no es hipotético: la mediana de la puntuación media de los episodios seleccionados cada día sube de 628 a más de 1 100 a lo largo de la muestra, de modo que un identificador de agente codifica parcialmente el desenlace.]

Excluidas por constantes. El campo de resultado del estado actual, fijo en -1 en todos los estados frescos.

V-G3. Información oculta, verificada antes que supuesta: El entorno ya retiene lo que debe retener, y lo comprobamos en lugar de confiar. A lo largo de 139 672 estados inspeccionados, la mano del oponente fue nula en el 100 % de los casos con cero fugas detectadas, mientras que el recuento de cartas del oponente estuvo siempre disponible como entero. Las 1 281 678 ranuras de premio inspeccionadas —propias y del oponente por igual— fueron todas nulas.

[RAZÓN: La fuga de información oculta no es, por tanto, un riesgo que debamos mitigar; es una propiedad que no debemos

Tabla VII

VECTORES DE FUGA, LA EVIDENCIA DE AUDITORÍA QUE ESTABLECE CADA UNO COMO RIESGO REAL, Y EL CONTROL APLICADO.

Vector	Evidencia medida	Control
Por episodio	Una partición aleatoria 70/30 por filas sitúa 0.999945 de los episodios en ambas particiones	Partición y pliegues agrupados por identificador; prueba de intersección vacía
Información futura	Carga útil de visualización presente en el 100 % de los episodios, que expone el mazo restante ordenado	Características extraídas solo de la observación del asiento en τ ; carga útil en lista negra
Sustituto de habilidad	La mediana de la puntuación media sube de 628 a más de 1 100 a lo largo de la muestra	Metadatos de agente y equipo usados solo para auditoría y agrupación
Memorización de composiciones	2 376 mazos, pero los diez primeros cubren el 39.94 % de las instancias; un día tiene solo 48	Protocolo C; contexto de mazo confinado a una única ablación declarada
Información oculta	Cero fugas en 139 672 estados; 1 281 678 ranuras de premio todas nulas	Analizador que lee solo la observación propia, con aserción automatizada de privacidad
Metadatos	52 085 identificadores distintos sobre 52 085 filas	Columnas de agrupación excluidas del vector por construcción
Preprocesamiento	(riesgo de diseño, no propiedad del corpus)	Todas las transformaciones se ajustan dentro del pliegue de entrenamiento [21]
Temporal	Divergencia de mazos de 1.0000 entre el primer y el último día auditado	El protocolo temporal corta por fecha, nunca al azar [15]

destruir, razón por la cual las características se extraen exclusivamente de la observación propia del asiento y nunca de la carga útil de visualización.]

V-G4. Vectores de riesgo, evidencia y contramedidas:

[RAZÓN: Figueiredo y Mendes cuantifican la contaminación entre subconjuntos antes de entrenar modelo alguno [14]. Acompañar cada vector con evidencia medida sobre este corpus, y no únicamente con la descripción del riesgo, es lo que distingue una prevención verificada de una precaución declarada.]

V-G5. Verificación automática: El pipeline incluirá al menos dos invariantes que deben fallar antes de cualquier entrenamiento: primero, ninguna columna de la lista negra puede aparecer en el conjunto de características; segundo, la intersección de identificadores de episodio entre cualquier par de particiones debe ser vacía.

Se añadirá además una prueba del analizador que confirme que la información privada del oponente permanece oculta, y que ninguna transformación se ajusta con datos de validación o de prueba.

[RAZÓN: Una política de prevención sin una prueba que la verifique constituye una intención y no una mitigación. La verificación automática es la forma operativa de la separación aprender–predecir de Kaufman et al. [15].]

[DECIDIR: Figueiredo y Mendes comparan explícitamente el desempeño obtenido bajo distintas estrategias de partición, lo que permite cuantificar la inflación atribuible a la fuga [14]. Un procedimiento equivalente sobre este corpus —ejecutar el modelo de referencia bajo partición aleatoria y bajo partición agrupada, y reportar la diferencia— convertiría la prevención de fuga en un resultado medido. Su incorporación debe decidirse en la Etapa 2, y en caso de adoptarse debe declararse de forma inequívoca que la partición aleatoria se emplea únicamente como demostración del sesgo y no para reportar resultados.]

V-H. Representatividad

El corpus no es una muestra aleatoria del juego, y el editor lo dice: las repeticiones se seleccionan a diario, ordenadas por puntuación media de los agentes, y se truncan a 20 GiB por día [12].

De ahí se siguen tres consecuencias, y las tres están medidas. La población es de agentes artificiales, no de humanos. Es la franja alta de la escalera de clasificación, con la mediana de la puntuación media ascendiendo a lo largo de la muestra. Y está concentrada: los diez mazos más frecuentes suman el 39.94 % de las instancias y los cien más frecuentes el 74.76 %, con días individuales que caen a 48 mazos distintos.

Esto refleja la limitación que los autores de SC2EGSet declaran para su propio corpus [9], y es una versión más aguda del problema de población al que Janusz et al. se enfrentan desde la dirección opuesta, pues sus estados fueron generados por agentes que actúan al azar [8].

[RAZÓN: Leídos en conjunto, ambos acotan nuestro caso: un corpus procede de la población más débil posible y el otro de la más fuerte, y ninguno es la población general. Cualquier afirmación de este proyecto es, por tanto, una afirmación sobre agentes artificiales competitivos de una franja de puntuación específica durante una muestra específica de diez días.]

VI. CONSIDERACIONES ÉTICAS PRELIMINARES

VI-A. Sensibilidad de los datos

El corpus no contiene datos clínicos, biométricos ni conductuales sobre individuos identificados: sus registros son partidas simuladas entre agentes de software, publicadas bajo una licencia CC0-1.0 [12]. En la auditoría realizada no se identificaron datos personales sensibles de jugadores humanos.

Cabe una salvedad. Cada episodio lleva los nombres de equipo y de agente de los competidores, y en la muestra auditada esos nombres son seudónimos elegidos por sus dueños que en algunos casos se asemejan a nombres personales. Identifican a participantes de una competencia pública y no a sujetos de estudio, pero siguen siendo atribuibles a personas.

Se tratan por tanto como metadatos y no como material: se usan para auditoría, agrupación y la comprobación de juego contra uno mismo, quedan excluidos del vector de características por la lista negra descrita en la Sección V-G, y

no se publicará ningún ordenamiento ni comparación agregada de competidores nombrados.

[RAZÓN: Esta decisión coincide con el control de fuga, lo cual es conveniente pero no es la razón de la decisión. Declararlo así evita presentar una precaución técnica como si fuera una consideración ética, o viceversa.]

VI-B. Riesgo de sesgo y representatividad

El principal riesgo de este proyecto no es el daño a un sujeto de datos: es la sobreafirmación.

Los episodios se seleccionan a diario por puntuación media de los agentes y se truncan a un volumen diario fijo [12], de modo que el corpus es la franja alta de una escalera de agentes artificiales y no una muestra del juego. La auditoría cuantifica la concentración que se sigue de ello: los diez mazos más frecuentes cubren el 39.94 % de las instancias, un día auditado contiene solo 48 mazos distintos, y el conjunto de mazos del último día auditado es esencialmente disjunto del del primero. Un modelo ajustado aquí aprende un conjunto de estrategias estrecho y en movimiento.

La literatura revisada refuerza que el riesgo no es hipotético. Angliss et al. encuentran diferencias entre el rendimiento sobre composiciones vistas y la generalización a composiciones no vistas [11]. Chitayat et al. separan la evaluación entre versiones conocidas y posteriores [10]. Xenopoulos et al. muestran que la importancia relativa de las características difiere entre poblaciones de distinto nivel de habilidad, y que un modelo entrenado sobre una no necesariamente se extiende a otra sin pérdida de desempeño [6].

Saravanan y Guzdial orientan deliberadamente su agente a aproximar un nivel de habilidad promedio, argumentando que el conjunto de estrategias dominante constituye una medida de popularidad determinada mayoritariamente por jugadores de habilidad media [19]. Un corpus restringido a la franja superior observa, en consecuencia, una población distinta de aquella que determina el comportamiento agregado del juego.

VI-B1. Tres lecturas erróneas, cada una fácil de cometer: **Extrapolar a jugadores humanos** carecería de respaldo: no aparece ninguna partida humana en el corpus, y los dos corpus comparables de deportes electrónicos revisados declaran exactamente esta limitación para sí mismos [8], [9].

Extrapolar al juego completo tampoco tendría respaldo, puesto que un modelo que nunca vio un arquetipo de mazo carece de base para juzgar posiciones construidas en torno a él. Bertram et al. muestran cómo se ve ese fallo cuando el contenido se codifica por identidad en lugar de por descripción [2].

Tratar la salida como una propiedad estable de una posición tampoco tendría respaldo a lo largo del tiempo, porque la población cambia de forma medible en diez días.

VI-C. Interpretación de la probabilidad

Una estimación de probabilidad de victoria invita a un mal uso específico: leer un número entre cero y uno como una posibilidad bien fundada cuando puede ser solo una puntuación bien ordenada.

La distinción no es pedante. Guo *et al.* encontraron deterioro de la calibración en todos los estudios que la midieron bajo cambio temporal, frente a deterioro de la discriminación en solo tres de doce [16], lo que significa que un modelo puede seguir ordenando posiciones correctamente mucho después de que sus probabilidades declaradas hayan dejado de ser ciertas. La mayoría de los estudios comparables sobre estados de juego no reporta calibración en absoluto [8], [9].

[RAZÓN: Reportar una regla de puntuación propia y curvas de fiabilidad junto al área bajo la curva es por tanto un compromiso ético tanto como metodológico: es lo que permite a un lector saber cuál de las dos cosas es nuestro número.]

VI-D. Límites de generalización declarados

Los resultados de este trabajo no deben extrapolarse a:

- Partidas entre personas. El corpus procede de agentes artificiales, cuyo comportamiento no se asume equivalente al humano.
- El *Pokémon TCG* en su formato físico.
- El conjunto de estrategias posibles del juego, más allá de las composiciones observadas.
- Poblaciones de agentes con nivel de puntuación distinto del observado.
- Versiones del motor de simulación distintas de las presentes en los datos.
- Periodos posteriores a los cubiertos por la muestra auditada, más allá de lo que el protocolo B permita evaluar.
- Los 57 días no auditados del corpus publicado.

Dos precisiones adicionales sobre el alcance de las afirmaciones. Un buen resultado bajo la partición agrupada no implica robustez temporal: esa afirmación solo podrá sostenerse si el modelo mantiene su desempeño bajo el protocolo cronológico. Y un buen valor global de área bajo la curva no implica que la probabilidad esté calibrada, ni que el modelo se comporte de igual manera en las etapas tempranas y tardías de la partida.

[RAZÓN: Este apartado existe para impedir que los resultados se empleen fuera del ámbito en el cual fueron validados. Su omisión trasladaría al lector la responsabilidad de inferir los límites.]

VI-E. Riesgos de calidad no aislables

La auditoría identificó 73 episodios con desenlace anómalo, cinco episodios declarados en un manifiesto pero ausentes de los ficheros, y episodios de duración extrema —hasta 1 035 turnos— cuya causa no puede determinarse sin inspección individual. Estos casos se documentan y se reservan para análisis de sensibilidad, pero no puede descartarse la presencia de comportamientos degenerados de los agentes que no resulten identificables por completo.

Xenopoulos *et al.* reconocen una limitación análoga al señalar que no les resulta posible identificar a los jugadores que incurren en trampa [6]. Białecki *et al.* declaran que deliberadamente no filtraron repeticiones terminadas de forma prematura, con el fin de preservar las distribuciones originales [9].

[RAZÓN: Declarar las anomalías que se sabe que existen pero no se pueden aislar por completo es preferible a presentar el corpus

como libre de contaminación. Los precedentes citados establecen que esta declaración es práctica aceptada en el dominio.]

VI-F. Mitigaciones previstas antes del entrenamiento

- Toda cifra reportada lleva su alcance: los diez días auditados, la franja de puntuación y las versiones del motor presentes.
- La discriminación y la calibración se reportan por separado, y los resultados bajo los protocolos temporal y de reserva de composiciones se reportan aparte del protocolo primario en lugar de promediarse con él.
- Los identificadores de agente y equipo quedan excluidos del vector de características, y no se publican resultados por competidor.
- Los intervalos de confianza se calculan sobre episodios, de modo que la incertidumbre no se subestime contando filas correlacionadas como evidencia independiente.
- El resumen, las conclusiones y cualquier síntesis pública declaran la población sobre la que se ajustó el modelo, de modo que la limitación viaje con el resultado en lugar de quedar confinada a esta sección.

[RAZÓN: Las cinco mitigaciones son verificables en el propio artículo. Una mitigación cuya ejecución no puede comprobarse no constituye una mitigación.]

VI-G. Aspectos diferidos

La ética del despliegue, los escenarios de uso indebido y los riesgos operativos de un agente que consuma este estimador —en particular el efecto de un evaluador sobreconfiado sobre las decisiones del agente— se abordan en la etapa final, cuando exista un agente.

REFERENCIAS

- [1] R. S. Brill, R. Yurko, and A. J. Wyner, “Exploring the difficulty of estimating win probability: A simulation study,” *Journal of Quantitative Analysis in Sports*, vol. 22, no. 1, pp. 105–115, 2026.
- [2] V. Bertram, “Learning with generalised card representations for “Magic: The gathering”,” *VERIFICAR*, vol. VERIFICAR, no. VERIFICAR, p. VERIFICAR, 2024.
- [3] A. A. Kamal, M. A. Mansor, L. Truna, N. Mohd. Shaipullah, and N. H. Habib Sultan, “Machine learning applications in multiplayer online battle arena esports—a systematic review,” *Pertanika Journal of Science & Technology*, vol. 33, no. 2, pp. 765–798, 2025.
- [4] P. Tian, W. Lan, and X. Zhang, “Hero featured learning algorithm for winning rate prediction of honor of kings,” in *2022 IEEE Conference on Games (CoG)*. IEEE, 2022, pp. 322–329.
- [5] V. J. Hodge, S. Devlin, N. Sephton, F. Block, P. I. Cowling, and A. Drachen, “Win prediction in multiplayer esports: Live professional match prediction,” *IEEE Transactions on Games*, vol. 13, no. 4, pp. 368–379, 2021.
- [6] P. Xenopoulos, W. R. Freeman, and C. Silva, “Analyzing the differences between professional and amateur esports through win probability,” in *Proceedings of the ACM Web Conference 2022 (WWW ’22)*. New York, NY, USA: Association for Computing Machinery, 2022, pp. 3418–3427.
- [7] R. Miernik and J. Kowalski, “Evolving evaluation functions for collectible card game AI,” in *Proceedings of the 14th International Conference on Agents and Artificial Intelligence (ICAART)*, vol. 3. SciTePress, 2022, pp. 253–260.
- [8] A. Janusz, T. Tajmajar, and M. Świechowski, “Helping AI to play hearthstone: AIA’17 data mining challenge,” in *Proceedings of the 2017 Federated Conference on Computer Science and Information Systems (FedCSIS)*, ser. Annals of Computer Science and Information Systems, vol. 11, 2017, pp. 121–125.

- [9] A. Białecki, N. Jakubowska, P. Dobrowolski, P. Białecki, L. Krupiński, A. Szczap, R. Białecki, and J. Gajewski, "SC2EGSet: StarCraft II esports replay and game-state dataset," *Scientific Data*, vol. 10, no. 1, p. 600, 2023.
- [10] A. Pedrassoli Chitayat, F. Block, J. Walker, and A. Drachen, "Beyond the meta: Leveraging game design parameters for patch-agnostic esports analytics," in *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 19, no. 1, 2023, pp. 116–125.
- [11] C. L. Angliss, J. Cui, J. Hu, A. Rahman, and P. Stone, "VGC-Bench: Towards mastering diverse team strategies in competitive pokémon," in *Proceedings of the 25th International Conference on Autonomous Agents and Multiagent Systems (AAMAS 2026)*. IFAAMAS, 2026, pp. 2299–2307.
- [12] The Pokémon Company, "PTCG AI battle challenge simulation episodes," Conjunto de datos en Kaggle, licencia CC0-1.0, 2026, vERIFICAR: título exacto, URL y fecha de acceso.
- [13] VERIFICAR, "Participant-aware model validation for repeated-measures data: Comparative cross-validation study," *VERIFICAR*, vol. VERIFICAR, no. VERIFICAR, p. VERIFICAR, 2026.
- [14] R. B. D. Figueiredo and H. A. Mendes, "Analyzing information leakage on video object detection datasets by splitting images into clusters with high spatiotemporal correlation," *IEEE Access*, vol. 12, pp. 47 646–47 655, 2024.
- [15] S. Kaufman, S. Rosset, and C. Perlich, "Leakage in data mining: Formulation, detection, and avoidance," in *Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '11)*. New York, NY, USA: Association for Computing Machinery, 2011, p. VERIFICAR.
- [16] V. Guo, "Systematic review of approaches to preserve machine learning performance in the presence of temporal dataset shift in clinical medicine," *VERIFICAR*, vol. VERIFICAR, no. VERIFICAR, p. VERIFICAR, 2021.
- [17] T. Silva Filho, H. Song, M. Perello-Nieto, R. Santos-Rodriguez, M. Kull, and P. Flach, "Classifier calibration: A survey on how to assess and improve predicted class probabilities," *Machine Learning*, vol. 112, no. 9, pp. 3211–3260, 2023.
- [18] L. Grinsztajn, E. Oyallon, and G. Varoquaux, "Why do tree-based models still outperform deep learning on typical tabular data?" in *Advances in Neural Information Processing Systems 35 (NeurIPS 2022), Datasets and Benchmarks Track*, vol. 35. Curran Associates, Inc., 2022, pp. 507–520. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/file/0378c7692da36807bdec87ab043cdadc-Paper-Datasets_and_Benchmarks.pdf
- [19] A. Saravanan and M. Guzdial, "A framework for predicting the impact of game balance changes through meta discovery," *IEEE Transactions on Games*, vol. 16, no. 4, pp. 821–830, Dec. 2024.
- [20] V. Borisov, T. Leemann, K. Seßler, J. Haug, M. Pawelczyk, and G. Kasneci, "Deep neural networks and tabular data: A survey," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 35, no. 6, pp. 7499–7519, Jun. 2024.
- [21] L. Sasse, E. Nicolaisen-Sobesky, J. Dukart, S. B. Eickhoff, M. Götz, S. Hamdan, V. Komeyer, A. Kulkarni, J. M. Lahnakoski, B. C. Love, F. Raimondo, and K. R. Patil, "Overview of leakage scenarios in supervised machine learning," *Journal of Big Data*, vol. 12, no. 1, p. 135, 2025.
- [22] A. Niculescu-Mizil and R. Caruana, "Predicting good probabilities with supervised learning," in *Proceedings of the 22nd International Conference on Machine Learning (ICML '05)*. New York, NY, USA: Association for Computing Machinery, 2005, pp. 625–632.
- [23] F. M. Ojeda, M. L. Jansen, A. Thiéry, S. Blankenberg, C. Weimar, M. Schmid, and A. Ziegler, "Calibrating machine learning approaches for probability estimation: A comprehensive comparison," *Statistics in Medicine*, vol. 42, no. 29, pp. 5451–5478, 2023.
- [24] T. Dimitriadis, T. Gneiting, and A. I. Jordan, "Stable reliability diagrams for probabilistic classifiers," *Proceedings of the National Academy of Sciences*, vol. 118, no. 8, p. e2016191118, 2021.
- [25] T. Emmanuel, T. Maupong, D. Mpoeleng, T. Semong, B. Mphago, and O. Tabona, "A survey on missing data in machine learning," *Journal of Big Data*, vol. 8, no. 1, p. 140, 2021.
- [26] R. van den Goorbergh, M. van Smeden, D. Timmerman, and B. Van Calster, "The harm of class imbalance corrections for risk prediction models: Illustration and simulation using logistic regression," *Journal of the American Medical Informatics Association*, vol. 29, no. 9, pp. 1525–1534, 2022.