

Estimación de la probabilidad de victoria a partir del estado de juego en el *Pokémon Trading Card Game*: un estudio tabular con control de fuga de datos sobre repeticiones de agentes competitivos

Versión preliminar — Etapa 1: estado del arte y diseño propuesto. Revisión individual del Eje C (conjunto de datos y validación).

Sebastián Hernández Bonilla
Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica
2022093651

Resumen—Resumen preliminar. Este resumen describe el problema, la motivación y el enfoque propuesto. No reporta resultados experimentales, puesto que en esta etapa no se ha entrenado ningún modelo. Evaluar una posición es una competencia central en los juegos de cartas competitivos y, sin embargo, en el *Pokémon Trading Card Game* (PTCG) no existe trabajo publicado que estime la probabilidad de victoria a partir de un estado de juego intermedio y parcialmente observable. El corpus de repeticiones del PTCG AI Battle Challenge, publicado recientemente, vuelve tratable la pregunta, pero su estructura hace que sea fácil responderla mal: una sola partida genera miles de estados fuertemente correlacionados, de modo que una partición aleatoria a nivel de fila coloca estados de la misma partida a ambos lados de la división. En una auditoría de 52 085 episodios medimos que tal partición situaría el 99.995 % de los episodios en ambas particiones de forma simultánea. Este trabajo pregunta, por tanto, cuánta información sobre el desenlace contiene un único estado observable, cómo crece esa información conforme avanza la partida y cuánta sobrevive al evaluar sobre partidas, mazos y periodos no vistos. Proponemos una formulación tabular supervisada, una fila por estado fresco del asiento activo, con características derivadas exclusivamente de la observación disponible en ese instante, con una escalera de modelos clásicos que va desde un predictor trivial hasta *gradient boosting*, una lista negra explícita de campos cuyo uso constituiría fuga de datos, y particiones agrupadas por episodio en lugar de por fila. La evaluación reporta discriminación y calibración por separado, de forma global y por ventana de turno, con intervalos de confianza remuestreados sobre episodios. El *baseline* de literatura es la tarea análoga sobre estados de juego de *Hearthstone*, cuyo *baseline* oficial alcanzó un AUC de 0.7846 y cuya mejor solución alcanzó 0.8019; las diferencias de juego, protocolo y población de agentes que impiden una comparación estricta se declaran explícitamente.

Palabras clave—estimación de probabilidad de victoria, juegos de cartas coleccionables, aprendizaje automático tabular, fuga de datos, validación cruzada agrupada, cambio de distribución

I. INTRODUCCIÓN

I-A. Contexto y relevancia

Estimar la probabilidad de que un jugador gane desde la posición que tiene actualmente sobre la mesa es una de las

competencias recurrentes de los sistemas que juegan. Una función de evaluación de estados convierte una búsqueda intratable en una tratable, y es lo que permite a un agente detener una simulación antes de tiempo y aún así devolver un juicio con sentido. En los juegos de cartas competitivos esa misma estimación tiene un segundo público: analistas, comentaristas y jugadores la leen como una afirmación sobre qué recursos deciden realmente una partida. Ambos usos dependen del mismo objeto, una función que asigna a una posición observable una probabilidad de victoria.

Dos propiedades convierten a los juegos de cartas coleccionables (CCG, por sus siglas en inglés) en un escenario difícil para esa función. La primera es la información imperfecta: un jugador nunca ve la mano del rival ni las cartas de premio boca abajo, de modo que el evaluador debe trabajar sobre una vista parcial y no sobre el estado verdadero del mundo. La segunda es la no estacionariedad. El repertorio de cartas legales, los mazos que los jugadores efectivamente llevan y la población de adversarios cambian con el tiempo, y un modelo ajustado a un metajuego no tiene por qué sobrevivir al siguiente. Bertram *et al.* lo muestran de forma concreta para *Magic: The Gathering*: un modelo cuya representación de carta es una codificación *one-hot* alcanza un 67.80 % de acierto *top-1* sobre el conjunto de cartas con el que fue entrenado y queda simplemente indefinido sobre cartas que nunca ha visto, mientras que una representación generalizada conserva un 68.00 % dentro de la distribución y aún alcanza un 42.87 % sobre conjuntos no vistos [1].

El problema de la evaluación ya se ha planteado antes en esta familia de juegos. El AAIA'17 Data Mining Challenge pidió a los participantes predecir el ganador de una partida de *Hearthstone* a partir de un único estado de juego, y reportó un *baseline* oficial de 0.7846 de AUC frente a una mejor solución de 0.8019 [2]. Para *StarCraft II*, el descriptor de datos SC2EGSet acompaña su corpus de repeticiones con experimentos de predicción de victoria sobre indicadores económicos agregados, y alcanza un acierto de 0.9071 cuando

dispone de las características de ambos jugadores [3]. El *Pokémon Trading Card Game* (PTCG) carece de un estudio publicado comparable, pese a que su estructura de recursos, cartas de premio, asignación de energía, banca, líneas de evolución, difiere de la de ambos juegos de maneras que deberían cambiar qué características transportan información.

Esa brecha se ha vuelto abordable recientemente. El PTCG AI Battle Challenge publica a diario repeticiones JSON de partidas completas entre agentes que compiten entre sí [4]. El corpus es grande y, para esta tarea, estructuralmente traicionero. Nuestra auditoría de diez publicaciones diarias, que cubren 52 085 episodios, encontró que esos episodios producen 7 038 378 instantáneas de estado utilizables: aproximadamente 135 filas correlacionadas por cada partida independiente. Datos con esta forma premian el protocolo equivocado. Karbalaie *et al.* midieron el efecto directamente en un conjunto clínico de medidas repetidas, donde un clasificador *extra trees* obtuvo 0.91 de acierto bajo validación cruzada estratificada de diez pliegues y 0.66 bajo validación dejando un participante fuera, una inflación de 0.25 producida enteramente por la regla de partición [5]. El costo de ignorar la estructura no es, por tanto, un sesgo marginal: es la diferencia entre un resultado y un artefacto.

I-B. Planteamiento del problema

Este trabajo ataca una limitación específica: para el *Pokémon TCG* no existe evidencia sobre cuánta información contiene un único estado observable acerca del desenlace, sobre cómo se acumula esa información a lo largo de la partida, ni sobre cuánta se transfiere a partidas, mazos y periodos temporales que no se vieron durante el entrenamiento. La literatura que respondería esas preguntas para juegos adyacentes responde solo una parte. Janusz *et al.* reportan discriminación pero no calibración [2]; Białecki *et al.* reportan acierto y describen sus propios experimentos como “más ilustrativos que investigativos” [3]; y ninguno reporta rendimiento bajo un cambio de distribución declarado.

El problema es también metodológico. Puesto que el corpus fue recolectado por un tercero y publicado en medio de una competencia en curso, no controlamos su procedencia, que es precisamente la situación que Kaufman *et al.* identifican como el caso más difícil para el control de la fuga de datos [6]. Establecer que una cifra reportada significa lo que aparenta significar forma parte, por tanto, del problema de investigación y no de sus preliminares.

I-C. Pregunta de investigación

PI: ¿En qué medida las características observables del estado de una partida de *Pokémon TCG* permiten predecir su resultado final mediante modelos clásicos de aprendizaje automático; cómo cambia esa capacidad predictiva conforme avanza la partida; y cuánta se conserva al evaluar sobre episodios, mazos y periodos temporales ausentes del entrenamiento?

La pregunta admite refutación, es medible y puede responderse dentro del semestre. Es refutable porque el modelo puede

no superar a un predictor trivial en los turnos tempranos; es medible mediante ROC-AUC y *log loss* calculados por ventana de turno sobre particiones agrupadas por episodio; y es responsable porque los datos ya están descargados y auditados, y definir el protocolo no requiere entrenar ningún modelo.

I-D. Hipótesis de trabajo

H1: Las características estructuradas del estado observable contienen señal predictiva sobre el desenlace desde etapas tempranas de la partida, ROC-AUC significativamente superior a 0.5 en la ventana de turnos temprana, y esa señal aumenta conforme la partida progresa.

H2: La señal temprana no se explica únicamente por el orden de turno ni por la identidad del mazo.

H3: Bajo el protocolo temporal, la calibración se degrada antes y en mayor medida que la discriminación.

H3 es una predicción importada de un campo vecino, no una conjetura. Guo *et al.* revisaron quince estudios clínicos sobre cambio temporal del conjunto de datos y encontraron que los once estudios que midieron calibración reportaron deterioro de la calibración, mientras que solo tres de los doce que midieron discriminación reportaron deterioro de la discriminación [7]. Si esa asimetría se sostiene en un dominio de juegos es una pregunta empírica abierta, y enunciarla como hipótesis la vuelve falsable aquí.

Cada hipótesis tiene un criterio de refutación declarado. H1 se debilita si el intervalo de confianza del AUC de la ventana temprana incluye 0.5, y su componente dinámico queda refutado si el AUC por ventana no crece una vez controlada la duración de la partida. H2 queda refutada si un modelo restringido al orden de turno y a la identidad del mazo iguala al conjunto completo de características, lo que indicaría un artefacto de emparejamiento y no señal del estado de juego. H3 queda refutada si el *Brier score* y las curvas de fiabilidad no se degradan más rápido que el AUC bajo la partición temporal. No se fija de antemano ningún umbral numérico de mejora: sin resultado empírico previo sobre este corpus, cualquier número de ese tipo sería inventado.

I-E. Objetivos

Objetivo general. Desarrollar y evaluar modelos clásicos de aprendizaje automático que estimen la probabilidad de victoria en partidas de *Pokémon TCG* a partir de características tabulares derivadas exclusivamente del estado observable, y caracterizar cómo evoluciona esa capacidad predictiva a lo largo de la partida y ante cambios de episodio, mazo y periodo temporal.

Objetivos específicos.

1. Caracterizar el corpus y su calidad sobre la representación tabular final: análisis exploratorio, diccionario de datos, mecanismos de ausencia, valores atípicos, balance de clases y representatividad.

2. Construir una tubería reproducible que vaya de la repetición JSON a una tabla de instantáneas frescas, con perspectiva normalizada, semillas fijas y verificación de esquema.
3. Diseñar y verificar los controles de fuga de datos: agrupación por episodio, lista negra explícita de campos prohibidos y pruebas automatizadas que fallen si una columna prohibida entra al vector de características.
4. Comparar una escalera de *baselines*, desde un predictor trivial hasta *gradient boosting*, bajo tres protocolos de partición, reportando discriminación y calibración con intervalos de confianza calculados sobre episodios.
5. Analizar explicabilidad y generalización: ablaciones por familia de características, importancia por permutación agrupada, curvas de fiabilidad y la curva de capacidad predictiva por turno.

I-F. Contribución esperada

Se esperan tres contribuciones. Primera, una caracterización de la probabilidad de victoria desde el estado de juego en un juego de cartas que no ha sido estudiado de esta forma, incluyendo el perfil por turno de la capacidad predictiva que Janusz *et al.* reportan para *Hearthstone* pero que no existe para el *PTCG*. Segunda, un protocolo de evaluación cuyos controles de fuga están medidos y no solo afirmados: la auditoría cuantifica la contaminación que produciría el protocolo ingenuo, de modo que el diseño agrupado se justifica con una cifra de este corpus y no por analogía. Tercera, una tubería reproducible y un diccionario de datos documentado para un corpus que hoy carece de descripción arbitrada, siguiendo la estructura que el descriptor SC2EGSet establece para datos de repeticiones de deportes electrónicos [3].

Un resultado negativo también sería una contribución. Si la discriminación colapsa bajo el protocolo temporal, eso constituye evidencia sobre la rapidez con que un metajuego invalida un evaluador de estados, que es la pregunta que Bertram *et al.* plantean para repertorios de cartas en cambio permanente [1].

I-G. Estructura del documento

La Sección II revisa la literatura a lo largo de tres ejes y cierra con el *baseline* de literatura y las brechas identificadas. La Sección III presenta la metodología propuesta. La Sección IV detalla el análisis técnico que exige el Track A. La Sección V discute las consideraciones éticas preliminares. La Sección VI declara el uso de herramientas de inteligencia artificial. La Sección VII cierra con el estado actual y los próximos pasos.

II. TRABAJOS RELACIONADOS

Esta revisión cubre los siete trabajos arbitrados asignados al autor bajo el Eje C (conjunto de datos, validación y cambio de distribución), que es el eje del que depende la validez de todo el estudio. Los candidatos se recuperaron de Scopus, IEEE Xplore, la ACM Digital Library y los registros de los editores de las revistas correspondientes, mediante cadenas de búsqueda que combinaron *win prediction*, *game state*, *collectible card game* y *esport*

replay dataset para el dominio, y *data leakage*, *grouped cross-validation*, *repeated measures* y *temporal dataset shift* para la metodología. Se examinaron nueve candidatos a texto completo y se retuvieron siete. La inclusión exigió venue arbitrado de revista o conferencia, un DOI que resolviera, y contenido que respaldara una decisión efectivamente tomada en este trabajo; las dos exclusiones están documentadas en el informe de selección del autor. Cinco de los siete se publicaron en 2021 o después. Los dos trabajos más antiguos se retienen deliberadamente: uno es la formulación canónica de la fuga de datos [6], el otro es la única competencia publicada de predicción de victoria desde el estado de juego en un juego de cartas coleccionables [2]. Esta es una revisión individual; el artículo conjunto de la Etapa 1 la fusionará con las revisiones de los Ejes A y B escritas por los otros dos integrantes del equipo, para un corpus combinado de al menos veintinueve trabajos.

II-A. Eje A: el problema y su dominio

¿Cómo se ha abordado este problema en la literatura? ¿Qué enfoques dominan? ¿Qué se considera resuelto y qué sigue abierto?

II-A1. Predicción del desenlace a partir de un único estado: La formulación dominante trata la predicción del desenlace como clasificación binaria supervisada sobre una instantánea de la posición, con la etiqueta tomada del resultado registrado de la partida completa. El AAAI'17 Data Mining Challenge lo enuncia exactamente en esos términos para *Hearthstone*: los participantes recibían la descripción de un estado de juego y entregaban la verosimilitud de que el jugador uno ganara, puntuada mediante el área bajo la curva ROC [2]. El descriptor SC2EGSet aplica el mismo encuadre a *StarCraft II*, derivando indicadores económicos de las repeticiones y clasificando el desenlace de la partida a partir de ellos [3]. Ninguna de las dos formulaciones requiere un simulador en el momento de la predicción, y ninguna trata la trayectoria como un problema de control; el estado es la entrada y el desenlace registrado es la etiqueta. Esta es la formulación que se adopta aquí.

Lo que ambos trabajos establecen es que la formulación es viable en juegos de esta familia y que la señal es sustancial. Lo que no establecen es que el nivel alcanzable se transfiera entre juegos. Los dos puntos de operación reportados difieren más entre sí que la diferencia entre métodos dentro de cualquiera de los dos estudios, y no están medidos en la misma escala: Janusz *et al.* reportan AUC sobre estados extraídos de partidas entre agentes que eligen sus acciones al azar, mientras que Bialecki *et al.* reportan acierto sobre características promediadas a lo largo de toda la partida. Un estudio sobre un tercer juego no puede heredar ninguna de las dos cifras como expectativa.

II-A2. Capacidad predictiva a lo largo de la partida: Un segundo tema, presente en ambos trabajos pero desarrollado por ninguno, es que la capacidad predictiva no es un escalár. Janusz *et al.* grafican el AUC sobre turnos consecutivos y muestran que crece a lo largo de la partida [2]; Bialecki *et al.* grafican el acierto sobre el tiempo de partida a intervalos de aproximadamente siete segundos y observan que sus tres

clasificadores alcanzan una asíntota alrededor de los 550 segundos, lo que interpretan como el punto en que los indicadores económicos dejan de aportar información adicional y otros factores toman el relevo [3]. Ambas curvas señalan el mismo punto metodológico: una única cifra agregada promedia un régimen en el que el estado dice poco con otro en el que lo dice casi todo. Ninguno de los dos trabajos reporta intervalos de confianza sobre esas curvas, y ninguno reporta cómo cambia su forma cuando cambia la población de jugadores.

II-A3. Generalización ante contenido cambiante: El tercer tema es que el contenido de estos juegos no se queda quieto. Bertram *et al.* lo abordan directamente para *Magic: The Gathering*, donde se publican conjuntos de cartas nuevos con regularidad, y evalúan reservando un conjunto de cartas completo. Sus resultados separan dos capacidades que una única puntuación dentro de la distribución confunde. Entrenada sobre un solo conjunto, una codificación *one-hot* de carta alcanza un 67.80 % de acierto *top-1* sobre datos reservados de ese mismo conjunto y no puede producir predicción alguna para cartas que nunca ha visto, mientras que una incrustación aleatoria de la misma dimensionalidad alcanza un 67.87 % dentro de la distribución y un 23.79 % fuera de ella, que es el acierto del azar para su tarea de elección [1]. Las representaciones construidas a partir de atributos de carta, metadatos y codificaciones de imagen alcanzan un 68.00 % dentro de la distribución y un 42.87 % sobre conjuntos no vistos; escalado a un corpus de 2990 cartas y unos 75 millones de decisiones, el mismo modelo alcanza un 55.44 % sobre el conjunto BRO, enteramente reservado [1]. La lección trasciende su tarea: una codificación del contenido basada en la identidad puede ser indistinguible de una semántica dentro de la distribución y no valer nada fuera de ella.

II-A4. Qué está resuelto y qué sigue abierto: Resuelto: la predicción del desenlace a partir de un estado intermedio es un problema supervisado bien planteado y tratable en juegos de cartas coleccionables y en juegos de estrategia en tiempo real; las características tabulares derivadas del estado transportan señal sustancial; y la capacidad predictiva varía sistemáticamente a lo largo de la partida. Abierto: si las probabilidades estimadas están calibradas y no meramente bien ordenadas; cómo se comporta el perfil por etapa bajo un cambio declarado en la población de jugadores o de mazos; y si algo de esto se sostiene en el *Pokémon TCG*, para el que no existe estudio publicado.

II-B. Eje B: técnicas del track seleccionado

¿Cuál es el estado actual de los métodos que pensamos utilizar, cuáles son sus fortalezas y límites, y bajo qué supuestos funcionan?

II-B1. El rendimiento marginal de la complejidad del modelo: La evidencia disponible aquí sostiene que los modelos tabulares clásicos son el instrumento adecuado para esta tarea, y lo hace con cifras y no con preferencias. En la competencia de *Hearthstone* se registraron 296 equipos y 188 enviaron solución; todos los equipos mejor clasificados usaron redes neuronales y el ganador usó redes convolucionales, y aun así la

puntuación ganadora de 0.8019 de AUC supera al *baseline* de los organizadores, 0.7846, una red totalmente conectada con dos capas ocultas entrenada sobre la representación tabular, por menos de un dos por ciento, y los organizadores lo hacen notar explícitamente [2]. La regresión logística aparece entre los enfoques que describen como simples y no obstante eficaces. En SC2EGSet, tres clasificadores convencionales con hiperparámetros iniciales típicos quedan a menos de 0.016 de acierto unos de otros en la tarea de dos jugadores: máquina de vectores de soporte con núcleo RBF en 0.9071, XGBoost en 0.8924 y regresión logística en 0.8916 [3]. Dos estudios independientes sobre dos juegos distintos coinciden, por tanto, en que la mayor parte de la señal extraíble de una representación tabular del estado de juego es alcanzable sin arquitecturas profundas, y en que el residuo es lo bastante pequeño como para que la interpretabilidad y el costo dominen la elección.

Una tercera fuente afina el argumento en dirección a los modelos más simples. Karbalaie *et al.* compararon diez clasificadores y encontraron que los modelos lineales fueron los más honestos bajo validación consciente del participante: la regresión logística y el análisis discriminante lineal difirieron a lo sumo en 0.03 de acierto entre el protocolo contaminado y el correcto, y mostraron brechas entre entrenamiento y prueba de aproximadamente 0.08, mientras que los *ensembles*, *extra trees*, *random forest*, *gradient boosting*, mostraron brechas de al menos 0.34 y fueron los modelos cuyas puntuaciones más infló el protocolo defectuoso [5]. Los modelos de alta capacidad no son solo más difíciles de interpretar: son los modelos a los que un protocolo defectuoso favorece. Ese es un argumento para mantener un modelo lineal regularizado en la comparación como punto de referencia, y no solo por formalidad.

II-B2. Validación cuando las observaciones no son independientes: El supuesto que estos métodos comparten es que las muestras son independientes, y es exactamente el supuesto que este corpus viola. Karbalaie *et al.* cuantifican la consecuencia sobre 623 ensayos de 72 participantes: la validación cruzada estratificada de diez pliegues da un acierto de 0.91 para *extra trees*, y el mismo modelo bajo validación dejando un participante fuera da 0.66 [5]. Su explicación es la que se transfiere: en datos de medidas repetidas el tamaño muestral efectivo se aproxima al número de participantes, no al número de ensayos. Sustituir participante por episodio e instantánea por ensayo enuncia la restricción que gobierna el presente trabajo. Reportan además que la validación cruzada agrupada de k pliegues coincide con el diseño anidado y con dejar uno fuera dentro de 0.02 de acierto a un costo mucho menor, lo que importa cuando la unidad de agrupación se cuenta en decenas de miles. **Brecha de dominio, declarada explícitamente:** se trata de un estudio de biomecánica, y se cita por su argumento estadístico sobre observaciones dependientes, no como resultado del dominio de juegos.

II-B3. La fuga de datos como objeto formal: Kaufman *et al.* aportan el marco que vuelve verificables, y no meramente intuitivas, esas decisiones. Definen la fuga de datos (*data leakage*) como una propiedad intrínseca de la relación entre las entradas observacionales de un modelo y la instancia objetivo:

una característica es legítima solo si es observable para el propósito de inferir ese objetivo en particular, evaluada instancia por instancia. Dos consecuencias gobiernan nuestro diseño. La primera es el *requisito de la no máquina del tiempo*: un modelo legítimo solo puede usar información de un instante no posterior al del objetivo. La segunda es la *separación aprender–predecir*, la metodología de evitación en la que cada observación se etiqueta con la información necesaria para decidir su legitimidad y el conjunto de entrenamiento se construye después de modo que solo entren entradas legítimas [6]. Advierten además que la fuga entra por las decisiones de diseño, diseño de características, selección de modelo, elección de hiperparámetros informada por conocimiento que el modelo desplegado no tendría, a la que llaman la forma más peligrosa, porque un evaluador no puede detectarla ni siquiera buscándola, y señalan que eliminar las fugas evidentes puede no sellar el resto.

Sasse *et al.* actualizan ese marco convirtiéndolo en un catálogo de escenarios que los profesionales encuentran realmente, organizado como fuga de prueba a entrenamiento, de prueba a prueba, de característica a objetivo, de objetivo, de conjunto de datos y de variables de confusión [8]. Tres de sus entradas se corresponden directamente con decisiones de este trabajo. Su tratamiento de la fuga de prueba a entrenamiento enumera el no tener en cuenta muestras dependientes como causa primaria y lo demuestra sobre pares de hermanos en una cohorte de neuroimagen, donde permitir que familiares caigan a ambos lados de la partición eleva el acierto medido. Su caso de preprocesamiento establece que el escalado, la imputación, la reducción de dimensionalidad y el sobremuestreo estimados sobre el conjunto completo antes de particionar constituyen por sí mismos fuga de datos, razón por la cual cualquier corrección de balance de clases en este trabajo debe ajustarse dentro del pliegue de entrenamiento. Su categoría de característica a objetivo cubre el caso que aquí más importa: variables informativas y disponibles durante el aprendizaje pero ausentes en el despliegue. Su prescripción es una pregunta antes que una regla, comprobar si cada característica estaría disponible tras el despliegue, y es la pregunta que aplicamos campo por campo en la Sección IV-G.

II-B4. Justificación técnica del Track A: El Track A se elige por la fuerza de esa evidencia y no por descarte. El corpus de repeticiones se reduce de forma natural a una tabla de ancho fijo con campos numéricos, binarios y categóricos, que es el régimen en el que los dos estudios del dominio de juegos citados arriba muestran una paridad casi total entre modelos clásicos y profundos. La pregunta científica es cuáles características del estado transportan información sobre la victoria, lo que exige modelos cuyas atribuciones puedan inspeccionarse. Y el riesgo dominante es de protocolo y no de capacidad: la contaminación medida de una partición a nivel de fila hace que sea el diseño de la partición, y no la arquitectura, la variable que determina si un resultado tiene significado. Un modelo secuencial profundo sobre la trayectoria, la alternativa natural del Track B, respondería una pregunta distinta y más amplia, heredando todos los riesgos de fuga y ninguna de las ventajas de interpretabilidad. El aprendizaje por refuerzo, la

lectura natural de un corpus de episodios, se descarta porque el objeto de estudio es la función de valor de forma aislada, aprendida *offline* a partir de desenlaces registrados, y no una política.

II-C. Eje C: conjunto de datos y conjuntos análogos

¿Qué trabajos han utilizado el conjunto de datos, bajo qué protocolo, cuál es el mejor resultado publicado y qué problemas presenta?

II-C1. Sin literatura previa sobre este corpus: No localizamos ninguna publicación arbitrada que utilice los episodios del PTCG AI Battle Challenge [4]. El corpus se publicó en 2026 y está ligado a una competencia todavía en curso. De acuerdo con el enunciado del curso, el eje se cubre por tanto con conjuntos de datos análogos del mismo dominio, y la sustitución se argumenta en lugar de darse por supuesta.

II-C2. Por qué los análogos son comparables, y dónde no lo son: SC2EGSet es el análogo estructural más cercano: un corpus de repeticiones competitivas de un juego de dos jugadores, procesado en registros de estado de juego por partida, publicado junto con sus herramientas de extracción y acompañado de experimentos de predicción de victoria sobre características tabulares [3]. Comparte la forma de la tubería, repetición cruda, estado analizado, características tabulares, etiqueta supervisada de desenlace, y el hecho de que los datos fueron producidos por competencia y no por experimento. Difiere en género, en tanto *StarCraft II* es un juego de estrategia en tiempo real con tiempo continuo y no un juego de cartas por turnos con recursos discretos, y difiere en unidad de observación, puesto que sus modelos consumen agregados por partida y no estados instantáneos. El conjunto de datos de la competencia de *Hearthstone* es el análogo más cercano en género: un juego de cartas coleccionables con mazos, mano, tablero e información oculta, cuya tarea es precisamente la predicción del ganador a partir de un estado intermedio [2]. Difiere en la calidad de los agentes que lo generaron y en que sus estados fueron publicados por los organizadores en formato tabular y JSON crudo en lugar de ser analizados por quien modela. El corpus de *drafting* de *Magic: The Gathering* es análogo solo en el sentido estrecho que importa para una de nuestras decisiones: es un juego de cartas coleccionables cuyo contenido cambia con el tiempo y cuya evaluación reserva contenido no visto [1]. Su tarea es predecir una elección humana de carta, no un desenlace de partida, y no debe leerse como un resultado de predicción de victoria.

II-C3. Problemas documentados de los corpus comparables: Los problemas que estos autores declaran son los problemas que deberíamos esperar. Bialecki *et al.* afirman que su corpus contiene únicamente repeticiones de nivel de torneo y que, en consecuencia, “no existe posibilidad de realizar análisis más generales que tomen en consideración a personas de distintos niveles de habilidad”; que los cambios del juego a lo largo del tiempo hacen que algunos campos de datos tomen valor cero, de modo que la representación del juego cambió con el tiempo; que la completitud dependió de qué organizadores de torneo decidieron publicar; y que deliberadamente no filtraron

repeticiones terminadas de forma prematura, con el fin de preservar las distribuciones originales [3]. Cada uno de esos puntos tiene su contraparte en nuestro corpus: los episodios se seleccionan por puntuación media de los agentes y se truncan a un tope diario de volumen; seis versiones del motor coexisten en la muestra auditada; y los episodios abandonados están presentes y son identificables.

Janusz *et al.* documentan dos problemas propios. Sus estados provenían de partidas entre agentes que elegían sus decisiones dentro del juego al azar, lo que constituye una población específica y no representativa; y se detectó una fuga de datos involuntaria durante las primeras semanas de la competencia, que obligó a los organizadores a mover 1 250 000 casos del conjunto de prueba al de entrenamiento [2]. Vale la pena enunciar lo segundo con claridad: un incidente de fuga dentro de una competencia organizada profesionalmente sobre exactamente esta tarea es la evidencia más fuerte disponible de que el riesgo es real y no hipotético.

II-C4. Cambio de distribución y qué daña primero: Su respuesta parcial al problema de la población es también el resultado de generalización más útil del que disponemos. Habiendo entrenado sobre estados de juego aleatorio, construyeron un segundo corpus de 28 604 partidas y 814 407 estados generados por agentes fuertes de búsqueda en árbol Monte Carlo que realizaban 15 000 simulaciones por acción, y observaron que el AUC total caía solo de aproximadamente 0.79 a aproximadamente 0.75 al evaluar sobre esa población desplazada [2]. Un cambio en la calidad de los agentes que generan los estados cuesta, por tanto, algo, pero mucho menos de lo que podría temerse.

Lo que ese experimento no mide es la calibración, y la evidencia sistemática indica que esa es la magnitud en mayor riesgo. Guo *et al.* examinaron 4 457 referencias y retuvieron quince estudios que cuantificaban el cambio temporal del conjunto de datos e implementaban alguna mitigación. Los once estudios que evaluaron calibración reportaron deterioro de la calibración, mientras que solo tres de los doce que evaluaron discriminación reportaron deterioro de la discriminación; los tres que lo hicieron eran estudios de un solo centro, mientras que los nueve que no reportaron deterioro eran multicéntricos [7]. Su inventario de mitigaciones está dominado por el reajuste del modelo ($n = 12$), la calibración de probabilidades ($n = 7$), la actualización del modelo ($n = 6$) y la selección de modelo ($n = 6$), frente a solo dos enfoques a nivel de características, y su síntesis es que todas esas estrategias preservaron la calibración pero ninguna preservó uniformemente la discriminación. Aportan además el vocabulario que este trabajo necesita, distinguiendo el cambio de covariables ($P_{\text{ent}}(x) \neq P_{\text{prueba}}(x)$ con $P_{\text{ent}}(y|x) = P_{\text{prueba}}(y|x)$) del cambio de concepto ($P_{\text{ent}}(y|x) \neq P_{\text{prueba}}(y|x)$ con $P_{\text{ent}}(x) = P_{\text{prueba}}(x)$), y señalando que ambos pueden coexistir. **Brecha de dominio, declarada explícitamente:** se trata de predicción clínica, citada por la asimetría que mide y por la terminología que estandariza, no como hallazgo del dominio de juegos. Sus propias limitaciones declaradas, un barrido incompleto de actas de congresos, modelos desplega-

dos no publicados y la ausencia de tratamiento del cambio geográfico, no afectan a ninguno de los dos usos.

II-D. Análisis comparativo

De la Tabla I emergen tres patrones. El primero es una división de métricas que bloquea la comparación directa: los dos estudios sobre estados de juego reportan escalares distintos, AUC en un caso y acierto en el otro, y ninguno reporta una regla de puntuación propia ni una curva de fiabilidad. Cualquier afirmación de que uno de estos sistemas está mejor calibrado que otro carecería de respaldo, porque ninguno lo midió. El segundo es que los estudios que miden generalización bajo cambio la miden contra cosas diferentes, calidad de los agentes [2], conjuntos de cartas no vistos [1], identidad del participante [5], tiempo calendario [7], y que las degradaciones reportadas son en todos los casos lo bastante grandes como para importar: $0.79 \rightarrow 0.75$ de AUC, $67.20\% \rightarrow 55.44\%$ de acierto, $0.91 \rightarrow 0.66$ de acierto. Una única cifra dentro de la distribución es la magnitud menos informativa que reporta cualquiera de estos trabajos.

El tercer patrón es una limitación recurrente antes que una tendencia. En todas las entradas empíricas, la unidad de observación es menor que la unidad que realmente es independiente, y los trabajos difieren en si actúan en consecuencia. Janusz *et al.* separan entrenamiento y prueba a nivel de partidas completas, de modo que su protocolo está agrupado aunque no lo formulen así. Karbalaie *et al.* convierten la agrupación en el objeto de estudio. Bialecki *et al.* reportan validación cruzada de cinco pliegues sobre 22 230 muestras promediadas derivadas de 11 115 partidas únicas, dos filas por partida, una por jugador, sin describir restricción alguna de agrupación a nivel de partida. **Esta es una inferencia nuestra, no una afirmación de los autores:** si esos pliegues se extrajeron a nivel de fila, ambas filas de una partida podrían caer a lados opuestos de una partición, y sus aciertos reportados serían optimistas en una cantidad desconocida. Lo señalamos como salvedad de comparabilidad y no como error, puesto que el artículo no declara el particionador que utilizó.

Una cuarta observación concierne al peso de la evidencia. Dos de los siete trabajos son referencias metodológicas sin conjunto de datos ni métrica propios [6], [8]; sus celdas se marcan como no aplicables en lugar de rellenarse con un valor plausible. Forzar números en esas filas tergiversaría lo que esos trabajos son.

II-E. Baseline de literatura

No existe resultado publicado sobre el corpus objetivo, de modo que el *baseline* se toma del trabajo análogo cuya tarea, unidad de observación y métrica son las más cercanas a las nuestras.

Objetivo de referencia: ROC-AUC en la banda 0.78–0.80, proveniente del AAIA'17 Data Mining Challenge sobre *Hearthstone*. Tarea: predecir el ganador a partir de un único estado de juego. Unidad de observación: un estado de juego. Métrica: área bajo la curva ROC. *Baseline* oficial de los organizadores:

Tabla I

RESUMEN COMPARATIVO DE LOS SIETE TRABAJOS REVISADOS. LAS FILAS SE ORDENAN POR PROXIMIDAD A NUESTRA TAREA. LOS VALORES ESTÁN TRANSCRITOS DE LA FUENTE; “N/A” MARCA UN CAMPO QUE EL TRABAJO NO POSEE, NO UN CAMPO QUE NO HAYAMOS PODIDO ENCONTRAR.

Referencia	Año	Técnica	Conjunto de datos / entorno	Métrica principal	Resultado reportado	Limitación identificada
[2]	2017	Competencia: <i>ensembles</i> de CNN y ANN, XGBoost, regresión logística; el <i>baseline</i> de los organizadores es una red totalmente conectada de 2 capas ocultas sobre datos tabulares	Estados de juego de <i>Hearthstone</i> ; 3.25 M de estados de entrenamiento provenientes de $\approx 65\,000$ partidas, 750 000 estados de prueba provenientes de $>180\,000$ partidas; 9 mazos en entrenamiento frente a 27 en prueba	ROC-AUC	0.7846 el <i>baseline</i> ; 0.8019 la mejor solución; brecha $< 2\%$. Transferencia a estados de agentes MCTS: $\approx 0.79 \rightarrow \approx 0.75$	Estados generados por agentes que eligen acciones al azar, una población no representativa; no se reporta calibración; se detectó una fuga involuntaria a mitad de competencia que obligó a pasar 1.25 M de casos de prueba al conjunto de entrenamiento
[3]	2023	Regresión logística, SVM (RBF) y XGBoost con hiperparámetros próximos a los predeterminados; validación cruzada de 5 pliegues	SC2EGSet: 55 paquetes de repeticiones de torneos de <i>StarCraft II</i> ; 11 115 partidas únicas reducidas a 22 230 muestras promediadas; 17 características económicas seleccionadas	Acierto	0.9071 con dos jugadores (SVM-RBF), 0.8924 XGBoost, 0.8916 regresión logística; 0.8488 con un jugador	Solo jugadores de nivel de torneo, por lo que no admite análisis entre niveles de habilidad; los autores llaman a sus experimentos “más ilustrativos que investigativos”; campos puestos a cero conforme el juego cambió; no se describe agrupación por partida para los pliegues
[1]	2024	Redes siamesas bajo ordenamiento contextual de preferencias, sobre representaciones generalizadas de carta (atributos, metadatos, imágenes autocodificadas)	Elecciones de <i>draft</i> de <i>Magic: The Gathering</i> ; ≈ 100 M de elecciones en 14 conjuntos de cartas; un conjunto completo reservado	Acierto <i>top-1</i>	67.20 % sobre conjuntos vistos frente a 55.44 % sobre el conjunto no visto; la codificación <i>one-hot</i> queda indefinida sobre cartas no vistas; la incrustación aleatoria da 23.79 % fuera de la distribución	La tarea es predecir una elección humana de carta y no un desenlace de partida, por lo que solo es análoga en cuanto a generalización de contenido; las elecciones humanas no son ni correctas ni consistentes, lo que acota el acierto alcanzable; el ajuste fino sobre un conjunto degrada los demás
[5]	2026	Diez clasificadores comparados bajo cuatro diseños de validación: estratificada de 10 pliegues, dejando un participante fuera, agrupada de 3 pliegues y anidada (dejando uno fuera + bucle interno agrupado)	623 ensayos de salto de 72 participantes tras reconstrucción de ligamento cruzado anterior; 624 características extraídas reducidas a un <i>top-10</i> fijo	Acierto, brecha entrenamiento-prueba, estabilidad de rangos	<i>Extra trees</i> 0.91 bajo estratificada de 10 pliegues frente a 0.66 dejando un participante fuera; los modelos lineales difieren ≤ 0.03 ; la anidada coincide con dejar uno fuera dentro de 0.02	Dominio de biomecánica, citado por su argumento estadístico y no como resultado del dominio de juegos; una única tarea binaria sobre 72 participantes; calibración y atribución de características explícitamente fuera de alcance

Tabla I
RESUMEN COMPARATIVO DE LOS SIETE TRABAJOS REVISADOS (CONTINUACIÓN).

Referencia	Año	Técnica	Conjunto de datos / entorno	Métrica principal	Resultado reportado	Limitación identificada
[7]	2021	Revisión sistemática (PRISMA) de estrategias de mitigación: reajuste del modelo ($n=12$), calibración de probabilidades ($n=7$), actualización del modelo ($n=6$), selección de modelo ($n=6$)	15 estudios de predicción clínica retenidos de 4 457 referencias examinadas; regresión logística usada en 13 de 15	Cambio en calibración y en discriminación	Deterioro de calibración en 11 de los 11 estudios que la midieron; deterioro de discriminación en solo 3 de 12	Dominio clínico, citado por la asimetría medida y por la terminología del cambio de distribución; no se realizó metaanálisis; cobertura incompleta de actas de congresos; no se examinó el cambio geográfico
[8]	2025	Catálogo de escenarios de fuga: de prueba a entrenamiento, de prueba a prueba, de característica a objetivo, de objetivo, decaimiento del conjunto de datos y de variables de confusión, con demostraciones ilustrativas	n/a — artículo de revisión; las demostraciones usan una cohorte de neuroimagen, sin corpus de referencia propio	n/a — sin métrica principal única	n/a — los efectos se muestran gráficamente por escenario en lugar de tabularse como una cifra única	Es un catálogo y no una comparación cuantitativa, por lo que establece qué fallos existen pero no su magnitud relativa; las demostraciones se limitan a un solo tipo de dato
[6]	2011	Definición formal de la fuga mediante la legitimidad de las entradas observacionales; evitación por etiquetado de legitimidad y separación aprender—predecir; detección por análisis exploratorio, análisis posterior y prueba temprana en campo	n/a — trabajo metodológico; ilustrado con competencias publicadas de minería de datos	n/a	n/a — no se reporta experimento alguno	Sin evaluación empírica de la metodología propuesta; los autores afirman que los intentos de reparar la fuga a posteriori suelen ser incompletos y pueden empeorar la situación

0.7846, obtenido por una red totalmente conectada con dos capas ocultas sobre la representación tabular, que quedó en el puesto 94. Mejor solución enviada: 0.8019, un *ensemble* construido sobre redes convolucionales. Protocolo: 3 250 000 estados de entrenamiento provenientes de aproximadamente 65 000 partidas frente a 750 000 estados de prueba provenientes de más de 180 000 partidas distintas, con 9 mazos en entrenamiento y 27 en prueba, de modo que el conjunto de prueba contiene cartas nunca vistas en entrenamiento; puntuaciones preliminares sobre un 5 % aleatorio fijo del conjunto de prueba y

puntuaciones finales sobre el resto [2].

Qué pretende hacer este trabajo con esa cifra. El objetivo operativo es que el modelo clásico más fuerte alcance esa banda de 0.78–0.80 de AUC bajo nuestro propio protocolo primario en la ventana tardía de la partida, y establecer en qué punto de la partida se alcanza por primera vez esa banda. No afirmamos que superaremos 0.8019, porque las dos cifras no están medidas sobre el mismo objeto.

Diferencias de protocolo que impiden una comparación justa.

- **Juego distinto.** *Hearthstone* y el *Pokémon TCG* difieren en sistemas de recursos, condiciones de victoria y estructura de

tablero, de modo que el contenido informativo de un estado no es la misma magnitud.

- **Población de agentes distinta.** Sus estados provienen de agentes que actúan al azar; los nuestros, de agentes que compiten y son seleccionados por puntuación. Su propio experimento de transferencia muestra que esto importa, y cuesta aproximadamente 0.04 de AUC en la dirección de agentes aleatorios a agentes fuertes [2].
- **Partición distinta.** Su separación es por partida y por mazo entre dos conjuntos fijos; la nuestra es una partición agrupada por episodio, con protocolos adicionales temporal y de reserva de mazos.
- **Prevalencia de clases distinta.** Su conjunto de entrenamiento tiene 50.46 % de victorias y el de prueba 57.27 %, de modo que las dos mitades de su propio banco de pruebas no provienen de la misma distribución [2].
- **Descripción del estado distinta.** Su representación tabular fue suministrada por los organizadores, y las mejores participaciones reconstruyeron características a partir del JSON crudo; nuestro conjunto de características lo construimos nosotros y está restringido por una lista negra de fuga.

Se dispone de un segundo anclaje, más débil. SC2EGSet reporta 0.9071 de acierto en predicción de victoria con dos jugadores y 0.8488 con un solo jugador [3]. Se registra aquí por completitud y no se adopta como objetivo: la métrica es acierto y no AUC, la unidad es una partida completa y no un instante, las características son promedios sobre la partida, y la cuestión de la agrupación planteada en la Sección II-D queda sin resolver.

II-F. Brechas identificadas

Brechas encontradas en la literatura.

1. **Ningún trabajo arbitrado utiliza este corpus.** Los episodios del PTCG AI Battle Challenge no tienen descripción publicada, ni diccionario de datos documentado, ni *baseline* reportado.
2. **La tarea no se ha estudiado en el *Pokémon TCG*.** La predicción de victoria desde el estado de juego está establecida en *Hearthstone* [2] y en *StarCraft II* [3], pero no en un juego cuya estructura de recursos se apoya en cartas de premio, asignación de energía, banca y evolución.
3. **Se reporta discriminación sin calibración.** Ninguno de los dos estudios sobre estados de juego reporta una regla de puntuación propia ni una curva de fiabilidad [2], [3], y Karbalaie *et al.* colocan explícitamente la calibración fuera de su alcance y la recomiendan como trabajo futuro [5]. Guo *et al.* muestran que esta es la magnitud que se degrada primero [7]. Un modelo pensado como evaluador de posiciones está siendo validado, por tanto, sobre la propiedad equivocada.
4. **La evaluación agrupada se aplica de forma inconsistente en corpus de estados de juego.** El costo medido de ignorar la dependencia solo está disponible desde otros campos [5], [8]; dentro de los conjuntos de datos de juegos la restricción unas veces se satisface sin ser nombrada [2] y otras queda sin describir [3].

5. **La generalización rara vez se evalúa bajo un cambio declarado.** Cuando se hace, la degradación es sustancial [1], [2], y la evidencia sistemática encuentra solo quince estudios que a la vez cuantifiquen el cambio temporal y actúen sobre él [7].

Brechas que este trabajo aborda. Las brechas 2 a 5. La 2, planteando la tarea en el *Pokémon TCG* por primera vez y reportando el perfil por turno de la capacidad predictiva. La 3, reportando *log loss*, *Brier score* y curvas de fiabilidad junto al ROC-AUC, y poniendo a prueba la hipótesis H3 de forma explícita. La 4, agrupando por *episode_id* toda partición, todo intervalo de confianza y todo pliegue de validación cruzada, y reportando la contaminación medida que produciría la alternativa ingenua. La 5, evaluando bajo tres cambios declarados, episodios no vistos, mazos no vistos y periodos temporales posteriores, y reportando cada uno por separado en lugar de promediarlos.

Brechas fuera de alcance. La brecha 1 se documenta, no se cierra: un proyecto de un semestre no puede establecer una referencia arbitrada para el corpus, y este trabajo no pretende serlo. La comparabilidad estricta con el banco de pruebas de *Hearthstone* también queda fuera de alcance, por las razones enumeradas en la Sección II-E; las diferencias son estructurales y no pueden eliminarse reejecutando ninguno de los dos experimentos. Más allá de estas, no intentamos construir un agente competitivo, aprender una política, separar la deriva del metajuego del cambio de versión del motor, la muestra auditada confunde ambas causas, ni generalizar ningún hallazgo a jugadores humanos.

III. METODOLOGÍA PROPUESTA

Esta sección describe lo que proponemos hacer. No se ha entrenado ningún modelo y ningún resultado aquí reportado es empírico; las únicas magnitudes medidas que aparecen son propiedades del corpus, establecidas por la auditoría que se describe en la Sección IV.

III-A. Formalización del problema

Sea $\mathcal{E}$ el conjunto de episodios, cada uno una partida completa entre dos agentes. Un episodio $e \in \mathcal{E}$ produce una secuencia ordenada de estados; de ella retenemos la subsecuencia de estados *frescos* del asiento que actúa, indexada por t . Cada estado retenido produce una observación

$$(x_i, y_i, g_i, \tau_i, d_i),$$

donde $x_i \in \mathcal{X} \subseteq \mathbb{R}^p$ es el vector de características construido a partir de la observación disponible para el asiento activo en ese instante, $y_i \in \{0, 1\}$ indica si el jugador desde cuya perspectiva se construyó la fila ganó el episodio, $g_i \in \mathcal{G}$ es el identificador del episodio, $\tau_i \in \mathbb{N}$ es el índice de turno y d_i la fecha de calendario. Los tres últimos campos se arrastran para agrupación, estratificación y análisis; por construcción, nunca son componentes de x_i .

La tarea es clasificación binaria probabilística: aprender $f : \mathcal{X} \rightarrow [0, 1]$ tal que $f(x) \approx P(y = 1 \mid x)$. Puesto que la salida es una probabilidad y no una etiqueta, el objetivo

```

repetición JSON
| validación de esquema (firma de nivel
  superior, schema_version)
| selección de estados frescos del asiento
  activo
| proyección a la perspectiva del jugador
  activo (propio / rival)
| filtro de lista negra → falla la
  construcción si un campo prohibido llega al
  vector de características
| ingeniería de características (familias
  M0-M4)
↓
tabla: una fila por instantánea, más
  episode_id, date y turn (solo agrupación)
| partición agrupada por episode_id →
  entrenamiento / validación / prueba
| ajuste del preprocesamiento SOLO sobre el
  pliegue de entrenamiento
↓
escalera de modelos B0-B4 → métricas por
  ventana de turno, más intervalos de confianza
  bootstrap sobre episodios

```

Figura 1. Tubería propuesta, de la repetición cruda al modelo evaluado. El filtro de lista negra y la partición agrupada se imponen mediante pruebas automatizadas, no por convención.

de entrenamiento es una regla de puntuación propia, la log-verosimilitud negativa regularizada:

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \left\{ -\frac{1}{N} \sum_{i=1}^N [y_i \log f(x_i) + (1 - y_i) \log (1 - f(x_i))] + \lambda \Omega(f) \right\}, \quad (1)$$

con Ω la penalización de complejidad de la familia de modelos $\mathcal{F}$ y λ seleccionado sobre datos de validación. Minimizar una regla de puntuación propia en lugar de una pérdida de clasificación es una elección deliberada: es el objetivo cuyo óptimo es la probabilidad condicional verdadera, y la calibración es una de las propiedades que este trabajo se propone medir.

Dos restricciones completan la formulación. La primera es la condición de legitimidad de Kaufman *et al.*: todo componente de x_i debe ser observable para el propósito de inferir y_i , evaluado instancia por instancia, y en particular no puede depender de información generada después del turno τ_i [6]. La segunda es una restricción de partición. Para cualesquiera dos partes A y B de una división,

$$\{g_i : i \in A\} \cap \{g_i : i \in B\} = \emptyset, \quad (2)$$

de modo que ningún episodio aporte filas a más de una parte. La restricción (2) es el enunciado formal del argumento del tamaño muestral efectivo de Karbalaie *et al.*: la unidad independiente es el episodio, no la fila [5].

III-B. Tubería propuesta

La Fig. 1 resume el flujo previsto. Dos decisiones de diseño merecen justificación. Primera, la perspectiva de cada fila se normaliza a *propio* frente a *rival* usando el índice de asiento,

de modo que el modelo aprenda relaciones entre magnitudes y no la identidad de un asiento; la auditoría encontró que asiento y orden de turno están casi perfectamente confundidos en los días tardíos, lo que de otro modo convertiría la identidad del asiento en un atajo atractivo. Segunda, los parámetros de preprocesamiento, escalado, codificación de variables categóricas, cualquier imputación, cualquier ponderación de clases, se estiman dentro del pliegue de entrenamiento y después se aplican a los datos reservados. Sasse *et al.* clasifican la alternativa, estimarlos sobre el conjunto completo antes de particionar, como fuga de prueba a entrenamiento, aunque el modelo en sí se ajuste después de la partición [8].

III-C. Protocolo experimental

III-C1. Partición de los datos: El protocolo primario es una partición 70/15/15 *agrupada por episodio*, que satisface (2). La alternativa, una partición aleatoria sobre filas, se rechaza sobre bases medidas y no de principio: en la muestra auditada, una partición aleatoria 70/30 de instantáneas colocaría el 99.9945 % de los episodios a ambos lados simultáneamente. Se proponen dos protocolos secundarios. Un protocolo temporal entrena sobre los días auditados más tempranos, valida sobre los días intermedios y prueba sobre los más tardíos, implementando la separación aprender–predecir que Kaufman *et al.* describen como predicción sobre el futuro [6]. Un protocolo de reserva de mazos aparta mazos completos o pares de mazos para el conjunto de prueba, que es el diseño que Bertram *et al.* emplean para separar la memorización de contenido conocido de la comprensión del contenido [1]. Los tres responden preguntas distintas y se reportan por separado, nunca promediados.

III-C2. Estrategia de validación: Los hiperparámetros se seleccionan con validación cruzada agrupada de k pliegues sobre la partición de entrenamiento, tomando el episodio como clave de agrupación; la partición de prueba se toca una sola vez, al final. Karbalaie *et al.* reportan que la validación cruzada agrupada de k pliegues coincide con el diseño de dejar un grupo fuera, mucho más costoso, dentro de 0.02 de acierto y a un costo un orden de magnitud menor, lo que resulta decisivo cuando la unidad de agrupación se cuenta en decenas de miles [5]. Se prefiere un diseño plenamente anidado allá donde el presupuesto computacional lo permita, puesto que tanto Karbalaie *et al.* como Sasse *et al.* identifican el sesgo de selección como una fuga residual cuando los mismos pliegues sirven para ajustar y para evaluar [5], [8].

III-C3. Métricas: Cada métrica se incluye porque responde una pregunta que las demás no pueden responder; la Tabla II indica cuál.

ROC-AUC es la métrica principal por tres razones: el objetivo está cercano al equilibrio a nivel de episodio, de modo que el acierto sería poco informativo antes que engañoso; la métrica no exige comprometerse con un umbral, y en esta etapa no hay definido ningún costo de decisión; y es la única métrica sobre la que existe una cifra publicada análoga. Si la distribución de clases de la tabla final resultara marcadamente desbalanceada, una magnitud aún no medida, puesto que depende de cuántas instantáneas aporta cada bando, se añadirá PR-AUC, con

Tabla II
MÉTRICAS DE EVALUACIÓN Y SU JUSTIFICACIÓN.

Métrica	Pregunta que responde, y por qué no basta por sí sola
ROC-AUC (principal)	¿Ordena el modelo correctamente dos posiciones? Es independiente del umbral y robusta ante desbalance moderado, y es la métrica de la única tarea publicada comparable [2]. No dice nada sobre si la probabilidad es correcta.
Log loss	¿Es exacta la probabilidad en sí misma? Es el objetivo de entrenamiento (1), de modo que reportarla muestra además si la optimización tuvo éxito.
Brier score	¿Cuál es el error cuadrático de la probabilidad, y cómo se descompone en calibración y refinamiento?
Curva de fiabilidad y error de calibración	Entre las posiciones a las que el modelo asigna un 70 %, ¿gana efectivamente el 70 %? Es la propiedad que Guo <i>et al.</i> encuentran que se degrada primero bajo cambio temporal [7] y que ninguno de los dos estudios comparables sobre estados de juego reporta [2], [3].
Acierto, precisión, exhaustividad y F1	Se reportan solo una vez fijado y justificado un umbral, para comparabilidad con trabajos que reportan acierto [3]. Insuficientes por sí solas: un modelo puede acertar la clase y estar sistemáticamente sobreconfiado.

la clase minoritaria declarada explícitamente. Cada métrica se reporta de forma global y por ventana de turno, y todo intervalo de confianza se obtiene por remuestreo *bootstrap sobre episodios*, nunca sobre filas, por la misma razón que gobierna (2).

III-C4. Prevención de la fuga de datos: Los vectores de fuga y sus contramedidas se enumeran en la Sección IV-G, donde cada uno se empareja con la evidencia de auditoría que lo establece como riesgo concreto y no hipotético. El mecanismo es una lista negra explícita más una prueba automatizada que hace fallar la construcción si una columna prohibida alcanza la matriz de características, que es la forma operativa de la separación aprender–predecir [6].

III-D. Plan de baselines

Cada peldaño de la escalera se justifica por lo que el anterior dejó sin explicar.

1. **B0 — baseline trivial.** Un clasificador de probabilidad a priori. Fija el suelo; lo que quede por debajo es ruido.
2. **B1 — heurística de dominio.** Una regla única sobre una diferencia de recursos, definida tras el análisis exploratorio. Responde si hace falta aprendizaje automático en absoluto.
3. **B2 — regresión logística regularizada.** ¿Es la relación esencialmente lineal? Aporta coeficientes inspeccionables y probabilidades que pueden calibrarse. Es además el modelo que la evidencia revisada trata como referencia honesta: fue el algoritmo más común en los quince estudios clínicos de cambio temporal [7], quedó a 0.016 de acierto del mejor modelo en SC2EGSet [3], y estuvo entre los menos inflados por un protocolo defectuoso en el banco de pruebas de validación [5].
4. **B3 — árbol de decisión y random forest.** ¿Existen interacciones y no linealidades que el modelo lineal pierde?
5. **B4 — gradient boosting (XGBoost, LightGBM o CatBoost),** incluido solo si B3 muestra que el margen lo justifica.

¿Cuánto compra la complejidad, y a qué costo de interpretabilidad? La evidencia revisada fija una expectativa baja sobre la respuesta: la mejor solución de *Hearthstone* superó al *baseline* de una red de dos capas por menos de un dos por ciento de AUC [2].

6. **Baseline de literatura.** La banda de 0.78–0.80 de AUC declarada en la Sección II-E, con sus límites declarados de comparabilidad.

Las ablaciones por familia de características, progreso, recursos, tablero, energía y contexto de mazo, se ejecutan bajo el mismo protocolo, de modo que la contribución marginal de cada bloque se mida en lugar de afirmarse. Una ganancia grande del bloque de contexto de mazo se interpreta como evidencia de memorización del metajuego y no de comprensión, que es la lectura que Bertram *et al.* justifican: una representación que identifica el contenido en lugar de describirlo puede ser excelente dentro de la distribución e inútil fuera de ella [1].

III-E. Plan de explicabilidad

La contribución no puede ser una puntuación de titular; la pregunta sustantiva es cuáles características del estado transportan información sobre la victoria. Se proponen cuatro instrumentos, cada uno ligado a una pregunta. Los coeficientes de la regresión logística responden si la asociación de una característica con la victoria tiene la dirección que el conocimiento del dominio predice. La importancia por permutación agrupada, permutando dentro de los episodios, nunca entre ellos, responde cuánto aporta una característica una vez respetada la dependencia; Karbalaie *et al.* señalan explícitamente que las estimaciones de importancia dependen del diseño de validación y pueden ser inestables bajo particiones a nivel de fila [5], razón por la cual la agrupación forma parte de la medición y no es un detalle de ella. Las ablaciones por familia responden cuánto vale cada bloque de características. Los valores SHAP se emplean únicamente cuando el modelo elegido es un *ensemble* de árboles y la pregunta es la atribución por instancia, por qué *esta* posición recibió esta puntuación, puesto que esa es la pregunta que los tres instrumentos anteriores no pueden responder; no se incluyen meramente porque estén disponibles.

III-F. Contrato de reproducibilidad

Las semillas se fijan y se versionan; la auditoría ya se ejecuta bajo una única semilla declarada. Las configuraciones viven en ficheros y no en banderas de línea de comandos. La representación tabular se materializa una sola vez en formato columnar, puesto que el cuello de botella computacional es el análisis sintáctico y no el entrenamiento. Los datos crudos nunca se versionan; el repositorio lleva los *scripts* y las instrucciones para obtenerlos. Esto refleja la práctica del descriptor SC2EGSet, que publica sus herramientas de extracción, sus registros de procesamiento y sus estadísticas resumidas por paquete de repeticiones junto a los datos [3], y atiende una debilidad documentada de la literatura sobre cambio temporal, donde el código estaba disponible en solo dos de quince estudios revisados [7].

Tabla III
RIESGOS IDENTIFICADOS Y SU MITIGACIÓN.

Riesgo	Impacto	Mitigación / disparador
Instantáneas de un mismo episodio repartidas entre particiones	A	Agrupar por <i>episode_id</i> en todas partes; prueba automatizada que verifica intersección vacía entre particiones
Un campo prohibido alcanza el vector de características	A	Lista negra explícita; la construcción falla si una columna prohibida está presente
Fuga introducida por decisiones de diseño	M	Reglas de exclusión y ventanas de turno declaradas antes de tocar el conjunto de prueba [6]
Preprocesamiento ajustado sobre el conjunto completo	M	Todas las transformaciones se ajustan dentro del pliegue de entrenamiento [8]
Cambio de distribución entre días tempranos y tardíos	M	Reportar el protocolo temporal por separado y declarar cualquier caída como resultado, no como fallo [7]
Memorización de mazos en lugar de comprensión del estado	M	Protocolo de reserva de mazos y ablación del bloque de contexto de mazo [1]
Características trivialmente predictivas cerca del final	M	Análisis por ventana de turno; las conclusiones tempranas se sostienen solo sobre la ventana temprana
Versión del motor confundida con el tiempo de calendario	M	Registrar la versión como covariable de auditoría y declarar la confusión
Lectura optimista de una puntuación no calibrada	M	Reportar una regla de puntuación propia y curvas de fiabilidad junto al AUC [7]

III-G. Riesgos y mitigación

III-H. Integración prevista con el agente

En la Etapa 3 el estimador entrenado es consumido por un agente inteligente como evaluador de posiciones. La interfaz es deliberadamente estrecha: el agente entrega un estado, el mismo extractor de características usado en entrenamiento produce x , y el modelo devuelve $f(x) \in [0, 1]$. El agente no entrena el modelo, no lo actualiza mediante interacción y no lo sustituye, de modo que el proyecto no se convierte en aprendizaje por refuerzo en ninguna etapa. El consumo se verificará mostrando que el ordenamiento de posiciones candidatas por parte del agente cambia cuando el estimador se reemplaza por el *baseline* trivial B0, es decir, que el agente está efectivamente usando la predicción. La calibración importa precisamente por esta razón: un evaluador que ordena correctamente las posiciones pero está sistemáticamente sobreconfiado engañará a cualquier regla de decisión que compare sus salidas contra un umbral fijo.

IV. ANÁLISIS TÉCNICO DEL TRACK SELECCIONADO

El track aprobado es el Track A, aprendizaje automático clásico sobre datos tabulares. El análisis que sigue se apoya en una auditoría del corpus realizada antes de cualquier modelado; produjo un registro por episodio para cada episodio auditado, un censo de campos a nivel de instantánea y un conjunto de compuertas de decisión, todo reproducible bajo una única semilla fija.

Regla epistémica de esta sección. Toda cifra que aparece a continuación fue medida por nuestra propia auditoría del corpus y es reproducible a partir de los *scripts* de auditoría. Las magnitudes que no han sido medidas se nombran como pendientes, nunca se estiman.

IV-A. Análisis exploratorio

IV-A1. Alcance de lo que ha sido medido: El corpus publica 67 entregas diarias que abarcan del 2026-06-16 al 2026-08-21, declarando 329 336 episodios y 1.29 TB sin comprimir. La auditoría cubre una muestra temporal de 10 de esos días, el 14.9 % de los días y el 15.8 % de los episodios declarados, elegidos para abarcar las fases inicial, media y tardía de la competencia, con tres días consecutivos al comienzo de modo que pudiera medirse la deriva día a día. Dentro de esa muestra se analizaron 52 085 episodios a partir de 182.6 GiB de JSON con cero errores de análisis sintáctico, produciendo 7 038 378 instantáneas utilizables. Toda afirmación de esta sección está acotada a esa muestra; nada de lo aquí escrito caracteriza a los 57 días no auditados.

IV-A2. Tamaño, estructura y unidad de observación: La duración de las partidas está fuertemente sesgada a la derecha. El número de pasos por episodio tiene mediana 140 y media 137.1, con cuartiles 101 y 171, un percentil 95 de 221 y un máximo de 6 900. El recuento de turnos es mucho menor que el de pasos, mediana 13, media 14.3, percentil 95 de 27, máximo 1 035, porque un solo turno se descompone en muchas acciones atómicas. Esa brecha gobierna cómo debe definirse una ventana de turno: fijar el “juego temprano” en los turnos uno a ocho sería una elección arbitraria contra una distribución cuya mediana es 13, de modo que la ventana se define a partir de la distribución empírica y se declara antes de tocar el conjunto de prueba.

La unidad de observación es un estado fresco del asiento que actúa, y esta es una decisión medida antes que estilística. En un sondeo de 139 672 estados frescos, la observación perteneciente al asiento que no actúa resultó idéntica a su propio estado anterior en 137 989 casos, es decir el 98.8 %. Tratar cada asiento de cada paso como una fila duplicaría por tanto casi todas las observaciones sin añadir información, y reponderaría silenciosamente los episodios por su duración. Restringirse al asiento activo da una razón medida entre estados activos y pasos de 0.9854, que es de donde procede la cifra de 7 038 378, y no de $2 \times n_{\text{pasos}}$.

El número de unidades *independientes* es 52 085. Siete millones de filas y cincuenta y dos mil unidades independientes es el hecho más consecuente de esta sección, y la Sección IV-G está construida sobre él.

IV-A3. Distribución del objetivo a nivel de episodio:

El desenlace se deriva del campo de recompensas a nivel de episodio, que resuelve el 99.86 % de los episodios. Las combinaciones observadas son (1, -1) en 27 135 episodios, (-1, 1) en 24 844, (0, 0) en 33, y una recompensa que no es un número en 73. A nivel de episodio esto da un 52.10 % de victorias para el asiento P0, un 47.70 % para P1, un 0.063 % de empates y un 0.140 % de abandonos, sin episodios sin resolver. Restringido a los 51 979 episodios con ganador decidido, la tasa de victoria de P0 es 0.5220 y la del jugador que mueve primero es 0.5287.

IV-A4. Estructura temporal y deriva: Los diez días auditados no son intercambiables. Medida con la divergencia de Jensen-Shannon en base 2 entre el primer y el último día auditado, la distribución de mazos es esencialmente disjunta, con 1.0000, la población de agentes casi tanto, con 0.9723, la distribución de cartas se ha desplazado hasta 0.4889, mientras que la duración de las partidas apenas se ha movido, con 0.1221. La diversidad no decae de forma suave: los mazos distintos por día van de 1 268 el 2026-06-23 a 48 el 2026-07-17, y los equipos distintos de 2 309 a 79 en esos mismos dos días. La mediana de la puntuación media de los episodios sube de 628 el primer día a 1 141 el 2026-07-17. Seis versiones del motor coexisten en la muestra, de la 1.30.1 a la 1.32.4, y están ordenadas en el tiempo, lo que significa que tiempo de calendario y versión del motor están confundidos en la muestra auditada. La auditoría no puede separar la deriva del metajuego del cambio del motor, y este trabajo reportará esa confusión en lugar de resolverla.

Un hallazgo de deriva constituye una amenaza directa a una característica concreta. La probabilidad de que el jugador que mueve primero sea el asiento P0 era 0.5089 el 2026-06-29 y es 0.9991 desde el 2026-07-17 en adelante. En los días tardíos, identidad de asiento y orden de turno son casi la misma variable.

IV-B. Diccionario de datos

Un censo de campos sobre 139 672 estados frescos encontró 34 campos de estado presentes en el 100 % de las instantáneas inspeccionadas: 11 campos globales, 13 campos por jugador y 10 campos por Pokémon sobre 1 118 776 instancias de Pokémon. La Tabla IV agrupa las características candidatas por familia y tipo. El diccionario es preliminar y está sujeto a revisión tras el análisis exploratorio de la tabla materializada.

Dos campos se excluyen sobre bases medidas antes de cualquier modelado. El campo de resultado del estado actual contiene el valor -1 en el 100 % de los 139 672 estados frescos inspeccionados: es constante y no transporta información en el momento de la predicción. El campo `looking` es nulo en 137 029 de esos estados, es decir el 98.1 %, y su nulidad es una propiedad del juego y no un defecto, véase la Sección IV-D.

IV-C. Calidad de los datos

IV-C1. Qué ha sido verificado: Los 52 085 episodios auditados se analizaron sin error. Una única firma de esquema de nivel superior cubre el 100 % de ellos y `schema_version`

Tabla IV
DICCIONARIO DE DATOS POR FAMILIA DE CARACTERÍSTICAS. LA “PRESENCIA” ES LA PROPORCIÓN MEDIDA DE INSTANTÁNEAS INSPECCIONADAS EN LAS QUE EL CAMPO DE ORIGEN EXISTE.

Familia	Tipo	Campos, derivación y presencia
Progreso	entero, binario	<code>turn</code> y <code>turnActionCount</code> directos; el indicador de jugador inicial derivado de <code>firstPlayer</code> y <code>yourIndex</code> ; <code>energyAttached</code> y <code>retreated</code> binarios. Presencia 100 %.
Recursos	entero	<code>deckCount</code> y <code>handCount</code> directos; el tamaño de la mano derivado de la lista de la mano propia; el tamaño del descarte derivado. Presencia 100 %.
Premios	entero	Ranuras de premio restantes, derivadas contando las ranuras no vacías. Presencia 100 %; el contenido está siempre oculto.
Tablero	entero, continuo, binario	Tamaño de la banca frente a <code>benchMax</code> ; <code>hp</code> , <code>maxHp</code> y su razón; totales de puntos de vida visibles; recuento de Pokémon dañados; <code>energies</code> , <code>energyCards</code> , <code>tools</code> ; <code>preEvolution</code> y <code>appearThisTurn</code> como binarios. Presencia 100 %.
Estado alterado	binario	<code>poisoned</code> , <code>burned</code> , <code>asleep</code> , <code>paralyzed</code> y <code>confused</code> por jugador; <code>stadium</code> , <code>stadiumPlayed</code> y <code>supporterPlayed</code> globales. Presencia 100 %.
Diferenciales	entero, continuo	Propio menos rival para recuentos de mano, premios, banca, puntos de vida, energía y mazo. Derivados.
Contexto de mazo	categorico	Huella del mazo sobre un catálogo de 2376 mazos distintos. Alta cardinalidad; se admite únicamente en la ablación de contexto de mazo.
Agrupación (nunca características)	—	<code>episode_id</code> , <code>date</code> y el índice de turno. Se arrastran para agrupación, estratificación y reporte por ventana.

vale 1 en todos, de modo que el corpus es estructuralmente homogéneo pese a las seis versiones del motor. Los índices de turno fueron monótonos en todos los episodios inspeccionados, con cero violaciones. Todos los episodios auditados aparecen en el manifiesto de su día; a la inversa, cinco episodios declarados en el manifiesto del 2026-08-04 están ausentes de los ficheros, de 4 816 declarados.

IV-C2. Duplicados: Tres comprobaciones independientes de duplicidad devolvieron cero: ningún `episode_id` repetido, ningún SHA-256 repetido sobre los bytes del fichero, y ninguna huella canónica repetida, esta última calculada sobre la semilla de configuración, ambos mazos de sesenta cartas en orden, la secuencia completa de acciones de ambos asientos y las recompensas, excluyendo deliberadamente los metadatos volátiles. Ningún `episode_id` aparece en más de un día. El juego contra uno mismo, donde el mismo equipo ocupa ambos asientos, ocurre en cero de los 52 085 episodios.

La duplicación exacta no es, por tanto, una preocupación a nivel de episodio. La duplicación funcional dentro de un episodio es una cuestión distinta y sigue abierta: instantáneas consecutivas de la misma partida difieren en una acción atómica y son casi idénticas por construcción. En la muestra sondeada,

los 139 672 estados frescos fueron distintos dentro de sus turnos, de modo que no hay dos filas idénticas a nivel de bytes, pero las cuasi duplicadas son la norma antes que la excepción. Esto no es un defecto que deba eliminarse, es la estructura de dependencia de los datos, y se aborda mediante agrupación y no mediante deduplicación.

IV-C3. Comprobaciones aún pendientes sobre la representación tabular: La auditoría verificó el corpus crudo. Lo siguiente debe verificarse sobre la tabla materializada, y se consigna aquí como pendiente antes que como supuesto: la ausencia de valores por columna; los rangos imposibles, como puntos de vida negativos, puntos de vida por encima del máximo, recuentos negativos o tamaño de banca por encima de `benchMax`; la consistencia lógica entre campos relacionados; las filas duplicadas dentro y entre episodios; y la cardinalidad efectiva de las columnas categóricas.

IV-D. Valores ausentes e imputación

La política distingue dos mecanismos, porque tratarlos por igual sería un error.

Ausencia estructural. Un campo es nulo porque el juego lo define así: no hay Pokémon activo, no hay estadio en juego, la carta está oculta. El caso más claro es `looking`, nulo en el 98.1% de los estados inspeccionados, y el segundo es la mano del rival, nula en el 100% de ellos. No son valores estadísticamente ausentes y no se imputan. Se codifican semánticamente, con un indicador binario de presencia más un centinela explícito. Imputar una media aquí fabricaría un estado de juego que no puede ocurrir, y además destruiría la señal misma que el campo transporta: el hecho de que no se esté mirando nada es información.

Ausencia inesperada. Un campo requerido está ausente porque un episodio está malformado o el analizador sintáctico es incompleto. El procedimiento es medir primero la frecuencia; si es residual, excluir la observación o el episodio dejando constancia del criterio y del recuento; si es sistemática, tratarla como un defecto del analizador o un cambio de esquema y corregir la tubería en lugar de parchear los datos. Ninguna variable numérica se imputa automáticamente antes de haber estudiado su mecanismo de ausencia.

Sea cual sea el mecanismo elegido, el estimador se ajusta dentro del pliegue de entrenamiento. Sasse *et al.* nombran explícitamente la imputación entre los pasos de preprocesamiento que producen fuga cuando se estiman sobre el conjunto completo antes de particionar [8]. La estrategia definitiva se fija tras el análisis exploratorio de la tabla materializada y se documenta con la frecuencia que la justifica.

IV-E. Detección de valores atípicos

En este corpus un valor extremo suele ser un atípico válido antes que un error. Los pasos por episodio alcanzan 6 900 frente a una mediana de 140, y el recuento de turnos alcanza 1 035 frente a una mediana de 13 y un percentil 95 de 27. Una partida de 1 035 turnos merece investigación, no borrado: puede ser un tiempo agotado, un bucle de acciones, una interacción inusual

de cartas, un fallo del simulador o una partida genuinamente larga, y esos cinco casos exigen respuestas distintas.

El procedimiento propuesto es, por tanto, diagnóstico antes que correctivo. Los candidatos se marcan por distancia distribucional, una regla intercuartil o de puntuación z robusta sobre las características de duración y recuento, y por rangos imposibles en el dominio, que es una prueba distinta con un significado distinto. Los episodios marcados se inspeccionan caso por caso contra los estados registrados para ellos. Solo se eliminan los registros demostrablemente corruptos, y cualquier regla de exclusión se declara antes de examinar la partición de prueba; una regla elegida después de ver su efecto sobre la puntuación de prueba es una fuga por decisión de diseño en el sentido de Kaufman *et al.* [6]. Señalamos un contraste con la práctica seguida en un corpus comparable: los autores de SC2EGSet reemplazaron por la mediana los valores que excedían tres desviaciones estándar en sus propios experimentos [3]. Preferimos no adoptar esa regla por defecto aquí, porque en un juego por turnos la cola de la distribución de duración puede ser exactamente donde vive el comportamiento interesante.

IV-F. Desbalance de clases

A nivel de episodio el objetivo está cerca del equilibrio: 52.10 % frente a 47.70 %, con empates en 0.063 % y abandonos en 0.140 %.

Esa no es, sin embargo, la distribución que verá el modelo. La etiqueta se define desde la perspectiva del jugador que actúa, y cada partida aporta un número distinto de instantáneas desde cada bando, de modo que la prevalencia de clases de la tabla final es función de la tabularización y **aún no ha sido medida**. Debe recalcularse sobre la tabla materializada antes de tomar decisión alguna, y esta sección se completará con esa medición.

La regla de decisión queda no obstante fijada de antemano, de modo que no pueda elegirse para acomodar un resultado. Si el desbalance resultante es leve no se corregirá: corregir un desbalance que no necesita corrección distorsiona las probabilidades predichas, y esas probabilidades son la salida de este proyecto y no un subproducto. Si es apreciable, se preferirá la ponderación de clases al remuestreo, por la misma razón. No se usará sobremuestreo sintético sin justificación explícita, y bajo ninguna circunstancia fuera del pliegue de entrenamiento, Sasse *et al.* enumeran el sobremuestreo aplicado antes de particionar entre sus casos documentados de fuga de prueba a entrenamiento [8].

Los 33 empates y los 73 abandonos se tratan por separado. Los empates se excluyen del objetivo binario y se documentan; su volumen no puede sostener una tercera clase. Los abandonos tienen ganador identificable, pero el final no procede de la dinámica del juego, los estados registrados son tiempos agotados, errores y estados inválidos, de modo que se excluyen del entrenamiento y se reservan para un análisis de sensibilidad.

IV-G. Dependencia entre muestras y prevención de la fuga de datos

Esta es la subsección de la que depende la validez de todo lo demás, y el enunciado del curso penaliza la fuga confirmada

más severamente que cualquier otro fallo aislado.

IV-G1. La estructura de dependencia, medida: Cada episodio aporta en promedio unas 135 instantáneas, e instantáneas consecutivas difieren en una única acción atómica. Las filas son por tanto fuertemente dependientes dentro de un episodio e independientes solo entre episodios. Medimos la consecuencia directamente: bajo una partición aleatoria 70/30 a nivel de instantánea, la fracción esperada de episodios presentes en ambas particiones es 0.999945. Dicho de otro modo, el protocolo ingenuo contamina esencialmente todo el corpus.

La literatura dice qué le haría eso a las cifras. Karbalaie *et al.* midieron un acierto de 0.91 para *extra trees* bajo validación cruzada estratificada de diez pliegues frente a 0.66 dejando un participante fuera sobre los mismos datos, e identificaron la causa en que el tamaño muestral efectivo es el número de participantes y no el de ensayos [5]. Sasse *et al.* clasifican precisamente este caso, no tener en cuenta muestras dependientes, como vía primaria de fuga de prueba a entrenamiento y lo demuestran sobre pares de hermanos en una cohorte de neuroimagen [8]. Nuestro corpus es una instancia más extrema de la misma estructura: no dos muestras relacionadas, sino 135.

IV-G2. El momento de la predicción: Un campo puede existir en el JSON y aun así ser inválido como característica. La prueba que gobierna es el requisito de la no máquina del tiempo de Kaufman *et al.*: un modelo legítimo solo puede usar información de un instante no posterior al del objetivo [6], afinada por la pregunta que Sasse *et al.* recomiendan hacer de cada columna, si ese campo estaría disponible en el despliegue [8]. Aplicar esa prueba campo por campo produce cuatro clases.

Seguras. Los campos de estado presentes en el 100 % de las instantáneas, leídos de la observación propia del asiento activo en el turno τ , junto con los recuentos, razones y diferenciales derivados de ellos. Son lo que el propio agente vio cuando decidió.

Requieren investigación. El indicador de jugador inicial, porque asiento y orden de turno están casi perfectamente confundidos desde el 2026-07-17 en adelante y el modelo podría aprender el asiento en lugar del tempo; y el registro acumulado de acciones, que es legítimo únicamente si se trunca estrictamente antes de τ .

Fuga directa, excluidas por construcción. El campo de recompensas a nivel de episodio y el resultado final; cualquier recompensa por paso, que es no nula únicamente en el último paso; la carga útil de visualización, presente en el 100 % de los episodios, que expone el mazo restante de cada jugador en orden, información perfecta que nunca aparece en la observación y que el agente no tenía; las marcas de tiempo y los identificadores derivados del fichero; y los nombres de equipo o de agente, que actúan como sustituto de la habilidad. Lo último no es hipotético: la mediana de la puntuación media de los episodios seleccionados cada día sube de 628 a más de 1 100 a lo largo de la muestra, de modo que un identificador de agente codifica parcialmente el desenlace.

Tabla V
VECTORES DE FUGA DE DATOS, LA EVIDENCIA DE AUDITORÍA QUE ESTABLECE CADA UNO COMO RIESGO REAL, Y EL CONTROL APLICADO.

Vector	Evidencia medida	Control
Fuga de episodio	Una partición aleatoria 70/30 por filas sitúa 0.999945 de los episodios en ambas particiones	Partición y pliegues agrupados por <code>episode_id</code> ; prueba que verifica intersección vacía
Información futura	Carga útil de visualización presente en el 100 % de los episodios, que expone el mazo restante ordenado	Características extraídas solo de la observación del asiento en τ ; carga útil en lista negra
Sustituto de la habilidad	La mediana de la puntuación media sube de 628 a más de 1 100 a lo largo de la muestra	Metadatos de agente y equipo usados solo para auditoría y agrupación, nunca como características
Memorización de mazos	2 376 mazos, pero los 10 primeros cubren el 39.94 % de las instancias; un día tiene solo 48	Protocolo de reserva de mazos; contexto de mazo confinado a una única ablación declarada
Información oculta	0 fugas en 139 672 estados; 1 281 678 ranuras de premio todas nulas	Analizador que lee solo la observación propia, con una aserción automatizada de privacidad
Metadatos	52 085 <code>episode_id</code> distintos sobre 52 085 filas	Columnas de agrupación excluidas de la matriz de características por construcción
Preprocesamiento	(riesgo de diseño, no propiedad del corpus)	Todas las transformaciones se ajustan dentro del pliegue de entrenamiento [8]
Temporal	Divergencia de Jensen–Shannon de mazos de 1.0000 entre el primer y el último día auditado	El protocolo temporal corta por fecha, nunca al azar [6]

Excluidas por constantes. El campo de resultado del estado actual, fijo en -1 en todos los estados frescos.

IV-G3. Información oculta, verificada antes que supuesta: El entorno ya retiene lo que debe retener, y lo comprobamos en lugar de confiar. A lo largo de 139 672 estados inspeccionados, la mano del rival fue nula en el 100 % de los casos con cero fugas detectadas, mientras que el recuento de cartas del rival estuvo siempre disponible como entero. Las 1 281 678 ranuras de premio inspeccionadas, propias y del rival por igual, fueron todas nulas. La fuga de información oculta no es, por tanto, un riesgo que debamos mitigar; es una propiedad que no debemos destruir, razón por la cual las características se extraen exclusivamente de la observación propia del asiento y nunca de la carga útil de visualización.

IV-G4. Contramedidas: La Tabla V empareja cada vector con la evidencia que lo convierte en un riesgo concreto y con el control aplicado. Cada control se impone mediante una prueba automatizada y no por convención, que es la forma operativa de la separación aprender–predecir de Kaufman *et al.* [6].

IV-H. Representatividad

El corpus no es una muestra aleatoria del juego de *Pokémon TCG*, y el editor lo dice: las repeticiones se seleccionan a diario, ordenadas por puntuación media de los agentes, y se truncan a 20 GiB por día [4]. De ahí se siguen tres consecuencias, y las tres están medidas. La población es de agentes artificiales, no de humanos. Es la franja alta de la escalera de clasificación, con la mediana de la puntuación media ascendiendo a lo largo de la muestra. Y está concentrada: los diez mazos más frecuentes suman el 39.94 % de las instancias de mazo y los cien más frecuentes el 74.76 %, con días individuales que caen a 48 mazos distintos.

Esto refleja la limitación que los autores de SC2EGSet declaran para su propio corpus, que solo contiene repeticiones de nivel de torneo y por tanto no admite análisis entre niveles de habilidad [3], y es una versión más aguda del problema de población al que Janusz *et al.* se enfrentan desde la dirección opuesta, pues sus estados fueron generados por agentes que actúan al azar [2]. Leídos en conjunto, ambos acotan nuestro caso: un corpus procede de la población más débil posible y el otro de la más fuerte, y ninguno es la población general. Cualquier afirmación de este proyecto es, por tanto, una afirmación sobre agentes artificiales competitivos de una franja de puntuación específica durante una muestra específica de diez días, y la Sección V trata la tentación de enunciarla de forma más amplia como el principal riesgo ético.

V. CONSIDERACIONES ÉTICAS PRELIMINARES

V-A. Sensibilidad de los datos

El corpus no contiene datos clínicos, biométricos ni conductuales sobre individuos identificados: sus registros son partidas simuladas entre agentes de software, publicadas bajo una licencia CC0-1.0 [4]. Cabe una salvedad. Cada episodio lleva los nombres de equipo y de agente de los competidores, y en la muestra auditada esos nombres son seudónimos elegidos por sus dueños que en algunos casos se asemejan a nombres personales. Identifican a participantes de una competencia pública y no a sujetos de estudio, pero siguen siendo atribuibles a personas. Los tratamos por tanto como metadatos y no como material: se usan para auditoría, agrupación y la comprobación de juego contra uno mismo, quedan excluidos de la matriz de características por la lista negra descrita en la Sección IV-G, y no se publicará ningún ranking ni comparación agregada de competidores nombrados. Esto coincide con el control de fuga, lo cual es conveniente pero no es la razón de la decisión.

V-B. Sesgo y representatividad

El principal riesgo de este proyecto no es el daño a un sujeto de datos; es la sobreafirmación. Los episodios se seleccionan a diario por puntuación media de los agentes y se truncan a un volumen diario fijo [4], de modo que el corpus es la franja alta de una escalera de agentes artificiales y no una muestra del juego de *Pokémon TCG*. La auditoría cuantifica la concentración que se sigue de ello: los diez mazos más frecuentes cubren el 39.94 % de las instancias de mazo, un día auditado contiene solo 48 mazos distintos, y el conjunto de

mazos del último día auditado es esencialmente disjunto del del primero. Un modelo ajustado aquí aprende un metajuego estrecho y en movimiento.

De ahí se siguen tres lecturas erróneas, y cada una merece ser nombrada porque cada una es fácil de cometer. Extrapolar a jugadores humanos carecería de respaldo: no aparece ninguna partida humana en el corpus, y los dos corpus comparables de deportes electrónicos que revisamos declaran exactamente esta limitación para sí mismos [2], [3]. Extrapolar al juego completo tampoco tendría respaldo, puesto que un modelo que nunca vio un arquetipo de mazo carece de base para juzgar posiciones construidas en torno a él, Bertram *et al.* muestran cómo se ve ese fallo cuando el contenido se codifica por identidad en lugar de por descripción [1]. Y tratar la salida como una propiedad estable de una posición tampoco tendría respaldo a lo largo del tiempo, porque la población cambia de forma medible en diez días.

V-C. Interpretación de la probabilidad

Una estimación de probabilidad de victoria invita a un mal uso específico: leer un número entre cero y uno como una posibilidad bien fundada cuando puede ser solo una puntuación bien ordenada. La distinción no es pedante. Guo *et al.* encontraron deterioro de la calibración en todos los estudios que la midieron bajo cambio temporal, frente a deterioro de la discriminación en solo tres de doce [7], lo que significa que un modelo puede seguir ordenando posiciones correctamente mucho después de que sus probabilidades declaradas hayan dejado de ser ciertas. Ninguno de los dos estudios comparables sobre estados de juego reporta calibración en absoluto [2], [3]. Reportar una regla de puntuación propia y curvas de fiabilidad junto al AUC es por tanto un compromiso ético tanto como metodológico: es lo que permite a un lector saber cuál de las dos cosas es nuestro número.

V-D. Mitigaciones previstas antes del entrenamiento

- Toda cifra reportada lleva su alcance: los diez días auditados, la franja de puntuación y las versiones del motor presentes.
- La discriminación y la calibración se reportan por separado, y los resultados bajo los protocolos temporal y de reserva de mazos se reportan aparte del protocolo primario en lugar de promediarse con él.
- Los identificadores de agente y equipo quedan excluidos de la matriz de características, y no se publican resultados por competidor.
- Los intervalos de confianza se calculan sobre episodios, de modo que la incertidumbre no se subestime contando filas correlacionadas como evidencia independiente.
- El resumen, las conclusiones y cualquier síntesis pública declaran la población sobre la que se ajustó el modelo, de modo que la limitación viaje con el resultado en lugar de quedar confinada a esta sección.

V-E. Diferido a la Etapa 3

La ética del despliegue, los escenarios de mal uso y los riesgos operativos de un agente que consuma este estimador,

Tabla VI
USO DE HERRAMIENTAS DE INTELIGENCIA ARTIFICIAL EN ESTA VERSIÓN
INDIVIDUAL DE LA ETAPA 1.

Integrante	Herramienta	Dónde y para qué
S. Hernández	Claude (Claude Code, Opus 5)	Organización y cribado de la literatura; recuperación de textos completos desde fuentes de los editores y de acceso abierto; extracción de figuras, tablas y limitaciones declaradas de los siete trabajos revisados; resolución de metadatos bibliográficos contra Crossref y los registros de los editores; asistencia con LaTeX y construcción del fichero BibTeX.
S. Hernández	Claude (Claude Code, Opus 5)	Fase anterior: asistencia con los <i>scripts</i> de auditoría del corpus y con la lectura de sus salidas. Toda magnitud atribuida a la auditoría en la Sección IV es la salida de un <i>script</i> que se ejecutó sobre los datos descargados, no una cifra producida por un modelo de lenguaje.

en particular el efecto de un evaluador sobreconfiado sobre las decisiones del agente, se abordan en la etapa final, cuando exista un agente.

VI. DECLARACIÓN DE USO DE HERRAMIENTAS DE INTELIGENCIA ARTIFICIAL

Verificación realizada hasta ahora. Cada uno de los siete trabajos citados fue recuperado y leído a texto completo antes de ser citado, y todo valor atribuido a una fuente en este documento (tamaños de conjuntos de datos, valores de métricas, recuentos de estudios) fue transcrito de la tabla, figura o pasaje correspondiente de esa fuente. Todos los DOI se resolvieron contra Crossref o el registro del editor, y la bibliografía cita la versión que efectivamente se leyó. Una entrada merece mención explícita: para el marco de la fuga de datos citamos la versión de conferencia de KDD'11, que es la versión obtenida y leída; existe una versión de revista ampliada, que difiere en la lista de autores, y solo sustituirá a la actual si se lee a través de la suscripción institucional.

Verificación aún pendiente. Una relectura manual de las siete fuentes por parte del autor, independiente de la extracción descrita arriba, no se ha completado todavía y está programada antes de la entrega. Hasta entonces, esta declaración afirma extracción asistida por máquina con trazabilidad a nivel de fuente, y no confirmación humana independiente de cada cifra. El registro de trazabilidad, afirmación, fuente, ubicación en la fuente, se mantiene junto a esta versión de modo que cada enunciado pueda comprobarse individualmente.

Lo que no fue generado por inteligencia artificial. La pregunta de investigación, las hipótesis de trabajo, la elección del Track A, la decisión de agrupar por episodio, la lista negra de campos prohibidos, el diseño de la auditoría y su ejecución, y la interpretación de los resultados de la auditoría son trabajo propio de los autores. En este documento no se reporta ningún resultado experimental, de modo que ninguna herramienta generó resultado alguno.

VII. ESTADO ACTUAL Y PRÓXIMOS PASOS

La revisión establece que predecir el desenlace de una partida a partir de un único estado intermedio es un problema supervisado bien planteado en esta familia de juegos, que las características tabulares extraídas del estado transportan señal sustancial, y que los modelos clásicos capturan la mayor parte de ella: la mejor solución de *Hearthstone* mejoró al *baseline* de una red de dos capas ocultas en menos de un dos por ciento de AUC [2], y tres clasificadores convencionales quedaron a menos de 0.016 de acierto unos de otros en SC2EGSet [3]. Establece también lo que la literatura no ha resuelto. Ningún trabajo publicado plantea la pregunta para el *Pokémon TCG*. Ningún estudio comparable sobre estados de juego reporta si sus probabilidades están calibradas, aunque la evidencia sistemática identifica la calibración como la propiedad que falla primero [7]. Y el costo de ignorar la dependencia entre observaciones ha sido cuantificado en otros campos, un acierto de 0.91 para *extra trees* que colapsa a 0.66 una vez respetada la agrupación [5], pero se aplica de forma desigual dentro de los conjuntos de datos de juegos.

Este trabajo ataca esa intersección. Su objeto es el valor de un estado de forma aislada, aprendido *offline* bajo un protocolo cuyos controles de fuga se justifican por medición y no por argumento: en nuestra propia auditoría de 52 085 episodios y 7 038 378 instantáneas, una partición aleatoria a nivel de fila situaría el 99.995 % de los episodios a ambos lados de la división. La contribución a la que el proyecto aspira no es una puntuación de titular, sino una respuesta a tres preguntas ligadas: cuánto dice un estado, en qué momento de la partida empieza a decirlo, y cuánto sobrevive a un cambio de episodios, de mazos y de días.

El punto de referencia declarado es la banda de 0.78–0.80 de AUC del AAIA'17 sobre *Hearthstone*, adoptada como orden de magnitud y no como banco de pruebas, con las diferencias de juego, población de agentes, partición, prevalencia de clases y descripción del estado que impiden una comparación estricta enunciadas en la Sección II-E. Si el modelo clásico más fuerte alcanza esa banda en la ventana tardía de la partida bajo nuestro protocolo agrupado, el hallazgo sustantivo será en qué punto de la partida lo hace por primera vez.

Próximos pasos (Etapa 2).

- Materializar la representación tabular una sola vez, en formato columnar, y completar sobre ella las comprobaciones consignadas como pendientes en la Sección IV: prevalencia de clases del objetivo final, ausencia de valores por columna, rangos imposibles, filas duplicadas y cardinalidad efectiva.
- Implementar los controles de fuga como pruebas ejecutables, la aserción de lista negra y la aserción de intersección vacía entre particiones, y convertirlas en precondition de cualquier ejecución de entrenamiento.
- Fijar las ventanas de turno a partir de la distribución empírica de duración y declararlas antes de examinar la partición de prueba.
- Implementar y comparar la escalera de *baselines* B0 a B4 bajo el protocolo agrupado, reportando discriminación y

calibración con intervalos de confianza remuestreados sobre episodios.

- Ejecutar los protocolos temporal y de reserva de mazos y las ablaciones por familia de características, reportando cada uno por separado, y poner a prueba la hipótesis H3 sobre si la calibración se degrada antes que la discriminación.
- Fusionar esta revisión individual con las versiones de los Ejes A y B producidas por los otros dos integrantes del equipo en el artículo conjunto de la Etapa 1, resolviendo el solapamiento temático en lugar de concatenar las tres secciones de trabajos relacionados.

REFERENCIAS

- [1] T. Bertram, J. Fürnkranz, and M. Müller, "Learning with generalised card representations for "Magic: The gathering"," in *2024 IEEE Conference on Games (CoG)*. IEEE, 2024, pp. 1–8.
- [2] A. Janusz, T. Tajmajer, and M. Świechowski, "Helping AI to play Hearthstone: AAAI'17 data mining challenge," in *Proceedings of the 2017 Federated Conference on Computer Science and Information Systems (FedCSIS)*, ser. Annals of Computer Science and Information Systems, vol. 11. Prague, Czech Republic: IEEE, 2017, pp. 121–125.
- [3] A. Bialecki, N. Jakubowska, P. Dobrowolski, P. Bialecki, L. Krupiński, A. Szczap, R. Bialecki, and J. Gajewski, "SC2EGSet: StarCraft II esports replay and game-state dataset," *Scientific Data*, vol. 10, no. 1, p. 600, 2023.
- [4] The Pokémon Company, "PTCG AI battle challenge simulation episodes," Serie de conjuntos de datos diarios en Kaggle, competencia `pokemon-tcg-ai-battle`, 2026, repeticiones diarias de episodios, seleccionadas por puntuacion media de los agentes y truncadas a 20 GiB por día; licencia CC0-1.0.
- [5] A. Karbalaie, F. Abtahi, and C. K. Häger, "Participant-aware model validation for repeated-measures data: Comparative cross-validation study," *JMIR AI*, vol. 5, p. e87728, 2026.
- [6] S. Kaufman, S. Rosset, and C. Perlich, "Leakage in data mining: Formulation, detection, and avoidance," in *Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '11)*. San Diego, California, USA: ACM, 2011, pp. 556–563.
- [7] L. L. Guo, S. R. Pfohl, J. Fries, J. Posada, S. L. Fleming, C. Aftandilian, N. Shah, and L. Sung, "Systematic review of approaches to preserve machine learning performance in the presence of temporal dataset shift in clinical medicine," *Applied Clinical Informatics*, vol. 12, no. 4, pp. 808–815, 2021.
- [8] L. Sasse, E. Nicolaisen-Sobesky, J. Dukart, S. B. Eickhoff, M. Götz, S. Hamdan, V. Komeyer, A. Kulkarni, J. M. Lahnakoski, B. C. Love, F. Raimondo, and K. R. Patil, "Overview of leakage scenarios in supervised machine learning," *Journal of Big Data*, vol. 12, no. 1, p. 135, 2025.