

[POR COMPLETAR: Título del artículo — técnica + dominio + dataset]

Versión preliminar — Etapa 1: estado del arte y diseño propuesto

Adriel S. Chaves Salazar

Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica
2021031465

Daniel Duarte Cordero

Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica
2022012866

Sebastián Hernández Bonilla

Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica
[POR COMPLETAR: carné]

Resumen—Resumen preliminar. Este resumen describe el problema, la motivación y el enfoque propuesto. No incorpora resultados de ningún tipo, dado que en esta etapa no se ha ejecutado ningún experimento.

[POR COMPLETAR: 1–2 oraciones: el problema y por qué importa] [POR COMPLETAR: 1 oración: la brecha identificada en la literatura] [POR COMPLETAR: 1–2 oraciones: el enfoque propuesto y el track elegido] [POR COMPLETAR: 1 oración: el protocolo de evaluación y el baseline de literatura que el trabajo busca igualar o superar]

Palabras clave—[POR COMPLETAR: palabra clave], [POR COMPLETAR: palabra clave], [POR COMPLETAR: palabra clave], [POR COMPLETAR: palabra clave], [POR COMPLETAR: palabra clave]

I. INTRODUCCIÓN

I-A. Contexto y relevancia

Los juegos competitivos generan secuencias de estados en las que la ventaja cambia conforme avanza la partida. Estimar la probabilidad de victoria desde información disponible durante el juego es, por tanto, un problema distinto de predecir el ganador únicamente antes del inicio. En deportes electrónicos de tipo MOBA, la literatura ya trata la predicción de resultado como una aplicación consolidada de aprendizaje automático y emplea tanto variables previas a la partida como información observada durante ella [1]. Un ejemplo directo es el trabajo de Tian et al., que realiza predicción en tiempo real en *Honor of Kings* a partir de secuencias de estados y muestra que la importancia de la alineación, el oro, las bajas y las torres cambia con el progreso del encuentro [2].

La misma idea de asignar valor a estados intermedios aparece en juegos de cartas. Miernik y Kowalski evolucionan funciones de evaluación para *Legends of Code and Magic*, aunque su salida es un puntaje heurístico optimizado indirectamente por el rendimiento del agente, no una probabilidad calibrada de victoria [3]. Más cerca de nuestra formulación, el reto AAIA'17 de Hearthstone pidió estimar la probabilidad de que un jugador ganara a partir de un estado intra-partida y evaluó las soluciones mediante AUC [4]. En consecuencia, la pregunta general de predecir el desenlace desde estados intermedios no se presenta aquí como inédita; el interés está en trasladarla rigurosamente al

dominio de Pokémon TCG y estudiar sus problemas específicos de representación, fuga de información y generalización.

La generalización merece atención especial porque los entornos competitivos cambian. Chitayat et al. muestran en Dota 2 que representaciones ligadas a parámetros de diseño pueden conservar su rendimiento al atravesar parches posteriores, mientras que representaciones basadas solo en identidad son más frágiles [5]. En Pokémon VGC, VGC-Bench separa explícitamente el rendimiento sobre equipos vistos de la generalización a equipos no vistos y muestra que entrenar con mayor diversidad de composiciones mejora esa segunda capacidad [6]. Estos antecedentes motivan que una evaluación de Pokémon TCG no se limite a una partición aleatoria de partidas, sino que también examine cambios temporales y composiciones no observadas durante el entrenamiento.

I-B. Planteamiento del problema

El conjunto *PTCG AI Battle Challenge Simulation Episodes* contiene replays completos entre agentes artificiales. Una partida produce muchos snapshots correlacionados, por lo que la unidad de observación no coincide con la unidad estadísticamente independiente. La auditoría preliminar del proyecto identificó 52,085 episodios independientes y más de siete millones de snapshots útiles. Si estos snapshots se particionaran al azar, estados de una misma partida podrían aparecer en entrenamiento y prueba, produciendo una estimación artificialmente optimista del desempeño. El problema metodológico central es entonces estimar $P(\text{win} \mid \text{state})$ usando únicamente la información observable hasta el instante de predicción y manteniendo intactas las unidades independientes durante la evaluación.

Además, un buen resultado bajo partidas de distribución similar no basta para demostrar que el modelo aprendió propiedades transferibles del estado. La población auditada cambia en el tiempo en mazos, agentes y versión del motor, y los mazos más frecuentes concentran una parte importante de las observaciones. Por ello, el estudio debe distinguir entre generalización a nuevas partidas, a periodos futuros y a composiciones no vistas. Esta separación sigue la preocupación por robustez entre parches de

Chitayat et al. y por composiciones no vistas de VGC-Bench [5], [6].

I-C. Pregunta de investigación

PI: ¿En qué medida las características observables del estado de una partida de Pokémon TCG permiten predecir su resultado final mediante modelos clásicos de aprendizaje automático, cómo cambia esa capacidad predictiva conforme avanza la partida, y cuánto se conserva al evaluar sobre partidas, mazos y periodos no vistos en el entrenamiento?

Por qué es refutable. La respuesta sería negativa o quedaría sustancialmente debilitada si el intervalo de confianza del ROC-AUC en la ventana temprana incluyera 0.5, si el desempeño no mejorara al avanzar la partida, o si la señal desapareciera al evaluar en el protocolo temporal o en el holdout de mazos/matchups.

Por qué es medible. La discriminación se medirá con ROC-AUC y la calidad de la probabilidad con log loss, Brier score y curvas de calibración. Las métricas se reportarán globalmente y por ventana de turno. Las particiones y los intervalos de confianza se construirán sobre episodios, aunque cada fila del dataset tabular sea un snapshot.

I-D. Hipótesis de trabajo

H1: Las características estructuradas del estado contienen señal predictiva sobre el resultado desde etapas tempranas (ROC-AUC significativamente mayor que 0.5) y esa señal aumenta conforme progresa la partida.

H2: La señal temprana no se explica únicamente por el orden de turno ni por la identidad del mazo.

Criterios de falsación. H1 temprana se debilita si el intervalo de confianza del AUC temprano incluye 0.5; H1 dinámica se debilita si el AUC por ventana no aumenta una vez controlada la longitud de partida. H2 se debilita si un baseline compuesto por `is_first_player` e identidad de mazo iguala al modelo de estado completo. Una caída hasta azar en el protocolo temporal se interpretará como falta de generalización, no como un fallo de ejecución.

I-E. Objetivos

Objetivo general. Desarrollar y evaluar modelos clásicos de aprendizaje automático que estimen la probabilidad de victoria en Pokémon TCG a partir de características tabulares derivadas exclusivamente del estado observable, y caracterizar cómo evoluciona esa capacidad predictiva a lo largo de la partida.

Objetivos específicos.

1. Caracterizar el dataset y su calidad mediante EDA, diccionario de datos, análisis de faltantes, valores atípicos, desbalance y sesgos sobre la representación tabular final.
2. Construir un pipeline reproducible desde replay JSON hasta una tabla de snapshots frescos con perspectiva normalizada.
3. Diseñar y verificar controles de fuga mediante agrupación por `episode_id`, lista negra de campos y pruebas automáticas.

4. Comparar una escalera de baselines clásicos bajo protocolos agrupado, temporal y de robustez por mazo/matchup.
5. Analizar discriminación, calibración, explicabilidad y generalización globalmente y por ventana de turno.

I-F. Contribución esperada

Se espera aportar una formulación reproducible de estimación de probabilidad de victoria desde estados intermedios de Pokémon TCG, un pipeline tabular con controles explícitos de fuga, y una comparación entre modelos clásicos bajo distintos ejes de generalización. El trabajo también hará explícita la diferencia entre discriminación y calidad probabilística y evaluará si la información útil del estado cambia conforme avanza la partida, sin prometer de antemano que exista una mejora positiva.

I-G. Estructura del documento

La Sección II revisa la literatura en tres ejes y cierra identificando las brechas. La Sección III declara el baseline de literatura y su comparabilidad. La Sección IV presenta la metodología propuesta. La Sección V desarrolla el análisis técnico específico del track. La Sección VI documenta las consideraciones éticas preliminares.

II. TRABAJOS RELACIONADOS

Para descubrimiento y verificación se consultaron fuentes editoriales primarias y bases bibliográficas de IEEE, ACM, AAAI/AIIDE, Springer y los proceedings correspondientes. Se priorizaron trabajos arbitrados sobre predicción de victoria durante la partida, evaluación de estados en juegos de cartas, generalización entre composiciones o parches, y dos requisitos metodológicos del Track A: imputación y desbalance. Se excluyeron estudios exclusivamente pre-partida cuando no aportaban a la representación de estados ni a la generalización. **% TODO integración:** sustituir este párrafo por la metodología de búsqueda del equipo completo, incluyendo cadenas de búsqueda y el número total de trabajos cribados y retenidos.

II-A. Eje A: el problema y el dominio

La predicción de resultados en juegos competitivos aparece de forma recurrente en la literatura de esports. La revisión sistemática de Kamal et al. incluye 35 estudios de MOBA y encuentra un predominio del aprendizaje supervisado, con uso frecuente de estadísticas de jugador, mecánicas del juego y eventos intra-partida para tareas que incluyen la predicción del ganador [1]. El estudio de Tian et al. es un ejemplo específico de predicción durante la partida: su Hero Featured Network combina información de combate y de héroes a lo largo del tiempo y reporta 81.8% de accuracy en el nodo de 7 minutos en la tabla detallada, aunque el resumen del artículo menciona 84.7% [2]. Más importante para nuestro problema, el estudio muestra que la utilidad de las variables cambia con el progreso: la alineación domina al inicio, el oro gana relevancia en la etapa media y las bajas y torres se vuelven más informativas más adelante.

En juegos de cartas, la evaluación de estados se ha abordado con objetivos distintos. Miernik y Kowalski evolucionan funciones lineales y basadas en árboles para asignar un valor escalar a estados de *Legends of Code and Magic*; su mejor variante global alcanza 60.2% de win rate en el torneo de evaluación, pero la función se optimiza indirectamente por el desempeño del agente y no representa una probabilidad de victoria aprendida de pares estado–resultado [3]. El antecedente más cercano a nuestra tarea es el AIAA’17 Data Mining Challenge de Hearthstone: su objetivo fue predecir la probabilidad de victoria desde estados intra-partida y la métrica del reto fue AUC. El baseline oficial alcanzó 0.7846 y la mejor solución 0.8019 [4]. Este antecedente establece que el problema es viable en otro CCG, pero no resuelve su transferencia a Pokémon TCG ni sus riesgos particulares de dependencia entre snapshots.

Otra familia de trabajos se concentra menos en la precisión dentro de una distribución fija y más en la robustez frente a cambios del entorno. Chitayat et al. proponen Clustered Character Representation (CCR), que codifica héroes de Dota 2 mediante atributos y habilidades de diseño en lugar de depender solo de IDs. Un modelo con CCR obtiene AUC 0.85 en parches conocidos y mantiene 0.85 y 0.86 en dos parches posteriores no usados para entrenar el modelo con partidas, lo que apoya el uso de representaciones ligadas a mecánicas cuando el juego cambia [5]. Sin embargo, su caso de estudio predice conteos finales de bajas usando duración y composición de equipo, no probabilidad de victoria desde un estado intermedio rico.

VGC-Bench aborda otra forma de cambio: la diversidad de composiciones. El benchmark de Pokémon VGC separa equipos vistos y 72 equipos fuera de distribución, con 1000 episodios por emparejamiento en sus pruebas principales. En la prueba de generalización, el agente entrenado con 64 equipos vence al entrenado con uno con win rate 0.669, y los autores concluyen que una mayor diversidad de entrenamiento mejora la transferencia a equipos no vistos aun cuando empeora el rendimiento en configuraciones familiares [6]. La tarea es de aprendizaje de políticas, no de estimación probabilística, pero el diseño de holdout por composición ofrece un antecedente metodológico para preguntar si nuestro predictor aprende estado de juego o memoriza el metajuego.

Qué enfoques dominan. En esports predominan métodos supervisados para predicción de resultado y, en trabajos de estado dinámico, representaciones que incorporan información intra-partida. En CCG y Pokémon también aparecen evaluadores heurísticos, búsqueda, behavior cloning y aprendizaje por refuerzo, pero esos enfoques optimizan decisiones o políticas y no necesariamente producen probabilidades calibradas [1], [3], [6].

Qué se considera resuelto. La literatura demuestra que es posible extraer señal predictiva del estado durante la partida y que la importancia de las variables puede cambiar con la progresión temporal [2], [4]. También existen protocolos explícitos para estudiar robustez a parches y a composiciones no vistas [5], [6].

Qué sigue abierto. No se ha establecido, con las referencias revisadas, un protocolo equivalente para Pokémon TCG que

combine snapshots tabulares observables, control de dependencia entre estados de una misma partida, calidad probabilística y evaluación bajo cambio temporal y de mazos. Tampoco es válido asumir que los resultados de MOBA, VGC o Hearthstone se transfieren directamente porque cambian las reglas, las unidades de observación, los protocolos y la población.

II-B. Eje B: las técnicas del track

Dentro de las referencias asignadas a Daniel, dos trabajos sostienen decisiones transversales del Track A. Emmanuel et al. revisan mecanismos de datos faltantes y métodos de imputación, y muestran que la precisión relativa de KNN y missForest cambia entre datasets [7]. El resultado relevante para este proyecto no es que una técnica sea superior, sino que la estrategia de imputación depende del mecanismo de ausencia y de las características del conjunto de datos. Por ello, una frecuencia alta de valores ausentes no justifica por sí sola imputarlos automáticamente.

Van den Goorbergh et al. estudian modelos de regresión logística estándar y ridge bajo ausencia de corrección, random undersampling, random oversampling y SMOTE. Las correcciones no mejoran de forma sistemática el AUROC y sí producen sobreestimación pronunciada de la probabilidad de la clase minoritaria, deteriorando la calibración [8]. El alcance debe respetarse: el trabajo no evalúa `class_weight`, Random Forest, SVM o redes neuronales; por tanto, no justifica preferir ponderación de clases como regla general.

Fortalezas. Estas referencias permiten justificar un tratamiento de faltantes guiado por mecanismo y una evaluación del desbalance centrada no solo en clasificación sino también en calibración cuando la salida deseada es una probabilidad [7], [8].

Límites. Ninguna de estas dos referencias decide por sí sola qué modelo tabular clásico debe ser el principal. Paper 6 no formaliza nuestra noción de ausencia estructural/semántica, y Paper 7 solo estudia correcciones de desbalance en regresión logística. **% TODO integración:** incorporar las referencias de Adriel sobre modelos tabulares, calibración y explicabilidad para completar las 3–5 síntesis exigidas por el Eje B.

Supuestos bajo los que funcionan. Las decisiones de imputación requieren identificar razonablemente el mecanismo y tipo de dato; las conclusiones de Paper 7 son directamente aplicables a modelos de regresión logística probabilística y solo indicativas para otras familias.

Justificación técnica del track. Con las referencias de Daniel puede sostenerse que un problema de probabilidad sobre características estructuradas exige especial cuidado con calidad de datos y calibración. La justificación completa de por qué se elige Track A frente a una alternativa profunda o de RL debe integrarse con las referencias metodológicas del resto del equipo. **% TODO integración.**

II-C. Eje C: el dataset

El dataset *PTCG AI Battle Challenge Simulation Episodes* fue publicado en 2026 y, en la revisión realizada hasta esta etapa, no se localizó literatura arbitrada que lo utilice. Por ello,

el requisito de baseline se sustituye por datasets y entornos análogos. Hearthstone es el análogo más cercano porque también es un juego de cartas con información imperfecta y el reto AAIA'17 predice el ganador desde un estado intra-partida [4]. LoCM aporta un antecedente conceptual de evaluación de estados en CCG, aunque su protocolo es simulación evolutiva y su salida no es probabilística [3].

VGC-Bench y el trabajo de Chitayat et al. no son datasets equivalentes, pero aportan protocolos útiles para dos riesgos presentes en nuestros datos: composiciones no vistas y cambio de versión. VGC-Bench reserva configuraciones de equipo fuera de entrenamiento, mientras que CCR se evalúa en dos parches posteriores excluidos del entrenamiento con partidas [5], [6]. Estas comparaciones justifican incorporar pruebas de robustez separadas del holdout principal.

Métricas y protocolos reportados. Hearthstone usa AUC para comparar predictores de probabilidad; Tian et al. reportan accuracy por nodos temporales; Chitayat et al. reportan AUC entre parches; VGC-Bench usa win rate, cross-play, Alpha-Rank y evaluaciones sobre equipos vistos/no vistos [2], [4]–[6]. La heterogeneidad impide leer sus números como un ranking único.

Problemas conocidos. Los análogos revelan riesgos de representatividad y generalización: Tian et al. usan un solo día y jugadores de alto nivel; Chitayat et al. restringen sus partidas a profesionales/premium; VGC-Bench muestra degradación al ampliar la diversidad de equipos. En el dataset propio, además, la auditoría muestra fuerte dependencia entre snapshots de un mismo episodio y cambios temporales de mazos, agentes y versiones. **% TODO integración:** incorporar aquí la revisión específica de Sebastián sobre el dataset y análogos adicionales.

II-D. Análisis comparativo

La tabla muestra que los resultados numéricos no admiten una comparación directa. Tian et al. evalúan accuracy de un modelo secuencial en un MOBA, Miernik y Kowalski evalúan win rate de agentes que consumen una función heurística, VGC-Bench compara políticas por cross-play y el estudio de Chitayat et al. usa AUC para una tarea de predicción de bajas. Hearthstone es el único antecedente cuyo objetivo y métrica se aproximan a nuestro planteamiento: estimar la posibilidad de victoria desde un estado intra-partida mediante AUC [4].

Sí aparece una tendencia transversal: el desempeño depende del momento del juego y de la distribución sobre la que se evalúa. Tian et al. encuentran distinta utilidad de variables por etapa; VGC-Bench separa composiciones vistas de no vistas; Chitayat et al. separan parches de entrenamiento y parches futuros [2], [5], [6]. Por ello, un único holdout aleatorio sería insuficiente para sostener una conclusión fuerte de generalización en Pokémon TCG.

Otra limitación recurrente es que el resultado depende de una población acotada. Los estudios de HoK y Dota 2 revisados se restringen a jugadores de alto nivel/profesionales, y VGC-Bench trabaja con un entorno y formato distintos de Pokémon. Esto obliga a declarar los límites de extrapolación y evita

presentar un resultado sobre agentes artificiales de Pokémon TCG como evidencia sobre jugadores humanos.

II-E. Brechas identificadas

Carencias encontradas en la literatura.

1. No se localizó literatura arbitrada sobre el dataset específico de replays de la competencia Pokémon TCG de 2026.
2. La estimación de victoria desde estados existe en Hearthstone, pero no está establecida para la estructura de recursos y estados de Pokémon TCG en las referencias revisadas.
3. El antecedente de Hearthstone usa AUC como medida de discriminación, pero la calidad y calibración de la probabilidad requieren evaluación adicional cuando la salida se consume como evaluador de posiciones.
4. Los datasets con múltiples estados correlacionados por partida requieren particiones por unidad independiente; en el conjunto propio un split por snapshot produciría fuga entre episodios.
5. La literatura revisada muestra sensibilidad a composiciones y parches, pero no existe un protocolo único que combine partida nueva, mazo no visto y periodo futuro para esta tarea de Pokémon TCG.

Brechas que este trabajo aborda. El proyecto aborda las brechas 2–5 mediante una formulación supervisada de $P(\text{win} \mid \text{state})$, métricas de discriminación y calidad probabilística, particiones agrupadas por episodio, análisis por turno y pruebas secundarias temporales y por mazo/matchup.

Brechas fuera del alcance. La ausencia de literatura sobre el dataset no puede resolverse dentro del semestre; se documenta y se sustituye por análogos. Tampoco se busca demostrar transferencia a jugadores humanos, resolver el juego ni construir una política de RL. La comparabilidad estricta con Hearthstone permanece fuera del alcance porque cambian reglas, población, representación y protocolo.

III. BASELINE DE LITERATURA

III-A. Origen del baseline

El dataset propio carece de un resultado arbitrado previo directamente comparable. Se adopta como referencia análoga el AAIA'17 Data Mining Challenge sobre Hearthstone, cuya tarea consistía en estimar la probabilidad de victoria a partir de estados intra-partida y cuya métrica de competencia era AUC [4]. El artículo resumen reporta un baseline oficial de 0.7846 AUC y un mejor resultado final de 0.8019 AUC. La solución ganadora utilizó un ensamble de redes neuronales, pero ese detalle no convierte el valor en un benchmark equivalente para Pokémon TCG.

III-B. Número objetivo

Objetivo declarado: rango de referencia AUC 0.7846–0.8019 en el análogo de Hearthstone [4]. No se declara como umbral obligatorio a superar, sino como orden de magnitud externo para una tarea de predicción de victoria desde estado.

Tabla I
RESUMEN COMPARATIVO DE TRABAJOS RELACIONADOS.

Referencia	Año	Técnica	Dataset / entorno	Métrica principal	Resultado reportado	Limitación identificada
Kamal et al. [1]	2025	Revisión sistemática PRISMA	35 estudios sobre esports MOBA	Métricas heterogéneas	Sin mejor resultado único; se reportan, entre otros, AUC de 0.97 y accuracy cercana al 93 %	Alta heterogeneidad entre tareas, datasets y protocolos; generalización limitada entre regiones, periodos y poblaciones.
Tian et al. [2]	2022	Hero Featured Network (LSTM + características de héroes y combate)	27,256 partidas de Honor of Kings; 496,342 frames	Accuracy	81.8 % en el nodo de 7 min en la Tabla III; el abstract reporta 84.7 %	Datos de un solo día y jugadores de alto nivel; el split se describe a nivel de frames sin agrupación por partida explícita; no evalúa calibración.
Miernik y Kowalski [3]	2022	Evolución de funciones de evaluación lineales y basadas en árboles	Legends of Code and Magic	Win rate	60.2 % de win rate promedio global para Tree-from-Linear	No estima probabilidades supervisadas; puede existir especialización al oponente usado para evaluar fitness.
Angliss et al. [6]	2026	Behavior Cloning + RL multiagente (SP, FP y DO)	Pokémon VGC; poke-env; más de 700,000 battle logs humanos	Win rate / cross-play	Agente entrenado con 64 equipos vence al entrenado con 1 equipo con win rate de 0.669 sobre 72 equipos OOD	El desempeño disminuye al crecer la diversidad de equipos; la evaluación humana es anecdótica; no es una tarea de estimación de probabilidad.
Chitayat et al. [5]	2023	Clustered Character Representation con K-Means + redes neuronales	Dota 2; parches 7.27–7.33; 61,254 partidas	AUC	0.85 en test de parches conocidos, 0.85 en 7.32 y 0.86 en 7.33	Solo partidas profesionales/premium; predice bajas finales a partir de duración y composición, no probabilidad de victoria desde un estado intermedio rico.
Janusz et al. [4]	2017	Challenge de ML con baseline neuronal y soluciones de ensamble	Hearthstone; estados intermedios de partida	AUC	Baseline oficial 0.7846; mejor solución 0.8019	Juego, representación, población y protocolo diferentes; la comparación con Pokémon TCG es solo parcialmente comparable.

III-C. Comparabilidad del protocolo

La comparación es **parcialmente comparable**. Coinciden la naturaleza binaria del desenlace, el uso de información intra-partida y la evaluación mediante AUC, pero no coinciden el juego, las reglas, la representación del estado ni la población que genera las partidas. El valor de Hearthstone sirve para contextualizar el desempeño, no para afirmar superioridad directa.

Diferencias que impiden una comparación justa.

- La partición y el mecanismo de generación de ejemplos del reto de Hearthstone no son equivalentes a nuestro split agrupado por `episode_id` ni al protocolo temporal.
- Aunque ambos reportan AUC, nuestro estudio añade log loss, Brier score y calibración, por lo que la evaluación no se reduce a la misma métrica.
- Los estados, cartas, recursos, reglas y representación de Hearthstone son distintos de los snapshots observables de Pokémon TCG.
- La población de bots, mazos y distribución competitiva difiere de los agentes artificiales y mazos de la competencia Pokémon TCG.

Qué significa entonces el número. El intervalo 0.7846–0.8019 se usa como referencia externa del nivel de discriminación alcanzado en una tarea análoga. No es una cifra que el proyecto deba “batir” para considerarse válido: un resultado inferior puede ser metodológicamente sólido si se obtiene bajo un protocolo más estricto, y uno superior no probaría automáticamente mejor desempeño por las diferencias anteriores.

IV. METODOLOGÍA PROPUESTA

IV-A. Formalización del problema

El problema se formula como clasificación binaria probabilística sobre datos tabulares. Sea $x_t \in \mathcal{X}$ el vector de características construido exclusivamente con información observable hasta el instante t , y sea $y \in \{0, 1\}$ el resultado final desde la perspectiva del jugador al que corresponde la fila. Se aprende una función $f_\theta : \mathcal{X} \rightarrow [0, 1]$ que aproxime la probabilidad condicional de victoria.

$$f_\theta(x_t) \approx P(y = 1 \mid x_t), \quad \theta^* = \arg \min_{\theta} \sum_{i \in \mathcal{D}_{\text{train}}} \ell(y_i, f_\theta(x_i)), \quad (1)$$




Figura 1. Pipeline propuesto: replay JSON → validación de esquema → snapshots frescos normalizados → tabla de features → particiones por episodio → modelos y evaluación → probabilidad consumida por el agente.

donde ℓ es una función de pérdida probabilística apropiada para el modelo y toda selección de hiperparámetros se realiza sin utilizar el conjunto de prueba.

Definición del target. La etiqueta se deriva de `rewards` a nivel de episodio: $y = 1$ si gana el jugador desde cuya perspectiva se construye el snapshot y $y = 0$ si pierde. La auditoría resolvió el resultado en 99.86 % de los episodios. Los 33 empates se excluyen inicialmente del target binario. Los 73 finales por `TIMEOUT`, `ERROR` o `INVALID` se excluyen del entrenamiento principal y se reservan para análisis de sensibilidad, porque el desenlace no procede de la dinámica normal del juego.

Unidad de observación. Una fila corresponde a un snapshot fresco del asiento activo, proyectado a una perspectiva común *self/opp*. La observación congelada del asiento inactivo no se duplica como fila adicional.

Unidad independiente. La unidad estadísticamente independiente es el episodio. Los 52,085 episodios auditados generan más de siete millones de filas, pero ningún episodio puede aparecer en más de una partición. Esta distinción gobierna splits, validación e intervalos de confianza.

IV-B. Pipeline previsto

El pipeline ingiere los replays JSON, valida la firma de esquema y `schema_version`, selecciona los estados frescos del asiento activo y normaliza la perspectiva mediante `yourIndex`. Luego construye características de progreso, recursos, tablero, energía, estados especiales y diferenciales entre ambos jugadores. Las columnas `episode_id`, fecha y turno se conservan para agrupación, estratificación y análisis, pero no entran al vector predictivo. La tabla materializada se divide por episodio antes de ajustar cualquier transformación. Sobre train se ajustan preprocesamiento y modelos; la validación selecciona hiperparámetros y el test queda intacto hasta la evaluación final. En Etapa 3, el mismo extractor convertirá un estado actual en features y entregará $P(\text{win} \mid \text{state})$ al agente como evaluador de posiciones.

IV-C. Protocolo experimental

IV-C1. Particiones: El protocolo principal será 70/15/15 para train, validación y test, **agrupando por `episode_id`**. Se descarta el split por snapshot porque estados de una misma partida son fuertemente correlacionados y su presencia a ambos lados de la partición produciría fuga. Como protocolo secundario se usará una partición temporal: train con 2026-06-17, 06-18, 06-23 y 06-29; validación con 07-05 y 07-11;

Tabla II
MÉTRICAS DE EVALUACIÓN Y SU JUSTIFICACIÓN.

Métrica	Por qué esta y qué alternativa desplaza
ROC-AUC	Métrica principal de discriminación, independiente de un umbral y directamente comparable con el antecedente de Hearthstone [4].
Log loss	Evalúa la calidad de la probabilidad y penaliza con fuerza predicciones seguras y equivocadas; complementa lo que AUC no mide.
Brier score + calibración	Mide error cuadrático de probabilidad y se acompaña con curvas de fiabilidad; es necesario porque una corrección de clases puede preservar discriminación y deteriorar calibración [8].

test con 07-25 y 08-04. El día 06-16 se mantiene fuera por ser un arranque parcial y 07-17 se reserva por su concentración extrema de mazos/agentes, sujeto a revisión posterior al EDA. Un tercer análisis de robustez reservará mazos o pares de mazos completos para prueba. El objetivo de estos protocolos separados es distinguir nueva partida, futuro temporal y composición no vista, una preocupación coherente con la evaluación entre parches y equipos observada en literatura [5], [6].

IV-C2. Estrategia de validación: La selección de hiperparámetros se realizará exclusivamente dentro de train mediante validación cruzada agrupada por episodio (`GroupKFold`) o una variante equivalente que preserve grupos. La partición de validación externa se usa para comparar configuraciones y fijar decisiones antes de la prueba final. El test principal se toca una sola vez para la evaluación reportada. En el protocolo temporal se respeta el orden cronológico y no se reutilizan datos futuros para ajustar transformaciones.

IV-C3. Métricas y su justificación: ROC-AUC es principal porque conecta con el único antecedente cercano y responde si el modelo ordena estados ganadores por encima de perdedores. No obstante, una salida destinada a interpretarse como probabilidad no puede evaluarse solo por ranking o accuracy. Van den Goorbergh et al. muestran que intervenciones de balance pueden dejar el AUROC prácticamente sin mejora y, simultáneamente, distorsionar las probabilidades [8]. Por eso se reportan log loss, Brier score y curvas de calibración, globalmente y por ventana de turno. Los intervalos de confianza se estimarán por bootstrap sobre episodios, no sobre snapshots.

IV-D. Plan de baselines

Cada nivel añade complejidad solo para responder una pregunta que el anterior no puede resolver.

Tercera referencia. El rango 0.7846–0.8019 AUC de Hearthstone se arrastra como referencia externa parcialmente comparable junto con los baselines internos [4].

IV-E. Contrato de reproducibilidad

La auditoría ya utiliza la semilla fija 20260821. La etapa de modelado mantendrá las semillas y configuraciones en archivos versionados, fijará dependencias, registrará cada ejecución y su commit, y guardará tablas comparables de parámetros y

Tabla III
ESCALERA DE BASELINES.

Nivel	Modelo	Pregunta que responde
B0	DummyClassifier (prior / clase mayoritaria)	¿Cuál es el piso de rendimiento?
B1	Heurística simple de recursos o premios, fijada tras EDA	¿Hace falta ML o basta una regla de dominio?
B2	Regresión logística regularizada	¿La relación es esencialmente lineal y ofrece una referencia probabilística interpretable?
B3	Árbol de decisión / Random Forest	¿Hay no linealidades e interacciones que B2 no captura?
B4	Gradient Boosting (familia por fijar)	¿Cuánto rendimiento adicional compra la complejidad del ensamble?

Tabla IV
RIESGOS IDENTIFICADOS Y SU MITIGACIÓN.

Riesgo	Impacto	Mitigación / disparador
Fuga entre snapshots del mismo episodio	A	Split y CV obligatoriamente agrupados por episode_id; prueba de intersección vacía.
Uso de información futura/privada	A	Lista negra de rewards, visualize, metadata y campos posteriores al snapshot; test automático de columnas.
Cambio temporal de población/versión	A	Reportar holdout agrupado y temporal por separado; tratar la caída como resultado y no ocultarla.
Memorización de mazos frecuentes	M/A	Holdout por mazo/matchup y ablación de contexto de mazo; interpretar ganancias de ID con cautela.

métricas. El repositorio documentará hardware y el comando exacto de reproducción de cada resultado una vez el pipeline quede implementado. % **TODO implementación/integración:** insertar aquí los nombres finales de los archivos de configuración y comandos reproducibles; no se inventan en esta etapa.

IV-F. Riesgos y mitigación

V. ANÁLISIS TÉCNICO DEL TRACK

El proyecto trabaja en **Track A — aprendizaje automático clásico sobre datos tabulares**. % **TODO integración:** insertar la fecha exacta de aprobación comunicada por el docente.

V-A. Análisis exploratorio

La auditoría preliminar contiene 52,085 episodios independientes y 7,038,378 snapshots frescos útiles. Se inspeccionaron 34 campos de estado presentes en el 100 % de los snapshots muestreados. El target a nivel de episodio se resuelve desde rewards en 99.86 % de los casos: 27,135 episodios con recompensa (1, -1), 24,844 con (-1, 1), 33 empates y 73 casos con final anómalo. La representación final desde la perspectiva del jugador activo todavía debe materializarse para medir su proporción de clases por snapshot; no se sustituye esa medida por la distribución P0/P1 del episodio.

Tabla V
DICCIONARIO DE DATOS (EXTRACTO).

Variable	Tipo	Origen	Significado / rango / riesgo
turn	entero	current.turn	Progreso del juego; se usa para análisis por ventana y no como timestamp futuro.
is_first_player	binaria	firstPlayer/orden de inicio	Orden de inicio; riesgo de atajo porque se confunde con asiento en días tardíos.
prize_remaining	entero	ranuras de prize	Premios restantes por jugador; feature derivada observable.
active_hp_ratio	continua	active.hp/maxHp	Salud relativa del activo; debe respetar $0 \leq hp \leq maxHp$.
energy_diff	entero	agregados self-opp	Diferencia de energías visibles en tablero.
deck_hash	categorica	catálogo de mazos	Alto riesgo de memorizar metajuego; solo en ablación/contexto y con holdout por mazo.

La muestra cubre diez días auditados y varias versiones del motor (aproximadamente 1.30.1 a 1.32.4). Se identificaron 2,376 mazos y 3,139 agentes, con concentración apreciable y cambio temporal fuerte. La unidad de agrupamiento es el episodio, no el snapshot. El EDA de la tabla final reportará distribución por turno, episodios por día, cardinalidad de categóricas, percentiles de numéricas y correlaciones calculadas solo sobre train.

V-B. Diccionario de datos

El diccionario completo debe mantenerse en el repositorio e incluir familias de progreso, recursos, tablero, energía, estados especiales, diferenciales y contexto. Las columnas de agrupación y auditoría se documentan, pero se separan del vector predictivo.

V-C. Calidad de los datos

La auditoría verificó 52,085 episodios válidos, cero errores de parseo, una única firma de esquema top-level, schema_version=1, cero duplicados por episode_id/hash canónico, cero solapamientos entre días y cero self-play. Se identificaron cinco episodios declarados en el manifest del 2026-08-04 pero ausentes de los archivos. Sobre la tabla materializada se verificarán faltantes por columna, rangos imposibles (por ejemplo, HP negativo o mayor a maxHp), conteos negativos, bench_size > benchMax, consistencia lógica y cardinalidad de categóricas antes de cualquier modelado.

V-D. Datos faltantes e imputación

Emmanuel et al. distinguen mecanismos de datos faltantes y muestran que la eficacia de un método de imputación depende de las características del dataset; en su experimento KNN y missForest intercambian cuál es mejor según el conjunto de datos [7]. Por ello, la política del proyecto es medir y

caracterizar la ausencia antes de imputar, en vez de aplicar una técnica por defecto.

Ausencia estructural. En el replay existen valores `None` que corresponden a estados semánticamente no aplicables u ocultos por las reglas del juego, por ejemplo ausencia de un objeto o información privada del rival. La auditoría observó `looking=None` en 98.1 % de los estados inspeccionados. La decisión de codificar estos casos semánticamente proviene del esquema y del dominio del juego; **Paper 6 no formaliza por sí solo la categoría “ausencia estructural” ni debe citarse como si lo hiciera.** Se requiere una referencia adicional específica sobre missing-by-design/structural missingness para sostener esa terminología en la versión final.

Ausencia inesperada. Si un campo requerido falta por corrupción, cambio de esquema o error del parser, se medirá su frecuencia. Si es residual, podrá excluirse la observación o episodio con criterio documentado; si es sistemático, se tratará como defecto del pipeline o cambio de esquema y se corregirá antes de entrenar, no se ocultará mediante imputación.

Estrategia adoptada. Ninguna variable numérica se imputa automáticamente. Primero se clasifica la causa de ausencia y el tipo de variable; luego se decide si corresponde codificación semántica, exclusión documentada o una técnica de imputación ajustada solo con train. Esta postura es coherente con la conclusión de Emmanuel et al. de que no existe un método universalmente superior [7].

V-E. Valores atípicos

La detección combina reglas de dominio y estadística descriptiva. Los rangos imposibles se consideran errores potenciales; los extremos válidos se auditan antes de decidir cualquier exclusión. Por ejemplo, `n_steps` tiene mediana 140 y máximo 6,900, mientras `max_turn` tiene mediana 13, P95 27 y máximo 1,035. Un episodio de 1,035 turnos no se elimina por ser extremo: se investiga si corresponde a timeout, bucle, interacción válida o error. Las reglas de exclusión se fijan antes de observar el test.

V-F. Desbalance de clases

A nivel de episodio, P0 gana 52.10 % y P1 47.70 %, con 0.063 % de empates y 0.140 % de forfeits. Sin embargo, la etiqueta final se define desde la perspectiva del jugador activo y cada bando aporta un número distinto de snapshots; por eso la proporción de clases relevante debe medirse sobre la tabla final antes de elegir una intervención.

Si el desbalance es leve, la opción inicial será no corregirlo. Van den Goorbergh et al. muestran que, para regresión logística estándar y ridge, RUS, ROS y SMOTE no mejoran sistemáticamente el AUROC y pueden sobreestimar fuertemente la probabilidad de la clase minoritaria [8]. Dado que nuestra salida pretende interpretarse como probabilidad, cualquier corrección debe evaluarse también por calibración. Este artículo **no** avala preferir `class_weight`: esa técnica no fue evaluada y, por tanto, no se adoptará por cita indirecta. Si el EDA revela un desbalance material, se compararán alternativas únicamente dentro de train y se reportará su efecto sobre discriminación y calibración.

Tabla VI
VECTORES DE FUGA: RIESGO, EVIDENCIA Y MITIGACIÓN.

Tipo	Riesgo y evidencia medida	Mitigación
Episode leakage	Un split aleatorio de snapshots coloca estados de la misma partida en train y test para prácticamente todos los episodios.	Split/CV por <code>episode_id</code> ; intersección de grupos debe ser vacía.
Temporal/target leakage	<code>rewards</code> , <code>visualize</code> o logs futuros revelan desenlace o información posterior.	Lista negra y parser limitado a <code>observation</code> hasta t .
Deck/agent leakage	IDs o metadata pueden actuar como proxies del metajuego/habilidad; top-10 de mazos concentra 39.94 %.	Metadata fuera de features; holdout por mazo/matchup y ablación del contexto de mazo.

V-G. Prevención explícita de data leakage

El riesgo principal del Track A en este proyecto proviene de la multiplicidad de snapshots por episodio y de la presencia de información que solo existe después de la decisión. La mitigación combina diseño de particiones, exclusión de columnas y pruebas automáticas.

V-G1. Lista negra de información prohibida: No pueden entrar al vector de características: `episode_id`; nombres de equipo o agente; scores del manifest; timestamps como predictores directos; `rewards` y resultado final; cualquier campo posterior al snapshot; información privada del rival; `visualize`; contenido futuro de logs; nombres de archivo, rutas y hashes. En particular, `visualize` expone el mazo restante ordenado y no representa información disponible para el agente en el momento real de decisión.

V-G2. Taxonomía de riesgo:

V-G3. Verificación automática: El pipeline incluirá al menos dos invariantes que deben fallar en CI o antes de entrenar: (1) ninguna columna de la lista negra puede aparecer en el conjunto de features, y (2) la intersección de `episode_id` entre cualquier par de particiones debe ser vacía. Se añadirá una prueba del parser para confirmar que la información privada del rival permanezca oculta y que ninguna transformación se ajuste con datos de validación o test.

VI. CONSIDERACIONES ÉTICAS PRELIMINARES

VI-A. Sensibilidad de los datos

Los replays analizados describen partidas entre agentes artificiales y estados del juego; en la auditoría realizada no se identificaron datos personales sensibles de jugadores humanos. Sí existen nombres o IDs de agentes/equipos que se tratarán como metadata de auditoría y no como features. **% TODO integración:** verificar y citar la licencia exacta con la que The Pokémon Company/Kaggle distribuye los replays y resumir explícitamente qué usos y redistribución permite. No se infiere la licencia a partir de la mera disponibilidad pública.

VI-B. Riesgo de sesgo

La muestra no es aleatoria respecto del universo de Pokémon TCG. Los replays de la competencia se seleccionan por rating medio y se truncan a un volumen diario, por lo que representan principalmente agentes artificiales competitivos. La auditoría además muestra concentración de mazos y agentes, así como cambio fuerte entre días: el top-10 de mazos concentra 39.94 % de las instancias auditadas y las distribuciones de mazos/agentes cambian sustancialmente entre el primer y último día. Esto puede favorecer atajos asociados al metajuego dominante y degradar el desempeño cuando cambian composiciones o versiones.

La literatura revisada refuerza que este riesgo no es meramente hipotético: VGC-Bench encuentra diferencias entre rendimiento en equipos vistos y generalización a equipos no vistos, mientras Chitayat et al. separan evaluación en parches conocidos y posteriores [5], [6].

VI-C. Límites de generalización declarados

Los resultados no deben extrapolarse a jugadores humanos, al Pokémon TCG físico, a todas las estrategias posibles, ni a versiones del motor, mazos o poblaciones que no hayan sido cubiertos por los protocolos de evaluación. Tampoco un buen resultado en el split agrupado implica robustez temporal: esa afirmación solo podrá hacerse si el modelo mantiene desempeño bajo el protocolo cronológico. De forma análoga, un buen AUC global no implica que la probabilidad esté calibrada ni que el modelo funcione igual en etapas tempranas y tardías.

VI-D. Mitigación prevista antes de entrenar

- Separar y reportar los protocolos agrupado, temporal y por mazo/matchup, sin ocultar caídas de desempeño bajo cambio de distribución.
- Prohibir identidades de agente, ratings y metadata similares como features; usar la identidad de mazo solo en una ablación controlada y evaluarla con holdout por mazo.
- Reportar explícitamente composición de la muestra, versiones, concentración y límites de población para evitar que el modelo se presente como generalizable a humanos o a todo Pokémon TCG.

VI-E. Diferido a la Etapa 3

La ética del despliegue, los escenarios de uso indebido y los riesgos operativos del agente inteligente se abordan en la etapa final.

REFERENCIAS

- [1] A. A. Kamal, M. A. Mansor, L. Truna, N. Mohd. Shaipullah, and N. H. Habib Sultan, "Machine learning applications in multiplayer online battle arena esports—a systematic review," *Pertanika Journal of Science & Technology*, vol. 33, no. 2, pp. 765–798, 2025.
- [2] P. Tian, W. Lan, and X. Zhang, "Hero featured learning algorithm for winning rate prediction of honor of kings," in *2022 IEEE Conference on Games (CoG)*. IEEE, 2022, pp. 322–329.
- [3] R. Miernik and J. Kowalski, "Evolving evaluation functions for collectible card game ai," in *Proceedings of the 14th International Conference on Agents and Artificial Intelligence (ICAART)*, vol. 3. SciTePress, 2022, pp. 253–260.
- [4] A. Janusz, T. Tajmayer, and M. Świechowski, "Helping ai to play hearthstone: AAAI'17 data mining challenge," in *Proceedings of the 2017 Federated Conference on Computer Science and Information Systems (FedCSIS)*, ser. Annals of Computer Science and Information Systems, vol. 11, 2017, pp. 121–125.
- [5] A. Pedrassoli Chitayat, F. Block, J. Walker, and A. Drachen, "Beyond the meta: Leveraging game design parameters for patch-agnostic esports analytics," in *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 19, no. 1, 2023, pp. 116–125.
- [6] C. L. Angliss, J. Cui, J. Hu, A. Rahman, and P. Stone, "VGC-Bench: Towards mastering diverse team strategies in competitive pokémon," in *Proceedings of the 25th International Conference on Autonomous Agents and Multiagent Systems (AAMAS 2026)*. IFAAMAS, 2026, pp. 2299–2307.
- [7] T. Emmanuel, T. Maupong, D. Mpoeleng, T. Semong, B. Mphago, and O. Tabona, "A survey on missing data in machine learning," *Journal of Big Data*, vol. 8, no. 1, p. 140, 2021.
- [8] R. van den Goorbergh, M. van Smeden, D. Timmerman, and B. Van Calster, "The harm of class imbalance corrections for risk prediction models: Illustration and simulation using logistic regression," *Journal of the American Medical Informatics Association*, vol. 29, no. 9, pp. 1525–1534, 2022.